INF712 - Computerunterstützte Statistik

26-27 WS

08/10/2026

Inhaltsverzeichnis

1 Vorlesung 02-01: Grundlagen der Wahrscheinlichkeitsrechnung 3

1.0.1 Ergebnismenge und Ereignisse . . . 3
1.0.2 Mengenoperationen . . . 3
1.0.3 Die Axiome der Wahrscheinlichkeit . . . 4
1.0.4 Anwendungen in der Systemzuverlässigkeit . . . 4
1.0.5 Kombinatorik . . . 5
1.0.6 Bedingte Wahrscheinlichkeit und Unabhängigkeit . . . 6
1.0.7 Satz der totalen Wahrscheinlichkeit und Satz von Bayes . . . 6
1.0.8 Übungsaufgaben zu Kapitel 1 . . . 7
1.0.9 Mathematische Herleitung . . . 7
1.0.10 R-Code & Simulation . . . 7
1.0.11 Mathematische Herleitung . . . 8
1.0.12 R-Code & Simulation . . . 8
1.0.13 Mathematische Herleitung . . . 9
1.0.14 R-Code & Simulation . . . 9
1.0.15 Mathematische Herleitung . . . 9
1.0.16 R-Code & Simulation . . . 10
1.0.17 Mathematische Herleitung . . . 10
1.0.18 R-Code & Simulation . . . 11
1.0.19 Mathematische Herleitung . . . 12
1.0.20 R-Code & Simulation . . . 12
1.0.21 Mathematische Herleitung . . . 13
1.0.22 R-Code & Simulation . . . 13
1.0.23 Mathematische Herleitung . . . 14
1.0.24 R-Code & Simulation . . . 14
1.0.25 Mathematische Herleitung . . . 15
1.0.26 R-Code & Simulation . . . 15

1.1 Kapitel 2: Diskrete Zufallsvariablen . . . 16
1.1.1 Das Konzept der Zufallsvariable . . . 16
1.1.2 Wahrscheinlichkeitsfunktion (PMF) und Verteilungsfunktion (CDF) . . . 16
1.1.3 R-Simulation: Drei Münzwürfe . . . 16
1.1.4 Zufallsvektoren: Gemeinsame und Randverteilungen . . . 18
1.1.5 Erwartungswert, Varianz und Kovarianz . . . 18
1.1.6 Die Tschebyscheff-Ungleichung . . . 19
1.1.7 Familien diskreter Verteilungen . . . 19
1.1.8 Poisson-Approximation der Binomialverteilung . . . 20
1.1.9 Übungsaufgaben zu Kapitel 2 . . . 24
1.1.10 Mathematische Herleitung . . . 24
1.1.11 R-Code & Simulation . . . 25
1.1.12 Mathematische Herleitung . . . 26
1.1.13 R-Code & Simulation . . . 26
1.1.14 Mathematische Herleitung . . . 27
1.1.15 R-Code & Simulation . . . 28
1.1.16 Mathematische Herleitung . . . 28
1.1.17 R-Code & Simulation . . . 29
1.1.18 Mathematische Herleitung . . . 29
1.1.19 R-Code & Simulation . . . 31
1.1.20 Mathematische Herleitung . . . 31
1.1.21 R-Code & Simulation . . . 31
1.2 Kapitel 3: Stetige Zufallsvariablen und der Zentrale Grenzwertsatz . . . 32
1.2.1 Wahrscheinlichkeitsdichte (PDF) und stetige cdf . . . 32
1.2.2 Momente stetiger Verteilungen . . . 33
1.2.3 Familien stetiger Verteilungen . . . 33
1.2.4 Der Zentrale Grenzwertsatz (ZGS) . . . 36
1.2.5 Normalapproximation der Binomialverteilung und Stetigkeitskorrektur . . . 41
1.2.6 Übungsaufgaben zu Kapitel 3 . . . 42
1.2.7 Mathematische Herleitung . . . 43
1.2.8 R-Code & Simulation . . . 43
1.2.9 Mathematische Herleitung . . . 44
1.2.10 R-Code & Simulation . . . 44
1.2.11 Mathematische Herleitung . . . 45
1.2.12 R-Code & Simulation . . . 45
1.2.13 Mathematische Herleitung . . . 46
1.2.14 R-Code & Simulation . . . 47
1.2.15 Mathematische Herleitung . . . 47
1.2.16 R-Code & Simulation . . . 48
1.2.17 Mathematische Herleitung . . . 48
1.2.18 R-Code & Simulation . . . 49
1.2.19 Mathematische Herleitung . . . 49
1.2.20 R-Code & Simulation . . . 49

1.2.21 Mathematische Herleitung 50
1.2.22 R-Code & Simulation 51
1.2.23 Mathematische Herleitung 51
1.2.24 R-Code & Simulation 51
1.2.25 Mathematische Herleitung 52
1.2.26 R-Code & Simulation 52
1.3 Zusammenfassung: Verteilungs-Spickzettel 53
1.3.1 Diskrete Verteilungen (Support $\mathcal{X}$ diskret) 53
1.3.2 Stetige Verteilungen (Support $\mathcal{X}$ stetig) 55

1 Vorlesung 02-01: Grundlagen der Wahrscheinlichkeitsrechnung

Wahrscheinlichkeit wird im Alltag oft intuitiv als die Chance verstanden, dass ein bestimmtes Ereignis eintritt. Mathematisch wird diese Theorie formal über den Begriff des Zufallsexperiments, der Ergebnismenge und der Ereignisse aufgebaut.

1.0.1 Ergebnismenge und Ereignisse

> **i** Definitionen
>
> 1. **Ergebnismenge (Sample Space)** Ω: Die Menge aller Elementarergebnisse eines Zufallsexperiments.
> 2. **Ereignis (Event)**: Jede Teilmenge des Ergebnisraums Ω. Ein Ereignis ist somit eine Sammlung von Elementarergebnissen.

Wenn wir eine faire Münze werfen, haben wir zwei mögliche Ergebnisse: Kopf (H) oder Zahl (T). Der Ergebnisraum ist $\Omega = \{H, T\}$. Ein Würfelwurf liefert sechs mögliche Ergebnisse: $\Omega = \{1, 2, 3, 4, 5, 6\}$. Ein Ereignis könnte das Beobachten einer geraden Augenzahl sein: $A = \{2, 4, 6\}$.

Wenn eine Ergebnismenge aus N möglichen Ergebnissen besteht, gibt es insgesamt 2^N mögliche Ereignisse. Dies lässt sich dadurch beweisen, dass jedes Ergebnis bei der Bildung eines Ereignisses entweder ein- oder ausgeschlossen werden kann ($2 \cdot 2 \cdot \cdots \cdot 2 = 2^N$ Möglichkeiten).

1.0.2 Mengenoperationen

Da Ereignisse Mengen sind, nutzen wir klassische Mengenoperationen, um neue Ereignisse zu definieren:

- **Vereinigung ($A \cup B$)**: Tritt ein, wenn A *oder* B (oder beide) eintreten. Entspricht dem logischen "Oder".

- **Schnittmenge ($A \cap B$)**: Tritt ein, wenn sowohl A *als auch* B eintreten. Entspricht dem logischen "Und".
- **Komplement (A^c)**: Tritt ein, wenn A *nicht* eintritt. Es besteht aus allen Ergebnissen in Ω, die nicht in A liegen.
- **Differenz ($A \setminus B$)**: Tritt ein, wenn A eintritt, aber B *nicht*.

> **Definition: Disjunkte und ausschöpfende Ereignisse**
>
> - Zwei Ereignisse A und B sind **disjunkt** (mutually exclusive), wenn sie keine gemeinsamen Ergebnisse haben, d. h. $A \cap B = \emptyset$. Sie können nicht gleichzeitig eintreten.
> - Ereignisse $A, B, C, ...$ sind **ausschöpfend** (exhaustive), wenn ihre Vereinigung dem gesamten Ergebnisraum entspricht: $A \cup B \cup C \cup \cdots = \Omega$.

1.0.3 Die Axiome der Wahrscheinlichkeit

Wahrscheinlichkeit ist eine Funktion P, die jedem Ereignis E aus einer σ-Algebra $\mathcal{M}$ einen Wert im Intervall $[0, 1]$ zuordnet und die folgenden Axiome von Kolmogorov erfüllt:

1. **Normiertheit**: Das sichere Ereignis hat die Wahrscheinlichkeit 1:

$$P(\Omega) = 1$$

2. **σ-Additivität**: Für jede abzählbare Folge paarweise disjunkter Ereignisse $E_1, E_2, ...$ gilt:

$$P\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} P(E_i)$$

Aus diesen Axiomen lassen sich wichtige Sätze ableiten: * **Wahrscheinlichkeit der Vereinigung (Additionssatz)**:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Für disjunkte Ereignisse gilt vereinfacht: $P(A \cup B) = P(A) + P(B)$. * **Komplementärregel**:

$$P(A^c) = 1 - P(A)$$

* **Unmögliches Ereignis**: $P(\emptyset) = 0$.

1.0.4 Anwendungen in der Systemzuverlässigkeit

In der Zuverlässigkeitstheorie berechnen wir die Wahrscheinlichkeit, dass ein System aus mehreren Komponenten funktionsfähig bleibt.

1.0.4.1 Parallelschaltung (Redundanz)

Ein System aus parallel geschalteten, unabhängig voneinander ausfallenden Komponenten funktioniert, wenn *mindestens eine* Komponente arbeitet. Das System fällt nur aus, wenn alle Komponenten gleichzeitig ausfallen:

$$P(\text{System funktioniert}) = 1 - P(\text{alle fallen aus}) = 1 - \prod_{i=1}^{n} P(K_i \text{ fällt aus})$$

1.0.4.2 Reihenschaltung (Sequentiell)

Ein System aus sequentiell geschalteten Komponenten funktioniert nur, wenn *jede einzelne* Komponente funktioniert. Der Ausfall einer einzigen Komponente führt zum Systemausfall:

$$P(\text{System funktioniert}) = \prod_{i=1}^{n} P(K_i \text{ funktioniert})$$

1.0.5 Kombinatorik

Kombinatorische Methoden helfen uns, die Anzahl günstiger (N_F) und möglicher (N_T) Ergebnisse bei gleichwahrscheinlichen Ergebnissen (Laplace-Experimenten) zu bestimmen. Es gilt:

$$P(E) = \frac{\text{Anzahl günstige Ergebnisse}}{\text{Anzahl mögliche Ergebnisse}} = \frac{N_F}{N_T}$$

Wir unterscheiden das Ziehen mit oder ohne Zurücklegen sowie die Beachtung der Reihenfolge (unterscheidbar vs. ununterscheidbar):

1. **Permutationen mit Zurücklegen** (Reihenfolge wichtig, Ziehen mit Zurücklegen):

$$P_r(n,k) = n^k$$

2. **Permutationen ohne Zurücklegen** (Reihenfolge wichtig, Ziehen ohne Zurücklegen):

$$P(n,k) = \frac{n!}{(n-k)!}$$

3. **Kombinationen ohne Zurücklegen** (Reihenfolge egal, Ziehen ohne Zurücklegen):

$$C(n,k) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

4. **Kombinationen mit Zurücklegen** (Reihenfolge egal, Ziehen mit Zurücklegen):

$$C_r(n,k) = \binom{k+n-1}{k} = \frac{(k+n-1)!}{k!(n-1)!}$$

1.0.6 Bedingte Wahrscheinlichkeit und Unabhängigkeit

Bedingte Wahrscheinlichkeit

Die bedingte Wahrscheinlichkeit von A unter der Bedingung, dass B bereits eingetreten ist (mit $P(B) > 0$), ist definiert als:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

Daraus ergibt sich die allgemeine Multiplikationsregel für Schnittmengen:

$$P(A \cap B) = P(B) \cdot P(A \mid B) = P(A) \cdot P(B \mid A)$$

1.0.6.1 Unabhängigkeit von Ereignissen

Zwei Ereignisse A und B sind unabhängig, wenn das Eintreten von B die Wahrscheinlichkeit von A nicht beeinflusst:

$$P(A \mid B) = P(A) \iff P(A \cap B) = P(A) \cdot P(B)$$

1.0.7 Satz der totalen Wahrscheinlichkeit und Satz von Bayes

1.0.7.1 Satz der totalen Wahrscheinlichkeit

Sei $B_1, \ldots, B_k$ eine Partition des Ergebnisraums Ω (d. h. paarweise disjunkt und ausschöpfend). Dann gilt für jedes Ereignis A:

$$P(A) = \sum_{j=1}^{k} P(A \mid B_j) \cdot P(B_j)$$

1.0.7.2 Satz von Bayes

Unter den gleichen Voraussetzungen für B_j lässt sich die bedingte Wahrscheinlichkeit $P(B_i \mid A)$ berechnen als:

$$P(B_i \mid A) = \frac{P(A \mid B_i) \cdot P(B_i)}{P(A)} = \frac{P(A \mid B_i) \cdot P(B_i)}{\sum_{j=1}^{k} P(A \mid B_j) \cdot P(B_j)}$$

Diese Formel ist zentral bei Diagnose- und Testverfahren (z. B. medizinischen Screenings oder Computer-Code-Fehlertests), bei denen die Wahrscheinlichkeit für das Vorliegen einer Ursache (z. B. einer Infektion) gesucht wird, nachdem ein Symptom (z. B. ein positiver Test) beobachtet wurde.

1.0.8 Übungsaufgaben zu Kapitel 1

⚠ Übung 1.1 (Aufgabe 2.2 aus dem Lehrbuch)

Ein Computerhersteller weiß aus Erfahrung, dass nach 10 Jahren Betrieb 40% aller Rechner Probleme mit der Hauptplatine (MB) haben, 30% Probleme mit der Festplatte (HD) und 15% Probleme mit beiden Komponenten. Wie groß ist die Wahrscheinlichkeit, dass ein 10 Jahre alter Computer noch voll funktionsfähig ist (d. h. weder MB- noch HD-Probleme aufweist)?

1.0.9 Mathematische Herleitung

Definieren wir die Ereignisse: * M: Rechner hat ein Hauptplatinen-Problem (MB). $P(M) = 0{,}40$ * H: Rechner hat ein Festplatten-Problem (HD). $P(H) = 0{,}30$ * Schnittmenge $M \cap H$: Probleme mit beiden Komponenten. $P(M \cap H) = 0{,}15$
Ein voll funktionsfähiger Rechner hat weder MB- noch HD-Probleme, was dem Ereignis $M^c \cap H^c$ entspricht. Nach De Morgans Regel ist $M^c \cap H^c = (M \cup H)^c$.

1. Berechnen wir die Wahrscheinlichkeit, dass *mindestens ein* Problem auftritt ($P(M \cup H)$):

$$P(M \cup H) = P(M) + P(H) - P(M \cap H) = 0{,}40 + 0{,}30 - 0{,}15 = 0{,}55$$

2. Die Wahrscheinlichkeit, dass der Rechner voll funktionsfähig ist, beträgt:

$$P((M \cup H)^c) = 1 - P(M \cup H) = 1 - 0{,}55 = 0{,}45$$

Die Wahrscheinlichkeit beträgt somit 0,45 (oder 45%).

1.0.10 R-Code & Simulation

```
set.seed(42)
N <- 100000
# MB-Problem mit P(M) = 0.40, HD-Problem mit P(H) = 0.30, beide mit P(M & H) = 0.15
# Wir bilden die gemeinsame Verteilung ab:
# P(weder noch) = 0.45, P(nur MB) = 0.25, P(nur HD) = 0.15, P(beide) = 0.15
probs <- c(0.45, 0.25, 0.15, 0.15)
states <- sample(c("gut", "nur_MB", "nur_HD", "beide"), size = N, replace = TRUE, prob = pr

# Anteil voll funktionsfähiger Computer (weder MB- noch HD-Probleme)
mean(states == "gut")
#> [1] 0.44764
```

⚠ Übung 1.2 (Aufgabe 2.3 aus dem Lehrbuch)

Ein neuer Computervirus kann über E-Mail oder das Internet in ein System eindringen. Die Wahrscheinlichkeit für ein Eindringen über E-Mail beträgt 30%, über das Internet 40%. Gleichzeitig über beide Wege dringt der Virus mit einer Wahrscheinlichkeit von 15% ein. Wie groß ist die Wahrscheinlichkeit, dass der Virus überhaupt nicht in das System eindringt?

1.0.11 Mathematische Herleitung

Definieren wir: * E: Virus dringt über E-Mail ein. $P(E) = 0{,}30$ * I: Virus dringt über das Internet ein. $P(I) = 0{,}40$ * $E \cap I$: Eindringen über beide Kanäle. $P(E \cap I) = 0{,}15$
Der Virus dringt über mindestens einen Kanal ein mit der Wahrscheinlichkeit:

$$P(E \cup I) = P(E) + P(I) - P(E \cap I) = 0{,}30 + 0{,}40 - 0{,}15 = 0{,}55$$

Die Wahrscheinlichkeit, dass das System virusfrei bleibt ($P((E \cup I)^c)$), ist:

$$P((E \cup I)^c) = 1 - P(E \cup I) = 1 - 0{,}55 = 0{,}45$$

Die Wahrscheinlichkeit beträgt somit 0,45 (oder 45%).

1.0.12 R-Code & Simulation

```
set.seed(42)
N <- 100000
# E-Mail (E): P(E) = 0.30, Internet (I): P(I) = 0.40, beide: P(E & I) = 0.15
# Gemeinsame Wahrscheinlichkeiten:
# P(virusfrei) = 0.45, P(nur Email) = 0.15, P(nur Internet) = 0.25, P(beide) = 0.15
probs <- c(0.45, 0.15, 0.25, 0.15)
states <- sample(c("frei", "email", "internet", "beide"), size = N, replace = TRUE, prob =

# Anteil der virusfreien Systeme
mean(states == "frei")
#> [1] 0.44764
```

⚠ Übung 1.3 (Aufgabe 2.5 aus dem Lehrbuch)

Ein Computerprogramm wird mit 3 unabhängigen Tests geprüft. Wenn ein Fehler vorliegt, entdecken diese Tests den Fehler mit Wahrscheinlichkeiten von 0,2, 0,3 und 0,5. Angenommen, das Programm enthält einen Fehler. Wie hoch ist die Wahrscheinlichkeit, dass dieser von mindestens einem der Tests entdeckt wird?

1.0.13 Mathematische Herleitung

Seien T_1, T_2, T_3 die Ereignisse, dass Test 1, 2 oder 3 den Fehler entdecken. Da die Tests unabhängig sind, sind auch ihre Komplementärereignisse unabhängig. Gegeben sind: $P(T_1) = 0{,}2$, $P(T_2) = 0{,}3$ und $P(T_3) = 0{,}5$.
Die Wahrscheinlichkeit, dass *kein* Test den Fehler findet, ist:

$$P(T_1^c \cap T_2^c \cap T_3^c) = P(T_1^c) \cdot P(T_2^c) \cdot P(T_3^c) = (1-0{,}2) \cdot (1-0{,}3) \cdot (1-0{,}5) = 0{,}8 \cdot 0{,}7 \cdot 0{,}5 = 0{,}28$$

Die Wahrscheinlichkeit, dass *mindestens ein* Test den Fehler entdeckt, beträgt:

$$P(\text{Entdeckung}) = 1 - P(\text{keine Entdeckung}) = 1 - 0{,}28 = 0{,}72$$

Die Wahrscheinlichkeit beträgt somit 0,72 (oder 72%).

1.0.14 R-Code & Simulation

```
set.seed(42)
N <- 100000
# Drei unabhängige Tests mit Entdeckungswahrscheinlichkeiten 0.2, 0.3 und 0.5
t1 <- runif(N) < 0.2
t2 <- runif(N) < 0.3
t3 <- runif(N) < 0.5
entdeckt <- t1 | t2 | t3

# Wahrscheinlichkeit, dass mindestens ein Test den Fehler entdeckt
mean(entdeckt)
#> [1] 0.72328
```

⚠ Übung 1.4 (Aufgabe 2.8 aus dem Lehrbuch)

Der Start eines Space Shuttles hängt von drei kritischen Systemen ab, die unabhängig voneinander mit den Wahrscheinlichkeiten 0,01, 0,02 und 0,02 ausfallen können. Fällt eines dieser Systeme aus, wird der Start verschoben. Berechnen Sie die Wahrscheinlichkeit, dass das Shuttle planmäßig gestartet werden kann.

1.0.15 Mathematische Herleitung

Der Start ist erfolgreich, wenn *keines* der drei Systeme ausfällt. Sei F_1, F_2, F_3 der Ausfall von System 1, 2 und 3. $P(F_1) = 0{,}01$, $P(F_2) = 0{,}02$, $P(F_3) = 0{,}02$. Da die Ausfälle unabhängig sind, berechnet sich die Erfolgswahrscheinlichkeit wie folgt:

$$P(\text{Start auf Zeit}) = P(F_1^c \cap F_2^c \cap F_3^c) = P(F_1^c) \cdot P(F_2^c) \cdot P(F_3^c) = (1-0{,}01) \cdot (1-0{,}02) \cdot (1-0{,}02)$$

$$P(\text{Start auf Zeit}) = 0{,}99 \cdot 0{,}98 \cdot 0{,}98 = 0{,}950796$$

Die Wahrscheinlichkeit beträgt ca. 0,9508 (oder 95,08%).

1.0.16 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Drei kritische Systeme fallen unabhängig mit 0.01, 0.02, 0.02 aus
s1_fail <- runif(N) < 0.01
s2_fail <- runif(N) < 0.02
s3_fail <- runif(N) < 0.02
start_on_time <- !(s1_fail | s2_fail | s3_fail)

# Wahrscheinlichkeit für einen planmäßigen Start
mean(start_on_time)
#> [1] 0.95047
```

⚠ Übung 1.5 (Aufgabe 2.11 aus dem Lehrbuch)

Ein Computerprogramm wird mit 5 unabhängigen Tests auf Fehler überprüft. Ein eventuell vorhandener Fehler wird von den Tests mit den Wahrscheinlichkeiten 0,1, 0,2, 0,3, 0,4 und 0,5 entdeckt. Angenommen, das Programm enthält einen Fehler. Wie groß ist die Wahrscheinlichkeit, dass er gefunden wird: (a) durch mindestens einen Test? (b) durch mindestens zwei Tests? (c) durch alle fünf Tests?

1.0.17 Mathematische Herleitung

Wir haben die Entdeckungswahrscheinlichkeiten $p_1 = 0{,}1$, $p_2 = 0{,}2$, $p_3 = 0{,}3$, $p_4 = 0{,}4$, $p_5 = 0{,}5$. Sei X die Anzahl der Tests, die den Fehler finden.
(a) Mindestens ein Test ($X \geq 1$): Das Gegenereignis ist $X = 0$ (kein Test findet den Fehler):

$$P(X = 0) = (1-0{,}1)(1-0{,}2)(1-0{,}3)(1-0{,}4)(1-0{,}5) = 0{,}9 \cdot 0{,}8 \cdot 0{,}7 \cdot 0{,}6 \cdot 0{,}5 = 0{,}1512$$

$$P(X \geq 1) = 1 - P(X = 0) = 1 - 0{,}1512 = 0{,}8488$$

(b) Mindestens zwei Tests ($X \geq 2$):

$$P(X \geq 2) = 1 - P(X = 0) - P(X = 1)$$

Um $P(X = 1)$ zu berechnen, summieren wir die Wahrscheinlichkeiten, dass genau ein

Test den Fehler findet (während alle anderen versagen):

$$P(X = 1) = \sum_{i=1}^{5} p_i \prod_{j \neq i} (1 - p_j)$$

Da das Gesamtprodukt $\prod_{j=1}^{5}(1-p_j) = 0{,}1512$ ist, können wir jeden Summanden schreiben als $0{,}1512 \cdot \frac{p_i}{1-p_i}$: $* \; i = 1 : 0{,}1512 \cdot \frac{0{,}1}{0{,}9} = 0{,}0168 \; * \; i = 2 : 0{,}1512 \cdot \frac{0{,}2}{0{,}8} = 0{,}0378 \; * \; i = 3 : 0{,}1512 \cdot \frac{0{,}3}{0{,}7} = 0{,}0648 \; * \; i = 4 : 0{,}1512 \cdot \frac{0{,}4}{0{,}6} = 0{,}1008 \; * \; i = 5 : 0{,}1512 \cdot \frac{0{,}5}{0{,}5} = 0{,}1512$ Summe $P(X = 1) = 0{,}0168 + 0{,}0378 + 0{,}0648 + 0{,}1008 + 0{,}1512 = 0{,}3714$.

$$P(X \geq 2) = 1 - 0{,}1512 - 0{,}3714 = 0{,}4774$$

(c) Alle fünf Tests ($X = 5$): Da die Tests unabhängig sind, multiplizieren wir einfach die Einzelwahrscheinlichkeiten:

$$P(X = 5) = 0{,}1 \cdot 0{,}2 \cdot 0{,}3 \cdot 0{,}4 \cdot 0{,}5 = 0{,}0012$$

1.0.18 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# 5 unabhängige Tests mit Entdeckungswahrscheinlichkeiten 0.1, 0.2, 0.3, 0.4, 0.5
p <- c(0.1, 0.2, 0.3, 0.4, 0.5)
tests <- matrix(FALSE, nrow = 5, ncol = N)
for(i in 1:5) {
  tests[i, ] <- runif(N) < p[i]
}
anzahl_entdeckt <- colSums(tests)

# (a) durch mindestens einen Test
print(paste("(a) Mindestens ein Test:", round(mean(anzahl_entdeckt >= 1), 4)))
#> [1] "(a) Mindestens ein Test: 0.848"
# (b) durch mindestens zwei Tests
print(paste("(b) Mindestens zwei Tests:", round(mean(anzahl_entdeckt >= 2), 4)))
#> [1] "(b) Mindestens zwei Tests: 0.4772"
# (c) durch alle fünf Tests
print(paste("(c) Alle fünf Tests:", round(mean(anzahl_entdeckt == 5), 4)))
#> [1] "(c) Alle fünf Tests: 0.0012"
```

⚠ Übung 1.6 (Aufgabe 2.15 aus dem Lehrbuch)

Ein Computerprogramm besteht aus zwei Blöcken, die unabhängig voneinander von zwei Programmierern geschrieben wurden. Der erste Block enthält mit Wahrscheinlichkeit 0,2 einen Fehler, der zweite Block mit Wahrscheinlichkeit 0,3. Wenn das Programm bei der Ausführung einen Fehler zurückgibt (was passiert, sobald mindestens ein Block fehlerhaft ist), wie groß ist die Wahrscheinlichkeit, dass in *beiden* Blöcken ein Fehler vorliegt?

1.0.19 Mathematische Herleitung

Wir definieren: * B_1: Fehler im ersten Block. $P(B_1) = 0{,}2$ * B_2: Fehler im zweiten Block. $P(B_2) = 0{,}3$ * E: Programm gibt einen Fehler zurück ($B_1 \cup B_2$)
Da B_1 und B_2 unabhängig sind, gilt für das Fehlersignal des Programms:

$$P(E) = P(B_1 \cup B_2) = P(B_1) + P(B_2) - P(B_1)P(B_2) = 0{,}2 + 0{,}3 - (0{,}2 \cdot 0{,}3) = 0{,}44$$

Wir suchen die bedingte Wahrscheinlichkeit $P(B_1 \cap B_2 \mid E)$:

$$P(B_1 \cap B_2 \mid E) = \frac{P(B_1 \cap B_2 \cap E)}{P(E)} = \frac{P(B_1 \cap B_2)}{P(E)}$$

$$P(B_1 \cap B_2 \mid E) = \frac{0{,}2 \cdot 0{,}3}{0{,}44} = \frac{0{,}06}{0{,}44} = \frac{3}{22} \approx 0{,}1364$$

Die Wahrscheinlichkeit beträgt ca. 0,1364 (oder 13,64%).

1.0.20 R-Code & Simulation

```
set.seed(42)
N <- 100000
# Block 1 Fehler: 0.2, Block 2 Fehler: 0.3
b1 <- runif(N) < 0.2
b2 <- runif(N) < 0.3
programm_fehler <- b1 | b2

# Bedingte Wahrscheinlichkeit: Fehler in beiden Blöcken, gegeben Programmfehler
mean(b1[programm_fehler] & b2[programm_fehler])
#> [1] 0.1362273
```

⚠ Übung 1.7 (Aufgabe 2.18 aus dem Lehrbuch)

Eine Frage in einem Multiple-Choice-Test wird von einem vorbereiteten Studenten mit einer Wahrscheinlichkeit von 0,9 richtig beantwortet. Ein unvorbereiteter Student rät völlig

zufällig zwischen 4 Antwortmöglichkeiten (Wahrscheinlichkeit richtig zu raten: $1/4 = 0{,}25$). Angenommen, 75% der Studenten bereiten sich auf den Test vor. Wenn Herr X die Frage korrekt beantwortet, wie groß ist die Wahrscheinlichkeit, dass er sich *nicht* vorbereitet hatte?

1.0.21 Mathematische Herleitung

Wir definieren: * V: Student ist vorbereitet. $P(V) = 0{,}75 \implies P(V^c) = 0{,}25$ * R: Frage wird richtig beantwortet. * Gegebene bedingte Wahrscheinlichkeiten: $P(R \mid V) = 0{,}90$ und $P(R \mid V^c) = 0{,}25$.
Gesucht ist $P(V^c \mid R)$. Wir wenden den Satz von Bayes an: 1. Totale Wahrscheinlichkeit für eine richtige Antwort $P(R)$:

$$P(R) = P(R \mid V)P(V) + P(R \mid V^c)P(V^c) = 0{,}90 \cdot 0{,}75 + 0{,}25 \cdot 0{,}25 = 0{,}675 + 0{,}0625 = 0{,}7375$$

2. Bedingte Wahrscheinlichkeit $P(V^c \mid R)$:

$$P(V^c \mid R) = \frac{P(R \mid V^c)P(V^c)}{P(R)} = \frac{0{,}25 \cdot 0{,}25}{0{,}7375} = \frac{0{,}0625}{0{,}7375} = \frac{25}{295} = \frac{5}{59} \approx 0{,}0847$$

Die Wahrscheinlichkeit beträgt ca. 0,0847 (oder 8,47%).

1.0.22 R-Code & Simulation

```
set.seed(42)
N <- 100000
# 75% vorbereitet, 25% unvorbereitet
vorbereitet <- runif(N) < 0.75
richtig <- rep(FALSE, N)
richtig[vorbereitet] <- runif(sum(vorbereitet)) < 0.90
richtig[!vorbereitet] <- runif(sum(!vorbereitet)) < 0.25

# Bedingte Wahrscheinlichkeit: Nicht vorbereitet, gegeben richtig beantwortet
mean(!vorbereitet[richtig])
#> [1] 0.08630048
```

⚠ Übung 1.8 (Aufgabe 2.20 aus dem Lehrbuch)

Alle Athleten bei den Olympischen Spielen werden auf Steroidmissbrauch getestet. Der Test ist unvollkommen: Er liefert für 90% der echten Steroidnutzer ein positives Ergebnis, schlägt aber fälschlicherweise auch bei 2% der Nicht-Nutzer positiv an (Falsch-Positiv-Rate). Angenommen, 5% aller registrierten Athleten nutzen Steroide. Wenn ein Athlet

negativ getestet wird, wie groß ist die Wahrscheinlichkeit, dass er *dennoch* Steroide nutzt?

1.0.23 Mathematische Herleitung

Wir definieren: * D: Athlet nutzt Steroide (Doping). $P(D) = 0{,}05 \implies P(D^c) = 0{,}95$ * *pos*: Test fällt positiv aus. * *neg*: Test fällt negativ aus.
Gegeben ist: * Sensitivität: $P(pos \mid D) = 0{,}90 \implies P(neg \mid D) = 0{,}10$ (Falsch-Negativ-Rate) * Spezifität: $P(neg \mid D^c) = 0{,}98 \implies P(pos \mid D^c) = 0{,}02$ (Falsch-Positiv-Rate)
Wir suchen $P(D \mid neg)$: 1. Totale Wahrscheinlichkeit für ein negatives Testergebnis $P(neg)$:

$$P(neg) = P(neg \mid D)P(D) + P(neg \mid D^c)P(D^c) = 0{,}10 \cdot 0{,}05 + 0{,}98 \cdot 0{,}95 = 0{,}005 + 0{,}931 = 0{,}936$$

2. Bedingte Wahrscheinlichkeit $P(D \mid neg)$ mittels Bayes'scher Formel:

$$P(D \mid neg) = \frac{P(neg \mid D)P(D)}{P(neg)} = \frac{0{,}10 \cdot 0{,}05}{0{,}936} = \frac{0{,}005}{0{,}936} = \frac{5}{936} \approx 0{,}00534$$

Die Wahrscheinlichkeit beträgt ca. 0,0053 (oder 0,53%).

1.0.24 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# 5% nutzen Steroide, 95% nicht
steroid_user <- runif(N) < 0.05
test_positive <- rep(FALSE, N)
test_positive[steroid_user] <- runif(sum(steroid_user)) < 0.90
test_positive[!steroid_user] <- runif(sum(!steroid_user)) < 0.02
test_negative <- !test_positive

# Bedingte Wahrscheinlichkeit: Nutzt Steroide, gegeben negatives Testergebnis
mean(steroid_user[test_negative])
#> [1] 0.005131659
```

⚠ Übung 1.9 (Aufgabe 2.24 aus dem Lehrbuch)

Unter 10 Laptop-Computern sind fünf fehlerfrei und fünf defekt. Ein Kunde kauft ahnungslos 6 dieser Laptops. (a) Wie groß ist die Wahrscheinlichkeit, dass sich genau 2 defekte Laptops unter den gekauften befinden? (b) Angenommen, es befinden sich mindestens 2 defekte Laptops darunter. Wie groß ist die Wahrscheinlichkeit, dass es *genau* 2 sind?

1.0.25 Mathematische Herleitung

Das Ziehen erfolgt ohne Zurücklegen. Sei X die Anzahl defekter Laptops unter den 6 gekauften. X folgt einer hypergeometrischen Verteilung mit $N = 10$ (Gesamtzahl), $M = 5$ (Anzahl defekter in Grundgesamtheit) und $n = 6$ (Stichprobengröße).
(a) Genau 2 defekte Laptops ($X = 2$):

$$P(X = 2) = \frac{\binom{M}{2}\binom{N-M}{n-2}}{\binom{N}{n}} = \frac{\binom{5}{2}\binom{5}{4}}{\binom{10}{6}} = \frac{10 \cdot 5}{210} = \frac{50}{210} = \frac{5}{21} \approx 0{,}2381$$

(b) Genau 2 defekt unter der Bedingung, dass mindestens 2 defekt sind ($P(X = 2 \mid X \geq 2)$):

$$P(X = 2 \mid X \geq 2) = \frac{P(X = 2)}{P(X \geq 2)}$$

Wir bestimmen $P(X \geq 2) = 1 - P(X = 0) - P(X = 1)$. * $P(X = 0) = 0$, da wir 6 Laptops aus 10 wählen und es nur 5 fehlerfreie gibt (Schubfachprinzip). * $P(X = 1) = \frac{\binom{5}{1}\binom{5}{5}}{\binom{10}{6}} = \frac{5 \cdot 1}{210} = \frac{5}{210} = \frac{1}{42} \approx 0{,}0238$.
Damit ist:

$$P(X \geq 2) = 1 - 0 - \frac{5}{210} = \frac{205}{210}$$

Und die gesuchte bedingte Wahrscheinlichkeit:

$$P(X = 2 \mid X \geq 2) = \frac{50/210}{205/210} = \frac{50}{205} = \frac{10}{41} \approx 0{,}2439$$

Die Wahrscheinlichkeit beträgt ca. 0,2439 (oder 24,39%).

1.0.26 R-Code & Simulation

```
set.seed(42)
N <- 100000
# Ziehen ohne Zurücklegen aus 10 Laptops (5 defekt = 1, 5 fehlerfrei = 0)
urna <- c(rep(1, 5), rep(0, 5))
draws <- replicate(N, sum(sample(urna, size = 6, replace = FALSE)))

# (a) Genau 2 defekt
print(paste("(a) Genau 2 defekt:", round(mean(draws == 2), 4)))
#> [1] "(a) Genau 2 defekt: 0.2378"
# (b) Genau 2 defekt, gegeben mindestens 2 defekt
print(paste("(b) Genau 2 defekt, gegeben >= 2 defekt:", round(mean(draws[draws >= 2] == 2),
#> [1] "(b) Genau 2 defekt, gegeben >= 2 defekt: 0.2435"
```

1.1 Kapitel 2: Diskrete Zufallsvariablen

1.1.1 Das Konzept der Zufallsvariable

> **Definition: Zufallsvariable**
>
> Eine **Zufallsvariable** X ist eine reellwertige Funktion, die jedem Ergebnis ω des Stichprobenraums Ω eine reelle Zahl zuordnet:
>
> $$X = f(\omega)$$

Zufallsvariablen ermöglichen es uns, anstelle abstrakter Ergebnisse direkt mit numerischen Werten zu rechnen. Der Bereich aller Werte, die X annehmen kann, heißt **Träger** (Support) der Zufallsvariablen.

- **Diskrete Zufallsvariablen**: Nehmen endlich viele oder abzählbar unendlich viele isolierte Werte an (z. B. Anzahl der Fehler, Anzahl der Köpfe).
- **Stetige Zufallsvariablen**: Nehmen Werte in einem kontinuierlichen reellen Intervall an (z. B. Wartezeiten, Dateigröße).

1.1.2 Wahrscheinlichkeitsfunktion (PMF) und Verteilungsfunktion (CDF)

Für diskrete Zufallsvariablen beschreiben wir das Verhalten durch: 1. **Wahrscheinlichkeitsfunktion (Probability Mass Function, pmf)**:

$$P(x) = P(X = x)$$

Es gilt stets: $\sum_x P(x) = 1$. 2. **Kumulative Verteilungsfunktion (Cumulative Distribution Function, cdf)**:

$$F(x) = P(X \leq x) = \sum_{y \leq x} P(y)$$

$F(x)$ ist monoton nicht fallend, rechtsseitig stetig und es gilt $\lim_{x \to -\infty} F(x) = 0$ sowie $\lim_{x \to \infty} F(x) = 1$.

1.1.3 R-Simulation: Drei Münzwürfe

Wir können ein Zufallsexperiment, wie den dreifachen Münzwurf und das Zählen der Köpfe, mittels Monte-Carlo-Simulationen in R simulieren:

R-Code: Münzwurfsimulation

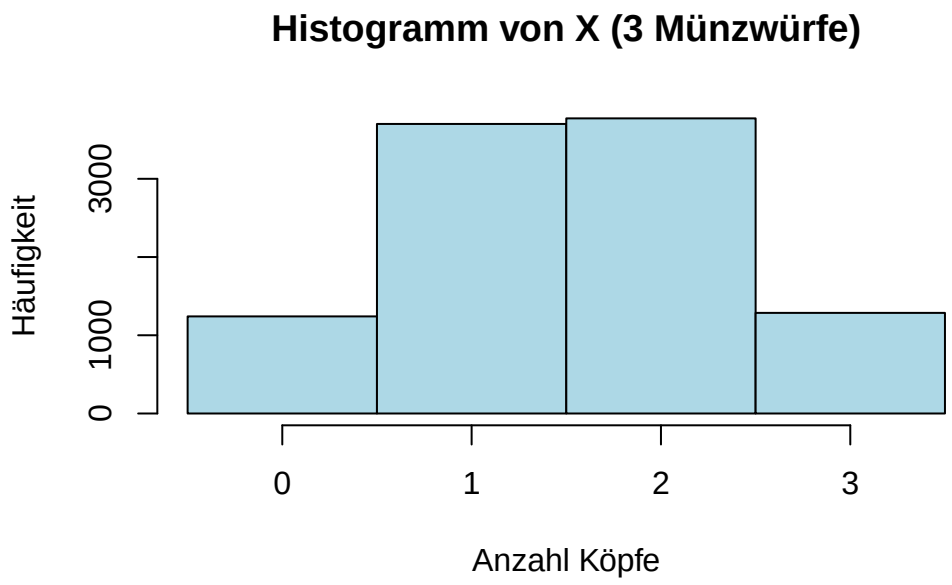
```r
N <- 10000 # Anzahl der Simulationen
# Generiere eine 3-by-N Matrix mit gleichverteilten Zufallszahlen aus [0, 1]
U <- matrix(runif(3 * N), 3, N)
# Y = 1 (Kopf), wenn U < 0.5, andernfalls Y = 0 (Zahl)
Y <- (U < 0.5)
# Spaltenweise Summation liefert X = Anzahl Köpfe (0 bis 3)
X <- colSums(Y)

# Ausgabe der relativen Häufigkeiten im Vergleich zur theoretischen PMF
table(X) / N
#> X
#>      0      1      2      3
#> 0.1241 0.3701 0.3772 0.1286
```

Wir können das Ergebnis auch als Histogramm visualisieren:

R-Code: Häufigkeitshistogramm

```r
hist(X, breaks = seq(-0.5, 3.5, 1), main = "Histogramm von X (3 Münzwürfe)",
     xlab = "Anzahl Köpfe", ylab = "Häufigkeit", col = "lightblue", border = "black")
```



1.1.4 Zufallsvektoren: Gemeinsame und Randverteilungen

Betrachten wir zwei Zufallsvariablen X und Y gleichzeitig, bilden sie einen **Zufallsvektor** (X, Y).

- **Gemeinsame Wahrscheinlichkeitsfunktion (Joint pmf)**:

$$P(x, y) = P(X = x \cap Y = y)$$

  Dabei gilt: $\sum_x \sum_y P(x, y) = 1$.
- **Randverteilungen (Marginal pmfs)** lassen sich über den Additionssatz aus der gemeinsamen Verteilung bestimmen:

$$P_X(x) = \sum_y P(x, y) \quad \text{und} \quad P_Y(y) = \sum_x P(x, y)$$

1.1.4.1 Unabhängigkeit von Zufallsvariablen

Zwei diskrete Zufallsvariablen X und Y sind unabhängig, wenn für alle x, y gilt:

$$P(x, y) = P_X(x) \cdot P_Y(y)$$

1.1.5 Erwartungswert, Varianz und Kovarianz

1.1.5.1 Erwartungswert (Expectation)

Der Erwartungswert ist der gewichtete Mittelwert aller möglichen Werte und repräsentiert physikalisch den Schwerpunkt (Center of Gravity) der Verteilung:

$$\mu = E(X) = \sum_x x \cdot P(x)$$

Eigenschaften des Erwartungswerts (für beliebige X, Y): * Linearität: $E(aX + bY + c) = aE(X) + bE(Y) + c$ * Multiplikativität bei Unabhängigkeit: $E(X \cdot Y) = E(X) \cdot E(Y)$

1.1.5.2 Varianz und Standardabweichung

Die Varianz misst die mittlere quadratische Abweichung vom Erwartungswert:

$$\sigma^2 = Var(X) = E\left[(X - E(X))^2\right] = \sum_x (x - \mu)^2 P(x)$$

Alternativer Rechenweg (Verschiebungssatz): $Var(X) = E(X^2) - (E(X))^2$.

Die **Standardabweichung** σ ist die Quadratwurzel der Varianz und besitzt dieselbe Maßeinheit wie die Zufallsvariable selbst:

$$\sigma = Std(X) = \sqrt{Var(X)}$$

Eigenschaften der Varianz: * $Var(aX + b) = a^2 Var(X)$ * Für unabhängige X, Y gilt: $Var(X + Y) = Var(X) + Var(Y)$.

1.1.5.3 Kovarianz und Korrelationskoeffizient

Die Kovarianz beschreibt den linearen Zusammenhang zwischen zwei Zufallsvariablen:

$$Cov(X, Y) = E\left[(X - E(X))(Y - E(Y))\right] = E(XY) - E(X)E(Y)$$

* $Cov(X, Y) > 0$: positive Korrelation (große Werte von X neigen dazu, mit großen Werten von Y aufzutreten). * $Cov(X, Y) < 0$: negative Korrelation. * $Cov(X, Y) = 0$: Unkorreliertheit (unabhängige Variablen sind immer unkorreliert, aber die Umkehrung gilt nicht zwingend!).

Der dimensionslose **Korrelationskoeffizient** ρ normiert die Kovarianz auf das Intervall $[-1, 1]$:

$$\rho = \frac{Cov(X, Y)}{Std(X) \cdot Std(Y)}$$

Ein Wert von $|\rho| = 1$ impliziert einen perfekten linearen Zusammenhang.

1.1.6 Die Tschebyscheff-Ungleichung

Die Tschebyscheff-Ungleichung liefert für jede beliebige Verteilung mit bekanntem Erwartungswert μ und Varianz σ^2 eine Schranke für die Wahrscheinlichkeit großer Abweichungen:

$$P(|X - \mu| \geq \epsilon) \leq \left(\frac{\sigma}{\epsilon}\right)^2$$

Sie zeigt, dass das Risiko extremer Werte direkt durch die Varianz kontrolliert wird.

1.1.7 Familien diskreter Verteilungen

1.1.7.1 1. Bernoulli-Verteilung

Ein einzelnes Experiment mit nur zwei möglichen Ergebnissen ("Erfolg" und "Misserfolg"). * Träger: $\{0, 1\}$ * Parameter: p (Erfolgswahrscheinlichkeit), $q = 1 - p$ * PMF: $P(1) = p, \quad P(0) = q$ * Erwartungswert und Varianz:

$$E(X) = p, \quad Var(X) = pq$$

1.1.7.2 2. Binomialverteilung

Die Anzahl der Erfolge in einer Reihe von n unabhängigen Bernoulli-Versuchen mit konstanter Erfolgswahrscheinlichkeit p. * Träger: $\{0, 1, \dots, n\}$ * PMF: $P(x) = \binom{n}{x} p^x q^{n-x}$ * Erwartungswert und Varianz:

$$E(X) = np, \quad Var(X) = npq$$

In R berechnet man: * PMF $P(X = x)$: `dbinom(x, n, p)` * CDF $P(X \leq x)$: `pbinom(x, n, p)`

1.1.7.3 3. Geometrische Verteilung

Die Anzahl der Bernoulli-Versuche *bis zum ersten Erfolg*. * Träger: $\{1, 2, 3, \dots\}$ (unbeschränkt) * PMF: $P(x) = q^{x-1}p$ (da $x - 1$ Misserfolge und am Ende ein Erfolg eintreten müssen) * Erwartungswert und Varianz:

$$E(X) = \frac{1}{p}, \quad Var(X) = \frac{q}{p^2}$$

1.1.7.4 4. Negative Binomialverteilung

Die Anzahl der unabhängigen Bernoulli-Versuche, die benötigt werden, um genau k Erfolge zu erzielen. Sie stellt eine Verallgemeinerung der geometrischen Verteilung dar ($k = 1$). * Träger: $\{k, k + 1, k + 2, \dots\}$ * PMF: $P(x) = \binom{x-1}{k-1} q^{x-k} p^k$ * Erwartungswert und Varianz:

$$E(X) = \frac{k}{p}, \quad Var(X) = \frac{kq}{p^2}$$

1.1.7.5 5. Poisson-Verteilung

Wird für die Modellierung der Anzahl seltener Ereignisse in einem festen Zeit- oder Raumbereich verwendet (z. B. Systemabstürze, Serveranfragen, Virusangriffe). * Träger: $\{0, 1, 2, \dots\}$ * Parameter: λ (mittlere Rate / Häufigkeit) * PMF: $P(x) = e^{-\lambda} \frac{\lambda^x}{x!}$ * Erwartungswert und Varianz:

$$E(X) = \lambda, \quad Var(X) = \lambda$$

1.1.8 Poisson-Approximation der Binomialverteilung

Wenn die Anzahl der Versuche n sehr groß und die Erfolgswahrscheinlichkeit p sehr klein ist, konvergiert die Binomialverteilung gegen die Poisson-Verteilung mit $\lambda = n \cdot p$. Als Faustregel gilt diese Approximation für $n \geq 30$ und $p \leq 0{,}05$ als sehr präzise.

1.1.8.0.1 Interaktive Gegenüberstellung: Binomial vs. Poisson

Um die Qualität der Poisson-Approximation visuell zu überprüfen, können wir die Wahrscheinlichkeitsfunktionen der Binomialverteilung und der zugehörigen Poisson-Verteilung ($\lambda = n \cdot p$) für eine Stichprobe von $n = 50$ und $p = 0{,}06$ ($\lambda = 3$) direkt vergleichen:

R-Code: Interaktiver Vergleich (Binomial vs. Poisson)

```r
library(ggplot2)
library(plotly)

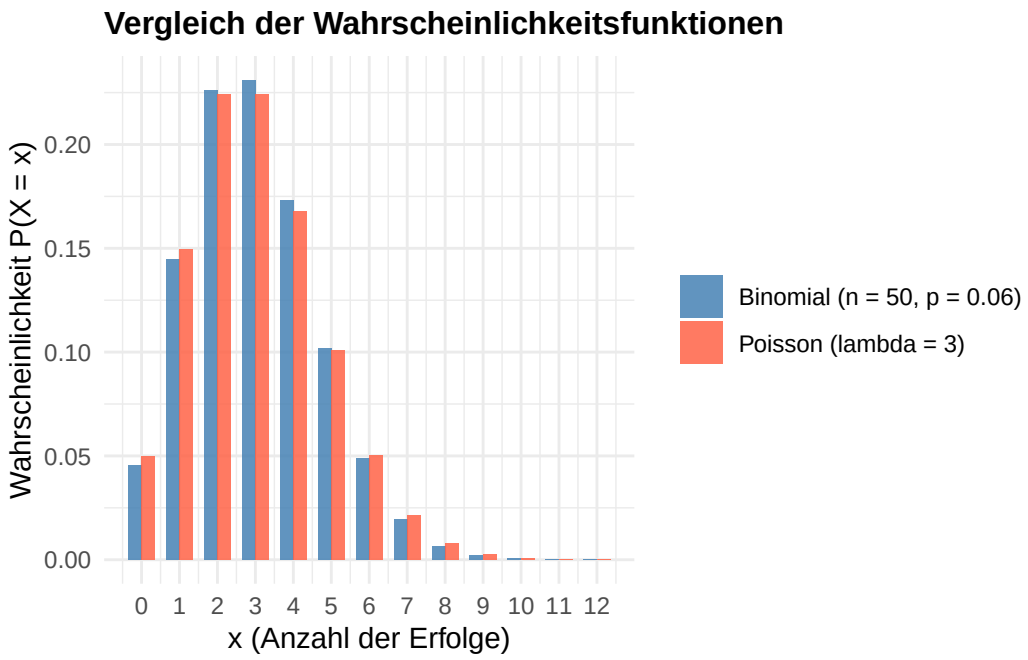
# Parameter definieren
n <- 50
p <- 0.06
lambda <- n * p  # lambda = 3

# Träger der Verteilung definieren (für die Visualisierung relevante Werte)
x_vals <- 0:12

# Daten für beide Verteilungen erstellen
df_approx <- data.frame(
  x = rep(x_vals, 2),
  Wahrscheinlichkeit = c(
    dbinom(x_vals, size = n, prob = p),
    dpois(x_vals, lambda = lambda)
  ),
  Verteilung = rep(
    c(paste0("Binomial (n = ", n, ", p = ", p, ")"), paste0("Poisson (lambda = ", lambda, '
    each = length(x_vals)
  )
)

# ggplot2-Säulendiagramm (position = "dodge" stellt Säulen nebeneinander)
p_approx <- ggplot(df_approx, aes(x = x, y = Wahrscheinlichkeit, fill = Verteilung)) +
  geom_col(position = "dodge", alpha = 0.85, width = 0.7) +
  scale_x_continuous(breaks = x_vals) +
  scale_fill_manual(values = c("#4682B4", "#FF6347")) + # Blau für Binomial, Tomatenrot fü
  labs(
    title = "Vergleich der Wahrscheinlichkeitsfunktionen",
    x = "x (Anzahl der Erfolge)",
    y = "Wahrscheinlichkeit P(X = x)"
  ) +
  theme_minimal() +
  theme(
    legend.title = element_blank(),
    plot.title = element_text(face = "bold", size = 12)
  )

# In plotly konvertieren für Interaktivität
interaktiv(p_approx)
```



Diese interaktive Grafik veranschaulicht eindrucksvoll, wie exzellent die Annäherung selbst bei einem moderaten n von 50 und einer Erfolgswahrscheinlichkeit von 6% bereits ist.

1.1.9 Übungsaufgaben zu Kapitel 2

⚠ Übung 2.1 (Aufgabe 3.1 aus dem Lehrbuch)

Ein Computervirus versucht, zwei unabhängige Dateien zu beschädigen. Die erste Datei wird mit einer Wahrscheinlichkeit von 0,4 beschädigt, die zweite mit einer Wahrscheinlichkeit von 0,3. (a) Bestimmen Sie die Wahrscheinlichkeitsfunktion (pmf) der Zufallsvariable X, welche die Anzahl beschädigter Dateien angibt. (b) Skizzieren Sie die kumulative Verteilungsfunktion (cdf) von X.

1.1.10 Mathematische Herleitung

Seien F_1, F_2 die Beschädigungen der Dateien 1 und 2. Sie sind unabhängig mit $P(F_1) = 0{,}4$ und $P(F_2) = 0{,}3$. Die Zufallsvariable X kann die Werte $\{0, 1, 2\}$ annehmen.
(a) Wahrscheinlichkeitsfunktion (pmf): * $X = 0$ **(keine Datei beschädigt):**

$$P(X = 0) = P(F_1^c \cap F_2^c) = (1 - 0{,}4)(1 - 0{,}3) = 0{,}6 \cdot 0{,}7 = 0{,}42$$

* $X = 1$ **(genau eine Datei beschädigt):**

$$P(X = 1) = P(F_1 \cap F_2^c) + P(F_1^c \cap F_2) = (0{,}4 \cdot 0{,}7) + (0{,}6 \cdot 0{,}3) = 0{,}28 + 0{,}18 = 0{,}46$$

* $X = 2$ **(beide Dateien beschädigt):**

$$P(X = 2) = P(F_1 \cap F_2) = 0{,}4 \cdot 0{,}3 = 0{,}12$$

Die pmf von X lautet:

x	0	1	2
$P(X = x)$	0,42	0,46	0,12

(Kontrollsumme: $0{,}42 + 0{,}46 + 0{,}12 = 1{,}00$)
(b) Kumulative Verteilungsfunktion (cdf): Die Verteilungsfunktion $F(x) = P(X \leq x)$ ist eine Treppenfunktion:

$$F(x) = \begin{cases} 0 & \text{für } x < 0 \\ 0{,}42 & \text{für } 0 \leq x < 1 \\ 0{,}88 & \text{für } 1 \leq x < 2 \\ 1{,}00 & \text{für } x \geq 2 \end{cases}$$

1.1.11 R-Code & Simulation

```
set.seed(42)
N <- 100000
f1 <- runif(N) < 0.4
f2 <- runif(N) < 0.3
X <- as.numeric(f1) + as.numeric(f2)

# Wahrscheinlichkeitsfunktion (pmf) als relative Häufigkeiten
table(X) / N
#> X
#>       0       1       2
#> 0.41936 0.46082 0.11982
```

⚠ Übung 2.2 (Aufgabe 3.5 aus dem Lehrbuch)

Ein Softwarepaket besteht aus 12 Programmen, von denen fünf aktualisiert werden müssen. Vier Programme werden zufällig für Tests ausgewählt. (a) Wie groß ist die Wahrscheinlichkeit, dass mindestens zwei der getesteten Programme aktualisiert werden müssen? (b) Wie hoch ist die erwartete Anzahl der zu aktualisierenden Programme unter den vier ausgewählten?

1.1.12 Mathematische Herleitung

Wir haben eine hypergeometrische Verteilung vorliegen (Ziehen ohne Zurücklegen): * Grundgesamtheit $N = 12$ * Merkmalsausprägung (aktualisierungsbedürftig) $M = 5$ * Stichprobengröße $n = 4$ * Zufallsvariable X: Anzahl der ausgewählten Programme, die aktualisiert werden müssen.
(a) Mindestens zwei Programme müssen aktualisiert werden ($X \geq 2$):

$$P(X \geq 2) = 1 - P(X = 0) - P(X = 1)$$

$$P(X = 0) = \frac{\binom{5}{0}\binom{7}{4}}{\binom{12}{4}} = \frac{1 \cdot 35}{495} = \frac{35}{495} \approx 0{,}0707$$

$$P(X = 1) = \frac{\binom{5}{1}\binom{7}{3}}{\binom{12}{4}} = \frac{5 \cdot 35}{495} = \frac{175}{495} \approx 0{,}3535$$

$$P(X \geq 2) = 1 - \frac{35}{495} - \frac{175}{495} = \frac{285}{495} = \frac{19}{33} \approx 0{,}5758$$

Die Wahrscheinlichkeit beträgt ca. 0,5758 (oder 57,58%).
(b) Erwartete Anzahl ($E(X)$): Der Erwartungswert einer hypergeometrischen Verteilung ist gegeben durch:

$$E(X) = n \cdot \frac{M}{N} = 4 \cdot \frac{5}{12} = \frac{20}{12} = \frac{5}{3} \approx 1{,}667$$

Wir erwarten im Mittel ca. 1,67 Programme, die aktualisiert werden müssen.

1.1.13 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Hypergeometrische Verteilung (Stichprobe 4 aus 12, davon 5 defekt/Auffrischung)
draws <- rhyper(N, m = 5, n = 7, k = 4)

# (a) Mindestens 2 Programme müssen aktualisiert werden
print(paste("(a) Wahrscheinlichkeit mindestens 2:", round(mean(draws >= 2), 4)))
#> [1] "(a) Wahrscheinlichkeit mindestens 2: 0.5774"
# (b) Erwartete Anzahl
print(paste("(b) Erwartete Anzahl:", round(mean(draws), 4)))
#> [1] "(b) Erwartete Anzahl: 1.6697"
```

Übung 2.3 (Aufgabe 3.8 aus dem Lehrbuch)

Eine Computernutzerin versucht sich an ihr Passwort zu erinnern. Sie weiß, dass es eines von 4 möglichen Passwörtern ist. Sie probiert sie nacheinander aus (ohne Zurücklegen / Wiederholen), bis sie das richtige findet. Sei X die Anzahl fehlerhafter Passwörter, die sie ausprobiert, bevor sie das richtige eingibt. Bestimmen Sie den Erwartungswert $E(X)$ und die Varianz $Var(X)$.

1.1.14 Mathematische Herleitung

Da sie Passwörter ohne Wiederholung ausprobiert, ist die Position des richtigen Passworts im Suchpfad gleichverteilt über $\{1, 2, 3, 4\}$. * Wenn das richtige Passwort an 1. Stelle steht, ist $X = 0$ (0 falsche Versuche). * An 2. Stelle: $X = 1$ (1 falscher Versuch). * An 3. Stelle: $X = 2$ (2 falsche Versuche). * An 4. Stelle: $X = 3$ (3 falsche Versuche).
Jedes Szenario tritt mit einer Wahrscheinlichkeit von $1/4 = 0{,}25$ auf. Die pmf von X ist somit gleichverteilt auf dem Träger $\{0, 1, 2, 3\}$.

1. **Erwartungswert** $E(X)$:

$$E(X) = \sum_{x=0}^{3} x \cdot P(X = x) = 0 \cdot 0{,}25 + 1 \cdot 0{,}25 + 2 \cdot 0{,}25 + 3 \cdot 0{,}25 = \frac{1+2+3}{4} = 1{,}5$$

2. **Zweites Moment** $E(X^2)$:

$$E(X^2) = \sum_{x=0}^{3} x^2 \cdot P(X = x) = 0^2 \cdot 0{,}25 + 1^2 \cdot 0{,}25 + 2^2 \cdot 0{,}25 + 3^2 \cdot 0{,}25 = \frac{1+4+9}{4} = \frac{14}{4} = 3{,}5$$

3. **Varianz** $Var(X)$:

$$Var(X) = E(X^2) - (E(X))^2 = 3{,}5 - (1{,}5)^2 = 3{,}5 - 2{,}25 = 1{,}25$$

Der Erwartungswert beträgt 1,5 Fehlversuche und die Varianz liegt bei 1,25 Versuche^2.

1.1.15 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Gleichverteilte Position des richtigen Passworts (1 bis 4)
position <- sample(1:4, size = N, replace = TRUE)
X <- position - 1

# Erwartungswert und Varianz
print(paste("Erwartungswert E(X):", round(mean(X), 4)))
#> [1] "Erwartungswert E(X): 1.4964"
print(paste("Varianz Var(X):", round(var(X) * (N-1)/N, 4)))
#> [1] "Varianz Var(X): 1.2512"
```

⚠ Übung 2.4 (Aufgabe 3.14 aus dem Lehrbuch)

Ein Internetdienstanbieter rechnet die Verbindungszeit seiner Kunden auf die nächste volle Stunde aufgerundet ab. Die gemeinsame Verteilung der genutzten Zeit (X in Stunden) und der Gebühr pro Stunde (Y in Cent) ist durch folgende Tabelle gegeben:

	$x=1$	$x=2$	$x=3$	$x=4$
$y=1$	0	0,06	0,06	0,10
$y=2$	0,10	0,10	0,04	0,04
$y=3$	0,40	0,10	0	0

Jedem Kunden wird der Gesamtbetrag $Z = X \cdot Y$ Cent in Rechnung gestellt. Bestimmen Sie die Wahrscheinlichkeitsfunktion (pmf) der Zufallsvariablen Z.

1.1.16 Mathematische Herleitung

Wir berechnen für jedes Feld der Tabelle mit einer Wahrscheinlichkeit $P(x,y) > 0$ den Wert $z = x \cdot y$: 1. $x=1, y=2 \implies z=2 \quad (P=0{,}10)$ 2. $x=1, y=3 \implies z=3 \quad (P=0{,}40)$ 3. $x=2, y=1 \implies z=2 \quad (P=0{,}06)$ 4. $x=2, y=2 \implies z=4 \quad (P=0{,}10)$ 5. $x=2, y=3 \implies z=6 \quad (P=0{,}10)$ 6. $x=3, y=1 \implies z=3 \quad (P=0{,}06)$ 7. $x=3, y=2 \implies z=6 \quad (P=0{,}04)$ 8. $x=4, y=1 \implies z=4 \quad (P=0{,}10)$ 9. $x=4, y=2 \implies z=8 \quad (P=0{,}04)$
Nun fassen wir gleiche Werte von z zusammen: * $Z=2$: $P(X=1,Y=2)+P(X=2,Y=1) = 0{,}10+0{,}06 = 0{,}16$ * $Z=3$: $P(X=1,Y=3)+P(X=3,Y=1) = 0{,}40+0{,}06 = 0{,}46$ * $Z=4$: $P(X=2,Y=2)+P(X=4,Y=1) = 0{,}10+0{,}10 = 0{,}20$ * $Z=6$: $P(X=2,Y=3)+P(X=3,Y=2) = 0{,}10+0{,}04 = 0{,}14$ * $Z=8$: $P(X=4,Y=2) = 0{,}04$

Die Wahrscheinlichkeitsfunktion von Z lautet:

z	2	3	4	6	8
$P(Z = z)$	0,16	0,46	0,20	0,14	0,04

(Kontrollsumme: $0{,}16 + 0{,}46 + 0{,}20 + 0{,}14 + 0{,}04 = 1{,}00$. Stimmt!)

1.1.17 R-Code & Simulation

```
set.seed(42)
N <- 100000
grid <- expand.grid(x = 1:4, y = 1:3)
probs <- c(
  0,    0.06, 0.06, 0.10, # y = 1
  0.10, 0.10, 0.04, 0.04, # y = 2
  0.40, 0.10, 0,    0     # y = 3
)
indices <- sample(1:12, size = N, replace = TRUE, prob = probs)
Z_sim <- grid$x[indices] * grid$y[indices]

# Wahrscheinlichkeitsfunktion von Z
table(Z_sim) / N
#> Z_sim
#>       2       3       4       6       8
#> 0.15975 0.46015 0.20051 0.13900 0.04059
```

⚠ Übung 2.5 (Aufgabe 3.26 aus dem Lehrbuch)

Nachdem ein Computervirus das Netzwerk infiziert hat, prüft eine IT-Managerin den Zustand wichtiger Dateien. Sie weiß, dass jede Datei unabhängig von den anderen mit einer Wahrscheinlichkeit von 0,2 beschädigt wurde. (a) Berechnen Sie die Wahrscheinlichkeit, dass mindestens 5 der ersten 20 geprüften Dateien beschädigt sind. (b) Berechnen Sie die Wahrscheinlichkeit, dass die Managerin mindestens 6 Dateien prüfen muss, um 3 unbeschädigte Dateien zu finden.

1.1.18 Mathematische Herleitung

(a) Mindestens 5 von 20 beschädigt: Die Anzahl der beschädigten Dateien X unter den $n = 20$ folgt einer Binomialverteilung mit $p = 0{,}2$. Wir suchen $P(X \geq 5) = 1 - P(X \leq 4)$. In R lässt sich dies über `1 - pbinom(4, 20, 0.2)` berechnen. Analytisch bestimmen wir die Einzelwahrscheinlichkeiten: * $P(X = 0) = 0{,}8^{20} \approx 0{,}0115$ * $P(X = 1) = 20 \cdot 0{,}2 \cdot 0{,}8^{19} \approx 0{,}0576$ * $P(X = 2) = 190 \cdot 0{,}04 \cdot 0{,}8^{18} \approx 0{,}1369$ * $P(X = 3) = 1140 \cdot 0{,}008 \cdot 0{,}8^{17} \approx 0{,}2054$

* $P(X = 4) = 4845 \cdot 0{,}0016 \cdot 0{,}8^{16} \approx 0{,}2182$
Die kumulierte Wahrscheinlichkeit $P(X \leq 4) \approx 0{,}0115+0{,}0576+0{,}1369+0{,}2054+0{,}2182 = 0{,}6296$.

$$P(X \geq 5) = 1 - 0{,}6296 = 0{,}3704$$

Die Wahrscheinlichkeit beträgt ca. 0,3704 (oder 37,04%).
(b) Mindestens 6 Dateien prüfen, um 3 unbeschädigte zu finden: Ein Erfolg ist hier eine *unbeschädigte* Datei ($p_{erfolg} = 0{,}8$, da Beschädigung = 0,2). Wir suchen die Anzahl der Versuche Y, um $k = 3$ Erfolge zu haben. Y folgt einer negativen Binomialverteilung. Die Aussage "mindestens 6 Versuche benötigt" bedeutet das Gegenteil von "höchstens 5 Versuche reichen aus", d. h. $P(Y \geq 6) = 1 - P(Y \leq 5)$. Die minimal mögliche Anzahl an Versuchen ist 3. Wir berechnen somit $P(Y = 3) + P(Y = 4) + P(Y = 5)$: * $P(Y = 3)$: Die ersten 3 Versuche sind direkt erfolgreich.

$$P(Y = 3) = p^3 = 0{,}8^3 = 0{,}5120$$

* $P(Y = 4)$: Unter den ersten 3 Versuchen befinden sich genau 2 Erfolge und der 4. Versuch ist ebenfalls ein Erfolg.

$$P(Y = 4) = \binom{3}{2} p^2 q \cdot p = 3 \cdot 0{,}8^2 \cdot 0{,}2 \cdot 0{,}8 = 3 \cdot 0{,}8^3 \cdot 0{,}2 = 0{,}3072$$

* $P(Y = 5)$: Unter den ersten 4 Versuchen befinden sich genau 2 Erfolge und der 5. Versuch ist ebenfalls ein Erfolg.

$$P(Y = 5) = \binom{4}{2} p^2 q^2 \cdot p = 6 \cdot 0{,}8^2 \cdot 0{,}04 \cdot 0{,}8 = 6 \cdot 0{,}8^3 \cdot 0{,}04 = 0{,}12288$$

Damit ist:

$$P(Y \leq 5) = 0{,}5120 + 0{,}3072 + 0{,}12288 = 0{,}94208$$

$$P(Y \geq 6) = 1 - 0{,}94208 = 0{,}05792$$

Die Wahrscheinlichkeit beträgt ca. 0,0579 (oder 5,79%).

1.1.19 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# (a) Mindestens 5 von 20 beschädigt (Binomialverteilung, p = 0.2)
X <- rbinom(N, size = 20, prob = 0.2)
print(paste("(a) Mindestens 5 beschädigt:", round(mean(X >= 5), 4)))
#> [1] "(a) Mindestens 5 beschädigt: 0.3713"

# (b) Mindestens 6 Prüfungen für 3 unbeschädigte (p = 0.8)
misserfolge <- rnbinom(N, size = 3, prob = 0.8)
pruefungen <- misserfolge + 3
print(paste("(b) Mindestens 6 Prüfungen:", round(mean(pruefungen >= 6), 4)))
#> [1] "(b) Mindestens 6 Prüfungen: 0.0568"
```

⚠ Übung 2.6 (Aufgabe 3.37 aus dem Lehrbuch)

Ein interaktives System besteht aus 10 Terminals, die mit dem Zentralrechner verbunden sind. Zu jedem beliebigen Zeitpunkt ist jedes Terminal unabhängig von den anderen mit einer Wahrscheinlichkeit von 0,7 bereit, eine Nachricht zu senden. Finden Sie die Wahrscheinlichkeit, dass um genau 8 Uhr exakt 6 Terminals sendebereit sind.

1.1.20 Mathematische Herleitung

Sei X die Anzahl sendebereiter Terminals. Da die Terminals unabhängig arbeiten, ist X binomialverteilt mit $n = 10$ und $p = 0{,}7$. Wir suchen $P(X = 6)$:

$$P(X = 6) = \binom{10}{6} p^6 q^4 = 210 \cdot (0{,}7)^6 \cdot (0{,}3)^4$$

$$P(X = 6) = 210 \cdot 0{,}117649 \cdot 0{,}0081 = 0{,}2001209$$

Die Wahrscheinlichkeit beträgt ca. 0,2001 (oder 20,01%).

1.1.21 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Binomialverteilung n = 10, p = 0.7
X <- rbinom(N, size = 10, prob = 0.7)

# Anteil für exakt 6 sendebereit
mean(X == 6)
#> [1] 0.1996
```

1.2 Kapitel 3: Stetige Zufallsvariablen und der Zentrale Grenzwertsatz

1.2.1 Wahrscheinlichkeitsdichte (PDF) und stetige cdf

Im Gegensatz zu diskreten Variablen können stetige Zufallsvariablen jeden beliebigen reellen Wert innerhalb eines Intervalls annehmen. Da die Wahrscheinlichkeit für einen exakten Einzelwert bei einer stetigen Verteilung stets null beträgt ($P(X = x) = 0$), arbeiten wir hier mit einer Dichtefunktion:

Definition: Wahrscheinlichkeitsdichtefunktion (PDF)

Eine Funktion $f(x)$ ist eine Wahrscheinlichkeitsdichtefunktion (pdf) für eine stetige Zufallsvariable X, falls gilt: 1. $f(x) \geq 0$ für alle x. 2. Das Integral über die gesamte reelle Achse ist normiert:

$$\int_{-\infty}^{\infty} f(x)dx = 1$$

3. Die Wahrscheinlichkeit, dass X in ein Intervall $[a, b]$ fällt, entspricht der Fläche unter der Kurve:

$$P(a < X < b) = \int_{a}^{b} f(x)dx = F(b) - F(a)$$

Die kumulative Verteilungsfunktion (cdf) ist das Integral der Dichtefunktion von $-\infty$ bis x:

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)dt$$

Zudem gilt nach dem Hauptsatz der Differential- und Integralrechnung: $f(x) = F'(x)$.

1.2.2 Momente stetiger Verteilungen

Analog zum diskreten Fall ersetzen wir bei der Berechnung der statistischen Kennwerte Summen durch Integrale: * **Erwartungswert**:

$$\mu = E(X) = \int_{-\infty}^{\infty} x \cdot f(x)dx$$

* **Varianz**:

$$\sigma^2 = Var(X) = \int_{-\infty}^{\infty} (x-\mu)^2 f(x)dx = \int_{-\infty}^{\infty} x^2 f(x)dx - \mu^2$$

1.2.3 Familien stetiger Verteilungen

1.2.3.1 1. Stetige Gleichverteilung (Uniform)

Modelliert ein Szenario, bei dem jeder Wert in einem Intervall $[a, b]$ gleich wahrscheinlich ist. Die Dichte ist konstant: * PDF: $f(x) = \frac{1}{b-a}$ für $a < x < b$ * Erwartungswert und Varianz:

$$E(X) = \frac{a+b}{2}, \quad Var(X) = \frac{(b-a)^2}{12}$$

1.2.3.2 2. Exponentialverteilung

Wird klassischerweise für das Modellieren von Wartezeiten und der Lebensdauer von Hardwarekomponenten genutzt. * PDF: $f(x) = \lambda e^{-\lambda x}$ für $x > 0$ * CDF: $F(x) = 1 - e^{-\lambda x}$ * Erwartungswert und Varianz:

$$E(X) = \frac{1}{\lambda}, \quad Var(X) = \frac{1}{\lambda^2}$$

1.2.3.2.1 Gedächtnislosigkeit (Memoryless Property)

Die Exponentialverteilung ist die einzige stetige Verteilung, die "ihr Alter vergisst":

$$P(T > t + x \mid T > t) = P(T > x)$$

Wenn eine Komponente bereits t Stunden überlebt hat, ist die Wahrscheinlichkeit, dass sie weitere x Stunden überlebt, exakt so groß wie die Überlebenswahrscheinlichkeit einer fabrikneuen Komponente.

1.2.3.3 3. Gammaverteilung

Die Gammaverteilung modelliert die Summe von α unabhängigen, identisch exponentialverteilten Variablen mit Parameter λ. Sie eignet sich für die Gesamtdauer mehrstufiger Prozesse. * PDF: $f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$ für $x > 0$ * Erwartungswert und Varianz:

$$E(X) = \frac{\alpha}{\lambda}, \quad Var(X) = \frac{\alpha}{\lambda^2}$$

1.2.3.3.1 Gamma-Poisson-Formel

Für ganzzahlige Parameter α lässt sich die Berechnung der Gamma-Wahrscheinlichkeiten drastisch vereinfachen, indem man sie auf eine Poisson-Verteilung zurückführt:

$$P(T \leq t) = P(X \geq \alpha) \quad \text{wobei } X \sim \text{Poisson}(\lambda t)$$

Damit lässt sich die aufwendige mehrfache partielle Integration bei Gamma-Verteilungen vermeiden.

1.2.3.4 4. Normalverteilung (Gauß-Verteilung)

Die wichtigste Verteilung der Statistik aufgrund des Zentralen Grenzwertsatzes. Die Dichte bildet die berühmte symmetrische, glockenförmige Kurve: * PDF: $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ für $-\infty < x < \infty$ * Erwartungswert und Varianz: $E(X) = \mu$, $Var(X) = \sigma^2$.

1.2.3.4.1 Interaktive Visualisierung in R

Um zu verstehen, wie die Parameter μ (Lage) und σ (Streuung) die Form der Gauß-Kurve beeinflussen, können wir mit `ggplot2` und `plotly` eine interaktive Grafik direkt in Quarto einbetten:

R-Code: Interaktive Gauß-Kurven

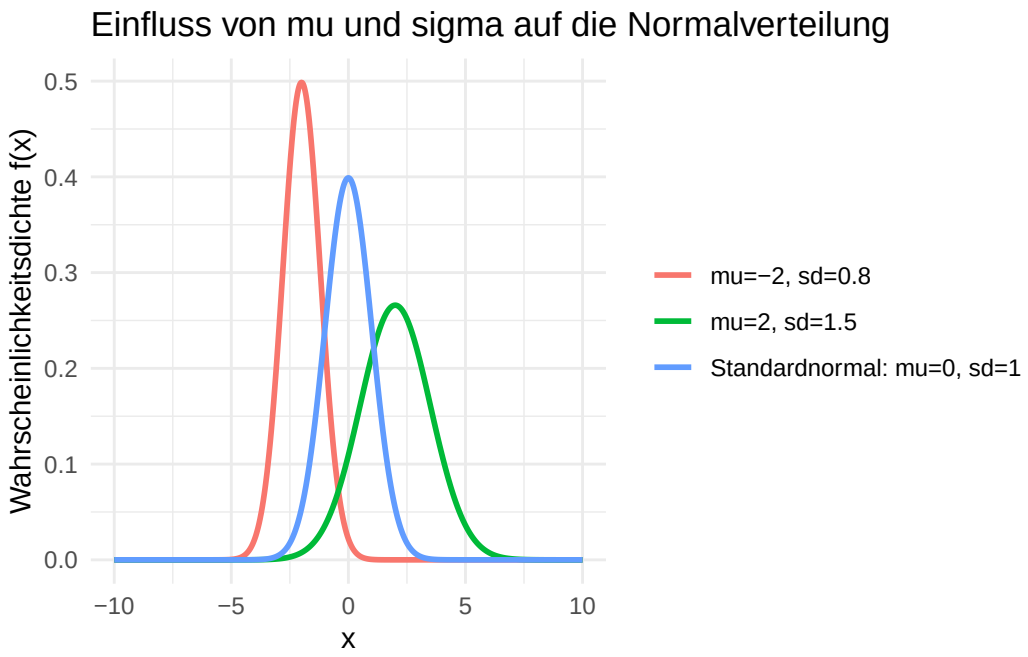
```r
library(ggplot2)
library(plotly)

# Wertebereich definieren
x_values <- seq(-10, 10, length.out = 1000)

# Daten für drei verschiedene Parameterkonfigurationen vorbereiten
df_normal <- data.frame(
  x = rep(x_values, 3),
  y = c(
    dnorm(x_values, mean = 0, sd = 1),
    dnorm(x_values, mean = 2, sd = 1.5),
    dnorm(x_values, mean = -2, sd = 0.8)
  ),
  Verteilung = rep(
    c("Standardnormal: mu=0, sd=1", "mu=2, sd=1.5", "mu=-2, sd=0.8"),
    each = 1000
  )
)

# ggplot2-Diagramm erstellen
p_normal <- ggplot(df_normal, aes(x = x, y = y, color = Verteilung)) +
  geom_line(linewidth = 1) +
  labs(
    title = "Einfluss von mu und sigma auf die Normalverteilung",
    x = "x",
    y = "Wahrscheinlichkeitsdichte f(x)"
  ) +
  theme_minimal() +
  theme(legend.title = element_blank())

# Plotly macht das Diagramm interaktiv (Hover-Effekt, Zoom etc.)
interaktiv(p_normal)
```



1.2.3.4.2 Standardisierung

Jede Normalverteilung $X \sim N(\mu, \sigma)$ kann durch das Abziehen des Mittelwerts und Teilen durch die Standardabweichung in eine Standardnormalverteilung $Z \sim N(0, 1)$ transformiert werden:

$$Z = \frac{X - \mu}{\sigma}$$

Wahrscheinlichkeiten werden dann über die Standard-Tabelle $\Phi(z)$ nachgeschlagen. Es gilt aufgrund der Symmetrie: $\Phi(-z) = 1 - \Phi(z)$.

1.2.4 Der Zentrale Grenzwertsatz (ZGS)

Satz 1: Zentraler Grenzwertsatz (Central Limit Theorem)

Seien $X_1, X_2, \ldots, X_n$ unabhängige, identisch verteilte (i.i.d.) Zufallsvariablen mit demselben Erwartungswert μ und derselben Standardabweichung σ. Für eine hinreichend große Anzahl n (meist $n > 30$) nähert sich die Verteilung der Summe $S_n = \sum X_i$ einer Normalverteilung an. Das bedeutet, dass die standardisierte Summe gegen die

Standardnormalverteilung konvergiert:

$$P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq z\right) \to \Phi(z) \quad \text{für } n \to \infty$$

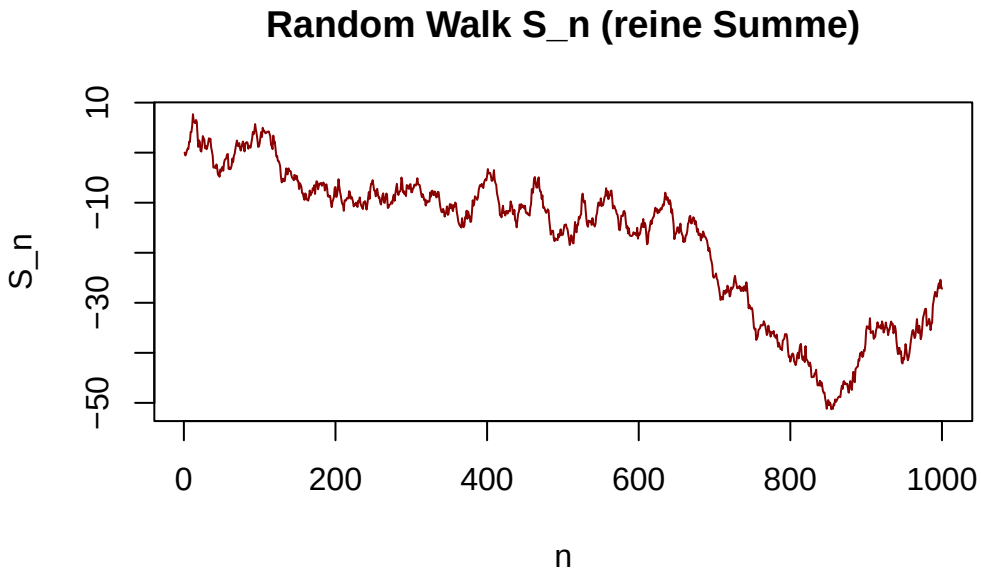
1.2.4.1 R-Simulation: Visualisierung des Random Walks

Der nachfolgende Code veranschaulicht die mathematische Konvergenz eines Random Walks $S_n = \sum Z_i$ mit standardnormalverteilten Schritten:

R-Code: Random Walk (Reine Summe S_n)

```
N <- 1000
S <- rep(0, N)
set.seed(42)
Z <- rnorm(N)
for (n in 2:N) {
  S[n] <- S[n-1] + Z[n]
}

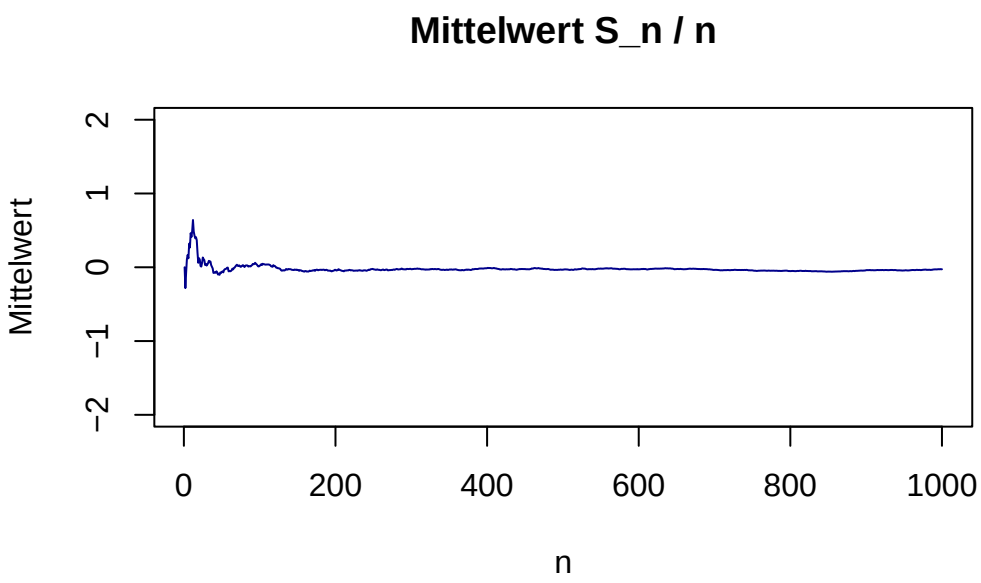
# Verhalten von S_n (Divergiert, da Varianz n*sigma^2 wächst)
plot(S, type='l', main='Random Walk S_n (reine Summe)', xlab='n', ylab='S_n', col='darkred'
```



Wenn wir den Pfad normieren, verringert sich die Varianz:

R-Code: Mittelwertverlauf (S_n/n)

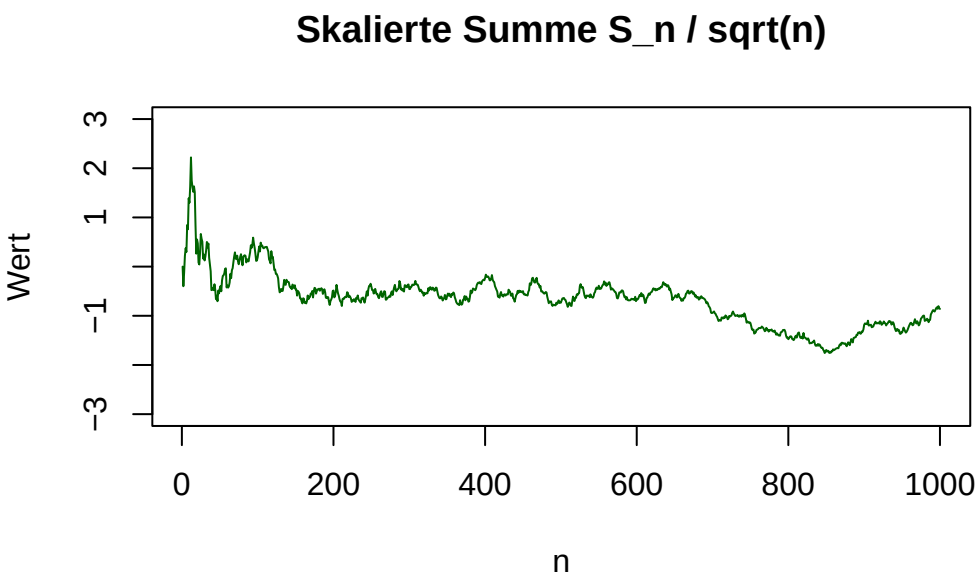
```
# Verhalten des Mittelwerts S_n / n (Konvergiert nach dem Gesetz der großen Zahlen gegen 0)
plot(S / (1:N), type='l', main='Mittelwert S_n / n', xlab='n', ylab='Mittelwert', col='dark
```



Normieren wir mit $1/\sqrt{n}$, konvergiert die Verteilung gegen eine stabile Zufallsvariable (die Normalverteilung):

R-Code: Skalierter Verlauf ($S_n/\sqrt{n}$)

```
# Verhalten von S_n / sqrt(n) (Weder Divergenz noch Konvergenz gegen 0, sondern fluktuieren
plot(S / sqrt(1:N), type='l', main='Skalierte Summe S_n / sqrt(n)', xlab='n', ylab='Wert',
```



1.2.4.2 Interaktive R-Simulation: Veranschaulichung des ZGS

Um zu veranschaulichen, wie stark ungleichmäßig verteilte Ausgangsvariablen bei Summation dennoch rasch gegen die Normalverteilung konvergieren, simulieren wir die Summe S_n von n unabhängigen exponentialverteilten Zufallsvariablen (mit Parameter $\lambda = 1$).

Die Dichte einer Exponentialverteilung ist stark rechtsschief (wie man bei $n = 1$ sieht). Wenn wir jedoch die Summe standardisieren ($Z_n = \frac{S_n - n}{\sqrt{n}}$), nähert sich die Dichteverteilung mit wachsendem n unaufhaltsam der symmetrischen Glockenform der Standardnormalverteilung an:

R-Code: Konvergenz zum Grenzwert

```r
library(ggplot2)
library(plotly)

set.seed(42)
N <- 5000 # Anzahl der Simulationsläufe

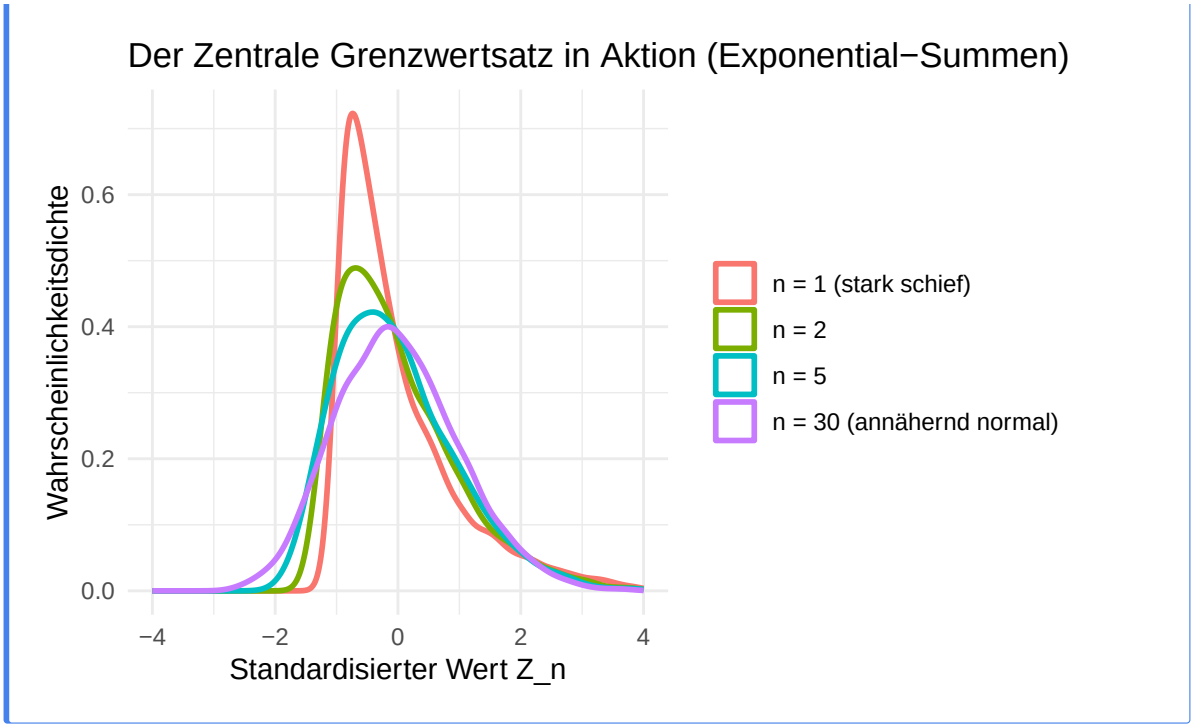
# Funktion zur Simulation der standardisierten Summe von n Exponentialvariablen (lambda = 1
sim_z_n <- function(n, N) {
  X <- matrix(rexp(n * N, rate = 1), nrow = n, ncol = N)
  S_n <- colSums(X)
  Z_n <- (S_n - n) / sqrt(n) # Erwartungswert = n, Varianz = n
  return(Z_n)
}

# Simulation für n = 1, 2, 5, 30
df_clt <- data.frame(
  Wert = c(sim_z_n(1, N), sim_z_n(2, N), sim_z_n(5, N), sim_z_n(30, N)),
  Stichprobenumfang = rep(c("n = 1 (stark schief)", "n = 2", "n = 5", "n = 30 (annähernd no
)

# Faktor-Level festlegen für die richtige Sortierung in der Legende
df_clt$Stichprobenumfang <- factor(df_clt$Stichprobenumfang,
                                   levels = c("n = 1 (stark schief)", "n = 2", "n = 5", "n =

# ggplot-Dichteschätzer erstellen
p_clt <- ggplot(df_clt, aes(x = Wert, color = Stichprobenumfang)) +
  geom_density(linewidth = 1, adjust = 1.2) +
  labs(
    title = "Der Zentrale Grenzwertsatz in Aktion (Exponential-Summen)",
    x = "Standardisierter Wert Z_n",
    y = "Wahrscheinlichkeitsdichte"
  ) +
  xlim(-4, 4) +
  theme_minimal() +
  theme(legend.title = element_blank())

# Plotly macht die Grafik interaktiv
interaktiv(p_clt)
```



1.2.5 Normalapproximation der Binomialverteilung und Stetigkeitskorrektur

Eine Binomialverteilung $Bin(n, p)$ lässt sich für moderate p und große n sehr gut durch eine Normalverteilung $N(np, \sqrt{npq})$ approximieren.

Da wir hierbei eine diskrete Verteilung durch eine stetige Verteilung annähern, müssen wir die **Stetigkeitskorrektur** (Continuity Correction) anwenden. Wir erweitern das diskrete Intervall um 0,5 in beide Richtungen:

$$P(X \leq x) \approx P(X_{stetig} \leq x + 0{,}5)$$

$$P(X < x) \approx P(X_{stetig} \leq x - 0{,}5)$$

1.2.6 Übungsaufgaben zu Kapitel 3

Übung 3.1 (Aufgabe 4.1 aus dem Lehrbuch)

Die Lebensdauer X (in Jahren) eines bestimmten elektronischen Bauteils ist eine stetige Zufallsvariable mit der Dichtefunktion:

$$f(x) = \begin{cases} \frac{k}{x^4} & \text{für } x \geq 1 \\ 0 & \text{für } x < 1 \end{cases}$$

Bestimmen Sie die Konstante k, die kumulative Verteilungsfunktion $F(x)$ und die Wahrscheinlichkeit, dass das Bauteil länger als 2 Jahre funktioniert.

1.2.7 Mathematische Herleitung

1. **Konstante k bestimmen**:

$$\int_1^\infty \frac{k}{x^4} dx = k \left[-\frac{1}{3x^3} \right]_1^\infty = k \left(0 - \left(-\frac{1}{3} \right) \right) = \frac{k}{3} = 1 \implies k = 3$$

2. **Kumulative Verteilungsfunktion** $F(x)$: Für $x < 1$ ist $F(x) = 0$. Für $x \geq 1$ gilt:

$$F(x) = \int_1^x \frac{3}{t^4} dt = \left[-\frac{1}{t^3} \right]_1^x = 1 - \frac{1}{x^3}$$

3. **Wahrscheinlichkeit über 2 Jahre** ($P(X > 2)$):

$$P(X > 2) = 1 - F(2) = 1 - \left(1 - \frac{1}{2^3} \right) = \frac{1}{8} = 0{,}125$$

Die Konstante ist $k = 3$, die cdf lautet $1 - x^{-3}$ (für $x \geq 1$) und die gesuchte Wahrscheinlichkeit beträgt 0,125 (oder 12,5%).

1.2.8 R-Code & Simulation

```
set.seed(42)
N <- 100000
# Inverse Transformationsmethode: X = U^(-1/3)
U <- runif(N)
X <- U^(-1/3)

# Wahrscheinlichkeit, dass Bauteil länger als 2 Jahre funktioniert
mean(X > 2)
#> [1] 0.12585
```

⚠ Übung 3.2 (Aufgabe 4.2 aus dem Lehrbuch)

Die Zeit (in Minuten), die für den Neustart eines bestimmten Servers benötigt wird, ist eine stetige Zufallsvariable mit der Dichte:

$$f(x) = \begin{cases} C(10-x)^2 & \text{für } 0 < x < 10 \\ 0 & \text{andernfalls} \end{cases}$$

(a) Berechnen Sie die Konstante C. (b) Wie hoch ist die Wahrscheinlichkeit, dass der Server-Neustart zwischen 1 und 2 Minuten dauert?

1.2.9 Mathematische Herleitung

(a) Konstante C bestimmen: Wir substituieren $u = 10 - x \implies du = -dx$:

$$\int_0^{10} C(10-x)^2 dx = C \int_0^{10} u^2 du = C \left[\frac{u^3}{3}\right]_0^{10} = C \cdot \frac{1000}{3} = 1 \implies C = \frac{3}{1000} = 0{,}003$$

(b) Wahrscheinlichkeit zwischen 1 und 2 Minuten ($P(1 < X < 2)$):

$$P(1 < X < 2) = \int_1^2 0{,}003(10-x)^2 dx = 0{,}003 \left[-\frac{(10-x)^3}{3}\right]_1^2 = 0{,}001 \left(-(8^3) - (-(9^3))\right)$$

$$P(1 < X < 2) = 0{,}001 \cdot (-512 + 729) = 0{,}001 \cdot 217 = 0{,}217$$

Die Konstante beträgt $C = 0{,}003$ und die Wahrscheinlichkeit liegt bei 0,217 (oder 21,7%).

1.2.10 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Inverse Transformation: X = 10 - 10 * U^(1/3)
U <- runif(N)
X <- 10 - 10 * U^(1/3)

# Wahrscheinlichkeit für Neustart zwischen 1 und 2 Minuten
mean(X > 1 & X < 2)
#> [1] 0.21676
```

⚠ Übung 3.3 (Aufgabe 4.7 aus dem Lehrbuch)

Die Druckzeit eines Netzwerkdruckers für einen Auftrag ist eine exponentialverteilte Zufallsvariable mit einer erwarteten Dauer von 12 Sekunden. Sie senden um 10:00 Uhr einen Druckauftrag ab, der an dritter Stelle in der Warteschlange steht (zwei Aufträge sind vor Ihrem, gefolgt von Ihrem eigenen). Wie groß ist die Wahrscheinlichkeit, dass Ihr Dokument noch vor 10:01 Uhr fertig gedruckt ist?

1.2.11 Mathematische Herleitung

Seien T_1, T_2, T_3 die unabhängigen Druckzeiten der drei Aufträge. $T_i \sim Exp(\lambda)$ mit $E(T_i) = 12$ Sekunden. Somit ist $\lambda = 1/12$ s^{-1}. Die Gesamtzeit bis zur Fertigstellung Ihres Auftrags ist $T = T_1 + T_2 + T_3$. Da T die Summe von $\alpha = 3$ unabhängigen exponentialverteilten Variablen ist, folgt T einer Gammaverteilung: $T \sim \text{Gamma}(\alpha = 3, \lambda = 1/12)$.
Wir suchen die Wahrscheinlichkeit, dass Ihr Auftrag in weniger als 1 Minute (60 Sekunden) fertig ist ($P(T < 60)$). Über die **Gamma-Poisson-Formel** gilt mit $t = 60$:

$$P(T < 60) = P(X \geq 3) \quad \text{wobei } X \sim \text{Poisson}(\lambda t = 1/12 \cdot 60 = 5)$$

Wir berechnen $P(X \geq 3)$ über das Gegenereignis:

$$P(X \geq 3) = 1 - P(X \leq 2) = 1 - \left(e^{-5} \frac{5^0}{0!} + e^{-5} \frac{5^1}{1!} + e^{-5} \frac{5^2}{2!} \right)$$

$$P(X \geq 3) = 1 - e^{-5}(1 + 5 + 12{,}5) = 1 - 18{,}5 \cdot e^{-5}$$

Da $e^{-5} \approx 0{,}006738$ ist, folgt:

$$P(X \geq 3) \approx 1 - 18{,}5 \cdot 0{,}006738 = 1 - 0{,}12465 = 0{,}87535$$

Die Wahrscheinlichkeit beträgt ca. 0,8754 (oder 87,54%).

1.2.12 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Summe von 3 exponentialverteilten Druckzeiten (Mittelwert = 12s, Rate = 1/12)
T_ges <- replicate(N, sum(rexp(3, rate = 1/12)))

# Wahrscheinlichkeit fertig vor 10:01 (in weniger als 60 Sekunden)
mean(T_ges < 60)
#> [1] 0.8752
```

⚠ Übung 3.4 (Aufgabe 4.9 aus dem Lehrbuch)

Ein Computer stürzt im Durchschnitt alle 5 Monate ab. Die Zeit bis zum ersten Absturz sowie die Zeiten zwischen den folgenden Abstürzen sind unabhängige, identisch exponentialverteilte Zufallsvariablen. Nach dem dritten Absturz benötigt der Rechner eine spezielle Wartung. (a) Berechnen Sie die Wahrscheinlichkeit, dass die spezielle Wartung innerhalb der nächsten 9 Monate erforderlich wird. (b) Angenommen, in den ersten 12 Monaten war keine Wartung erforderlich. Wie hoch ist die Wahrscheinlichkeit, dass sie auch in den darauffolgenden 4 Monaten nicht benötigt wird?

1.2.13 Mathematische Herleitung

Die Zeit T_i zwischen den Abstürzen folgt $Exp(\lambda = 1/5 = 0{,}2 \text{ Monate}^{-1})$. Die Zeit bis zur Wartung (3. Absturz) ist $T = T_1 + T_2 + T_3 \sim \text{Gamma}(\alpha = 3, \lambda = 0{,}2)$.
(a) Wartung innerhalb von 9 Monaten ($P(T \leq 9)$): Wir nutzen die Gamma-Poisson-Formel mit $t = 9$ und seltener Rate $\lambda t = 0{,}2 \cdot 9 = 1{,}8$:

$$P(T \leq 9) = P(X \geq 3) \quad \text{wobei } X \sim \text{Poisson}(1{,}8)$$

$$P(X \geq 3) = 1 - P(X \leq 2) = 1 - e^{-1{,}8}\left(1 + 1{,}8 + \frac{1{,}8^2}{2}\right) = 1 - e^{-1{,}8}(1 + 1{,}8 + 1{,}62) = 1 - 4{,}42 \cdot e^{-1{,}8}$$

Mit $e^{-1{,}8} \approx 0{,}1653$ ergibt sich:

$$P(T \leq 9) \approx 1 - 4{,}42 \cdot 0{,}1653 = 1 - 0{,}7306 = 0{,}2694$$

(b) Bedingte Wahrscheinlichkeit $P(T > 16 \mid T > 12)$:

$$P(T > 16 \mid T > 12) = \frac{P(T > 16)}{P(T > 12)}$$

Wir bestimmen $P(T > t) = P(X_t < 3) = P(X_t \leq 2)$ für $t = 12$ und $t = 16$: * **Für** $t = 12$ ($\lambda t = 0{,}2 \cdot 12 = 2{,}4$):

$$P(T > 12) = e^{-2{,}4}\left(1 + 2{,}4 + \frac{2{,}4^2}{2}\right) = e^{-2{,}4}(1 + 2{,}4 + 2{,}88) = 6{,}28 \cdot e^{-2{,}4} \approx 6{,}28 \cdot 0{,}0907 = 0{,}5697$$

* **Für** $t = 16$ ($\lambda t = 0{,}2 \cdot 16 = 3{,}2$):

$$P(T > 16) = e^{-3{,}2}\left(1 + 3{,}2 + \frac{3{,}2^2}{2}\right) = e^{-3{,}2}(1 + 3{,}2 + 5{,}12) = 9{,}32 \cdot e^{-3{,}2} \approx 9{,}32 \cdot 0{,}0408 = 0{,}3799$$

Die gesuchte bedingte Wahrscheinlichkeit lautet:

$$P(T > 16 \mid T > 12) = \frac{0{,}3799}{0{,}5697} \approx 0{,}6668$$

Die Wahrscheinlichkeit für (a) beträgt ca. 0,2694 (26,94%) und für (b) ca. 0,6668 (66,68%).

1.2.14 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Zeit bis zum 3. Absturz (Gamma mit alpha = 3, rate = 0.2)
T_wartung <- rgamma(N, shape = 3, rate = 0.2)

# (a) Wartung innerhalb der nächsten 9 Monate
print(paste("(a) Wahrscheinlichkeit <= 9 Monate:", round(mean(T_wartung <= 9), 4)))
#> [1] "(a) Wahrscheinlichkeit <= 9 Monate: 0.2709"
# (b) Bedingte Wahrscheinlichkeit T > 16 gegeben T > 12
print(paste("(b) Bedingte Wahrscheinlichkeit T > 16 | T > 12:", round(mean(T_wartung[T_wart
#> [1] "(b) Bedingte Wahrscheinlichkeit T > 16 | T > 12: 0.6662"
```

⚠ Übung 3.5 (Aufgabe 4.12 aus dem Lehrbuch)

Ein Computer verarbeitet ankommende Aufgaben in der Reihenfolge ihres Eingangs. Jede Aufgabe benötigt eine exponentialverteilte Rechenzeit mit einem Mittelwert von 2 Minuten. Berechnen Sie die Wahrscheinlichkeit, dass ein Paket aus 5 unabhängigen Aufgaben in weniger als 8 Minuten verarbeitet wird.

1.2.15 Mathematische Herleitung

Wir haben $n = 5$ Aufgaben. Jede Rechenzeit $T_i \sim Exp(\lambda)$ mit $E(T_i) = 2$ Minuten $\implies \lambda = 0{,}5\ \text{min}^{-1}$. Die Gesamtzeit $T = \sum_{i=1}^{5} T_i$ folgt einer Gammaverteilung: $T \sim \text{Gamma}(\alpha = 5, \lambda = 0{,}5)$. Wir suchen $P(T < 8)$. Unter Verwendung der Gamma-Poisson-Formel mit $t = 8$ und der Rate $\lambda t = 0{,}5 \cdot 8 = 4$:

$$P(T < 8) = P(X \geq 5) \quad \text{wobei } X \sim \text{Poisson}(4)$$

$$P(X \geq 5) = 1 - P(X \leq 4) = 1 - e^{-4}\left(1 + 4 + \frac{4^2}{2} + \frac{4^3}{6} + \frac{4^4}{24}\right)$$

$$P(X \geq 5) = 1 - e^{-4}\,(1 + 4 + 8 + 10{,}667 + 10{,}667) = 1 - 34{,}333 \cdot e^{-4}$$

Mit $e^{-4} \approx 0{,}018316$ erhalten wir:

$$P(X \geq 5) \approx 1 - 34{,}333 \cdot 0{,}018316 = 1 - 0{,}6288 = 0{,}3712$$

Die Wahrscheinlichkeit beträgt ca. 0,3712 (oder 37,12%).

1.2.16 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Summe von 5 Aufgaben (Exponentialverteilung mit Mittelwert = 2)
T_ges <- rgamma(N, shape = 5, rate = 0.5)

# Wahrscheinlichkeit weniger als 8 Minuten
mean(T_ges < 8)
#> [1] 0.37221
```

⚠ Übung 3.6 (Aufgabe 4.14 aus dem Lehrbuch)

Die Zeit X, die für den Neustart eines bestimmten Großrechners benötigt wird, ist gammaverteilt mit einem Erwartungswert von $E(X) = 20$ Minuten und einer Standardabweichung von $Std(X) = 10$ Minuten. (a) Bestimmen Sie die Parameter α und λ dieser Gammaverteilung. (b) Wie hoch ist die Wahrscheinlichkeit, dass der Neustart weniger als 15 Minuten in Anspruch nimmt?

1.2.17 Mathematische Herleitung

(a) Parameter bestimmen: Gegeben sind $E(X) = \frac{\alpha}{\lambda} = 20$ und $Var(X) = \sigma^2 = 10^2 = 100 \implies \frac{\alpha}{\lambda^2} = 100$. Wir teilen die Gleichungen durcheinander:

$$\frac{E(X)}{Var(X)} = \frac{\alpha/\lambda}{\alpha/\lambda^2} = \lambda = \frac{20}{100} = 0{,}2 \text{ min}^{-1}$$

Nun bestimmen wir α:

$$\alpha = 20 \cdot \lambda = 20 \cdot 0{,}2 = 4$$

Die Parameter sind $\alpha = 4$ und $\lambda = 0{,}2$.
(b) Wahrscheinlichkeit $P(X < 15)$: Da $\alpha = 4$ ganzzahlig ist, nutzen wir erneut die Gamma-Poisson-Formel mit $t = 15$ und $\lambda t = 0{,}2 \cdot 15 = 3$:

$$P(X < 15) = P(Y \geq 4) \quad \text{wobei } Y \sim \text{Poisson}(3)$$

$$P(Y \geq 4) = 1 - P(Y \leq 3) = 1 - e^{-3}\left(1 + 3 + \frac{3^2}{2} + \frac{3^3}{6}\right) = 1 - e^{-3}(1+3+4{,}5+4{,}5) = 1 - 13 \cdot e^{-3}$$

Mit $e^{-3} \approx 0{,}04979$ ergibt sich:

$$P(X < 15) \approx 1 - 13 \cdot 0{,}04979 = 1 - 0{,}6472 = 0{,}3528$$

Die Wahrscheinlichkeit beträgt ca. 0,3528 (oder 35,28%).

1.2.18 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Reboot-Zeit (Gamma mit alpha = 4, rate = 0.2)
X <- rgamma(N, shape = 4, rate = 0.2)

# Wahrscheinlichkeit für weniger als 15 Minuten
mean(X < 15)
#> [1] 0.35304
```

⚠ Übung 3.7 (Aufgabe 4.16 aus dem Lehrbuch)

Sei $Z \sim N(0,1)$ eine Standardnormalverteilung. Bestimmen Sie folgende Wahrscheinlichkeiten unter Zuhilfenahme der Verteilungstabelle $\Phi(z)$: (a) $P(Z < 1{,}25)$ (b) $P(Z \leq 1{,}25)$ (c) $P(Z > 1{,}25)$ (d) $P(|Z| \leq 1{,}25)$ (e) $P(Z < 6{,}0)$ (f) $P(Z > 6{,}0)$ (g) Welchen Wert überschreitet Z mit einer Wahrscheinlichkeit von höchstens 20% (d. h. gesucht ist das 80%-Quantil)?

1.2.19 Mathematische Herleitung

Aus der Standardnormalverteilungstabelle entnehmen wir $\Phi(1{,}25) \approx 0{,}8944$. * **(a)** $P(Z < 1{,}25) = \Phi(1{,}25) = \mathbf{0{,}8944}$ * **(b)** $P(Z \leq 1{,}25) = P(Z < 1{,}25) = \mathbf{0{,}8944}$ (da Z stetig ist, macht das Relationszeichen keinen Unterschied). * **(c)** $P(Z > 1{,}25) = 1 - \Phi(1{,}25) = 1 - 0{,}8944 = \mathbf{0{,}1056}$ * **(d)** $P(|Z| \leq 1{,}25) = P(-1{,}25 \leq Z \leq 1{,}25) = \Phi(1{,}25) - \Phi(-1{,}25) = 0{,}8944 - (1 - 0{,}8944) = 2 \cdot 0{,}8944 - 1 = \mathbf{0{,}7888}$ * **(e)** $P(Z < 6{,}0) \approx \mathbf{1{,}0000}$ (praktisch sicher, da 6 Standardabweichungen extrem weit entfernt sind). * **(f)** $P(Z > 6{,}0) \approx \mathbf{0{,}0000}$ (praktisch unmöglich). * **(g)** Wir suchen z mit $P(Z \leq z) = 0{,}80 \implies \Phi(z) = 0{,}80$. Aus der Tabelle lesen wir ab: $z \approx \mathbf{0{,}84}$ (genauer: 0,8416).

1.2.20 R-Code & Simulation

```r
set.seed(42)
N <- 100000
Z <- rnorm(N)

# (a) P(Z < 1.25)
print(paste("(a) P(Z < 1.25):", round(mean(Z < 1.25), 4)))
#> [1] "(a) P(Z < 1.25): 0.8944"
# (d) P(|Z| <= 1.25)
print(paste("(d) P(|Z| <= 1.25):", round(mean(abs(Z) <= 1.25), 4)))
#> [1] "(d) P(|Z| <= 1.25): 0.7875"
# (g) 80%-Quantil
print(paste("(g) 80%-Quantil:", round(quantile(Z, 0.80), 4)))
#> [1] "(g) 80%-Quantil: 0.8425"
```

⚠ Übung 3.8 (Aufgabe 4.23 aus dem Lehrbuch)

Die Lebensdauer eines bestimmten Typs elektronischer Komponenten besitzt einen Erwartungswert von 5000 Stunden und eine Standardabweichung von 100 Stunden. Wie hoch ist die Wahrscheinlichkeit, dass die durchschnittliche Lebensdauer einer Stichprobe von 400 solchen Komponenten weniger als 5012 Stunden beträgt?

1.2.21 Mathematische Herleitung

Seien $X_1, \ldots, X_{400}$ die Lebensdauern der Komponenten mit $\mu = 5000$ und $\sigma = 100$. Die Stichprobengröße beträgt $n = 400$. Der Stichprobenmittelwert $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ besitzt nach dem Zentralen Grenzwertsatz approximativ eine Normalverteilung mit: * Mittelwert $\mu_{\bar{X}} = \mu = 5000$ * Standardfehler $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{100}{\sqrt{400}} = \frac{100}{20} = 5$
Wir suchen $P(\bar{X} < 5012)$. Dazu standardisieren wir die Variable:

$$P(\bar{X} < 5012) = P\left(\frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} < \frac{5012 - 5000}{5}\right) = P\left(Z < \frac{12}{5}\right) = P(Z < 2{,}4)$$

Aus der Tabelle entnehmen wir $\Phi(2{,}4)$:

$$\Phi(2{,}4) = 0{,}9918$$

Die Wahrscheinlichkeit beträgt ca. 0,9918 (oder 99,18%).

1.2.22 R-Code & Simulation

```r
set.seed(42)
# Simulation der Verteilung des Stichprobenmittelwerts (n = 400, mean = 5000, sd = 100)
means <- replicate(10000, mean(rnorm(400, mean = 5000, sd = 100)))

# Wahrscheinlichkeit Mittelwert unter 5012 Stunden
mean(means < 5012)
#> [1] 0.9924
```

⚠ Übung 3.9 (Aufgabe 4.24 aus dem Lehrbuch)

Die Installation eines Softwarepakets erfordert das Herunterladen von 82 separaten Dateien. Im Durchschnitt dauert der Download einer Datei 15 Sekunden bei einer Varianz von 16 s^2. Wie groß ist die Wahrscheinlichkeit, dass die Installation des gesamten Pakets in weniger als 20 Minuten abgeschlossen ist?

1.2.23 Mathematische Herleitung

Wir modellieren die Downloadzeit der einzelnen Dateien als unabhängige Zufallsvariablen X_i $(i = 1, \dots, 82)$ mit $\mu = 15$ und $\sigma^2 = 16$. Die Gesamtinstallationszeit ist $S_{82} = \sum_{i=1}^{82} X_i$. Da $n = 82 > 30$ ist, können wir den Zentralen Grenzwertsatz anwenden. S_{82} ist approximativ normalverteilt mit: * Erwartungswert $E(S_{82}) = n \cdot \mu = 82 \cdot 15 = 1230$ Sekunden * Varianz $Var(S_{82}) = n \cdot \sigma^2 = 82 \cdot 16 = 1312 \implies Std(S_{82}) = \sqrt{1312} \approx 36{,}22$ Sekunden
Wir suchen die Wahrscheinlichkeit, dass die Gesamtzeit weniger als 20 Minuten $(20 \cdot 60 = 1200$ Sekunden) beträgt $(P(S_{82} < 1200))$:

$$P(S_{82} < 1200) \approx P\left(Z < \frac{1200 - 1230}{36{,}22}\right) = P\left(Z < \frac{-30}{36{,}22}\right) = P(Z < -0{,}828)$$

Wir runden auf $z = -0{,}83$ und lesen ab:

$$P(Z < -0{,}83) = 1 - \Phi(0{,}83) = 1 - 0{,}7967 = 0{,}2033$$

Die Wahrscheinlichkeit beträgt ca. 0,2033 (oder 20,33%).

1.2.24 R-Code & Simulation

```r
set.seed(42)
# Downloadzeit von 82 Dateien (Mittelwert = 15, SD = 4)
totals <- replicate(10000, sum(rnorm(82, mean = 15, sd = 4)))

# Wahrscheinlichkeit weniger als 20 Minuten (1200 Sekunden)
mean(totals < 1200)
#> [1] 0.2053
```

⚠ Übung 3.10 (Aufgabe 4.30 aus dem Lehrbuch)

Ein Sendezentrum überträgt nacheinander 70 unabhängige Textnachrichten. Die Übertragungszeit einer einzelnen Nachricht ist exponentialverteilt mit dem Parameter $\lambda = 5$ min^{-1}. Bestimmen Sie mithilfe des Zentralen Grenzwertsatzes die Wahrscheinlichkeit, dass die Übertragung aller 70 Nachrichten weniger als 12 Minuten dauert.

1.2.25 Mathematische Herleitung

Seien $X_i \sim Exp(\lambda = 5)$ für $i = 1, \ldots, 70$. Für eine exponentialverteilte Zufallsvariable gilt: * Erwartungswert $\mu = \frac{1}{\lambda} = 0{,}2$ Minuten * Varianz $\sigma^2 = \frac{1}{\lambda^2} = \frac{1}{25} = 0{,}04 \implies \sigma = 0{,}2$ Minuten
Die Gesamtübertragungszeit ist $S_{70} = \sum_{i=1}^{70} X_i$. Nach dem ZGS ist S_{70} näherungsweise normalverteilt mit: * Erwartungswert $E(S_{70}) = 70 \cdot 0{,}2 = 14$ Minuten * Varianz $Var(S_{70}) = 70 \cdot 0{,}04 = 2{,}8 \implies Std(S_{70}) = \sqrt{2{,}8} \approx 1{,}6733$ Minuten
Wir suchen $P(S_{70} < 12)$:

$$P(S_{70} < 12) \approx P\left(Z < \frac{12 - 14}{1{,}6733}\right) = P\left(Z < \frac{-2}{1{,}6733}\right) = P(Z < -1{,}195)$$

Wir runden auf $z = -1{,}20$ und nutzen die Verteilungstabelle:

$$P(Z < -1{,}20) = 1 - \Phi(1{,}20) = 1 - 0{,}8849 = 0{,}1151$$

Die Wahrscheinlichkeit beträgt ca. 0,1151 (oder 11,51%).

1.2.26 R-Code & Simulation

```r
set.seed(42)
N <- 100000
# Gesamtübertragungszeit von 70 Nachrichten (Exponential mit Rate = 5)
totals <- rgamma(N, shape = 70, rate = 5)

# Wahrscheinlichkeit unter 12 Minuten
mean(totals < 12)
#> [1] 0.11383
```

1.3 Zusammenfassung: Verteilungs-Spickzettel

Hier ist eine kompakte Übersicht aller behandelten Verteilungen als Referenz für Ihre Studierenden.

Spickzettel: Diskrete & Stetige Verteilungen im Überblick

1.3.1 Diskrete Verteilungen (Support $\mathcal{X}$ diskret)

Verteilung	Wahrscheinlichkeitsfunktion $P(X = x)$	Parameter	Erwartungswert $E(X)$	Varianz $Var(X)$	R-Funktionen
Bernoulli	$p^x(1-p)^{1-x}, \quad x \in \{0,1\}$	$p \in [0,1]$	p	$p(1-p)$	`dbinom(..., size=1)`
Binomial	$\binom{n}{x}p^x(1-p)^{n-x}, \quad x \in \{0,\dots,n\}$	$n \in \mathbb{N}, p \in [0,1]$	np	$np(1-p)$	`dbinom()`, `pbinom()`
Geometrisch	$(1-p)^{x-1}p, \quad x \in \{1,2,\dots\}$	$p \in (0,1]$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	`dgeom()`, `pgeom()`
Negative Binomial	$\binom{x-1}{k-1}(1-p)^{x-k}p^k, \quad x \in \{k,k+1,\dots\}$	$k \in \mathbb{N}, p \in (0,1]$	$\frac{k}{p}$	$\frac{k(1-p)}{p^2}$	`dnbinom()`, `pnbinom()`
Poisson	$e^{-\lambda}\frac{\lambda^x}{x!}, \quad x \in \{0,1,\dots\}$	$\lambda > 0$	λ	λ	`dpois()`, `ppois()`

Hinweis zu R: Die R-Funktionen `dgeom` und `dnbinom` zählen standardmäßig die Anzahl der Misserfolge Y vor dem Erfolg ($Y = X - 1$ bzw. $Y = X - k$). Um Wahrscheinlichkeiten für die Gesamtzahl der Versuche X abzufragen, muss daher `x - 1` bzw. `x - k` übergeben werden.

1.3.2 Stetige Verteilungen (Support $\mathcal{X}$ stetig)

Verteilung	Dichtefunktion $f(x)$	Parameter	Erwartungswert $E(X)$	Varianz $Var(X)$	R-Funktionen
Stetige Gleichverteilung	$\frac{1}{b-a}$, $a < x < b$	$a, b \in \mathbb{R}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	`dunif()`, `punif()`, `runif()`
Exponentialverteilung	$\lambda e^{-\lambda x}$, $x > 0$	$\lambda > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	`dexp()`, `pexp()`, `rexp()`
Gamma	$\frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$, $x > 0$	$\alpha > 0$ (Shape) $\lambda > 0$ (Rate)	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$	`dgamma(..., rate=lambda)`
Normal (Gauß)	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $x \in \mathbb{R}$	$\mu \in \mathbb{R}$ (Mean) $\sigma > 0$ (SD)	μ	σ^2	`dnorm()`, `pnorm()`, `rnorm()`