INF712 - Computerunterstützte Statistik

26-27 WS

11/10/2026

Inhaltsverzeichnis

1 Vorlesung 04: Parameterschätzung **2**

1.1 **Von der Stichprobe zur Population** . . . 2
1.2 **Momentenmethode** . . . 4
1.3 **Maximum-Likelihood-Methode** . . . 8
1.4 **Standardfehler von Schätzern** . . . 16
1.5 **Übungsaufgaben** . . . 19
1.5.1 Tipp . . . 19
1.5.2 Lösung . . . 19
1.5.3 Erklärung . . . 20
1.5.4 Tipp . . . 20
1.5.5 Lösung . . . 20
1.5.6 Erklärung . . . 20
1.5.7 Tipp . . . 21
1.5.8 Lösung . . . 21
1.5.9 Erklärung . . . 22
1.5.10 Tipp . . . 22
1.5.11 Lösung . . . 22
1.5.12 Erklärung . . . 23
1.5.13 Tipp . . . 23
1.5.14 Lösung . . . 24
1.5.15 Erklärung . . . 24
1.5.16 Tipp . . . 25
1.5.17 Lösung . . . 25
1.5.18 Erklärung . . . 25
1.5.19 Tipp . . . 26
1.5.20 Lösung . . . 26
1.5.21 Erklärung . . . 27

1.6 Das Minimum, das Sie ohne Hilfe beherrschen sollten 28

1 Vorlesung 04: Parameterschätzung

Momentenmethode, Maximum-Likelihood-Methode, Standardfehler von Schätzern (Baron, §9.1).

Lernziele

Nach dieser Vorlesung können Sie

- Parameter, Schätzer und Schätzwert unterscheiden und Schätzer nach Verzerrung, Standardfehler und mittlerem quadratischem Fehler beurteilen,
- Schätzer mit der Momentenmethode und der Maximum-Likelihood-Methode herleiten — von Hand und numerisch mit `optimize()`, `optim()` und `fitdistr()`,
- den Standardfehler eines Schätzers herleiten, schätzen und per Simulation überprüfen.

1.1 Von der Stichprobe zur Population

Wozu Parameter schätzen?

In der beschreibenden Statistik haben wir Lage- und Streuungsmaße berechnet. Oft vermuten wir aber zusätzlich eine **Verteilungsfamilie** — etwa Poisson für die Anzahl seltener Fehler auf einem Chip, Exponential für Wartezeiten, Gamma für Rechenzeiten. Eine Familie enthält unendlich viele Verteilungen; erst wenn die **Parameter** festgelegt sind, haben wir *eine* Verteilung, mit der wir rechnen, prognostizieren und simulieren können.

Baron stellt zwei Fragen, die das Problem gut zeigen:

- **Poisson (Bsp. 9.1):** Für $X \sim \text{Poisson}(\lambda)$ gilt $\lambda = E(X)$ *und* $\lambda = \text{Var}(X)$. Schätzen wir λ mit $\bar{X}$ oder mit s^2?
- **Gamma (Bsp. 9.2):** Die Parameter α und λ einer Gammaverteilung sind weder Mittelwert noch Varianz. Wie schätzt man sie überhaupt?

Es gibt keine eindeutige Antwort — aber es gibt allgemeine **Methoden**, die immer einen Schätzer liefern, und **Kriterien**, mit denen man Schätzer vergleicht.

Begriffe

Begriff	Bedeutung	Beispiel
Parameter θ	feste, unbekannte Kenngröße der Population	μ, λ, p

Begriff	Bedeutung	Beispiel
Schätzer $\hat{\theta} = T(X_1, \ldots, X_n)$	Rechenvorschrift, angewandt auf eine *zufällige* Stichprobe — also eine **Zufallsvariable**	$\bar{X} = \frac{1}{n}\sum X_i$
Schätzwert	die Zahl, die der Schätzer für die *beobachtete* Stichprobe liefert	$\bar{x} = 6{,}5$

Weil der Schätzer eine Zufallsvariable ist, hat er eine Verteilung — die **Stichprobenverteilung**. Sie haben sie in der letzten Vorlesung bereits per Monte Carlo gesehen: Die 2000 Schätzungen von π bildeten eine Normalverteilung um den wahren Wert.

Gütekriterien

Kriterium	Definition	Bedeutung
Verzerrung (*bias*)	$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$	systematischer Fehler; *erwartungstreu* heißt Bias $= 0$
Standardfehler	$\sigma(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$	zufälliger Fehler — wie stark schwankt $\hat{\theta}$ von Stichprobe zu Stichprobe?
Mittlerer quadratischer Fehler	$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \text{Bias}^2 + \text{Var}(\hat{\theta})$	Gesamtfehler
Konsistenz	$\hat{\theta} \to \theta$ für $n \to \infty$	mit genug Daten wird der Schätzer beliebig genau

Ein vertrautes Beispiel: Die Stichprobenvarianz mit Nenner $n - 1$,

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2,$$

ist erwartungstreu; die Variante mit Nenner n, $S^2 = \frac{1}{n}\sum(X_i - \bar{X})^2$, unterschätzt σ^2 systematisch um den Faktor $(n-1)/n$. Das prüfen wir per Simulation mit $n = 5$ und $\sigma^2 = 4$:

```
set.seed(1)
n <- 5
schaetzer <- replicate(10000, {
  x <- rnorm(n, mean = 0, sd = 2)
  c(s2 = var(x),                          # Nenner n - 1
    S2 = mean((x - mean(x))^2))           # Nenner n
```

```
})

rowMeans(schaetzer)                          # Erwartungswerte (Ziel: 4)
#>       s2       S2
#> 4.053083 3.242466
c(s2_theorie = 4, S2_theorie = 4 * (n - 1) / n)
#> s2_theorie S2_theorie
#>        4.0        3.2
```

> **i** Monte Carlo als Prüfstand für Schätzer
>
> Wenn wir die Daten **selbst simulieren**, kennen wir den wahren Parameter. Damit lassen sich Verzerrung, Standardfehler und MSE jedes Schätzers direkt messen — auch dann, wenn die Theorie zu schwierig ist. Dieses Werkzeug aus der letzten Vorlesung verwenden wir heute ständig.

1.2 Momentenmethode

Momente

	Population	Stichprobe
k-tes Moment	$\mu_k = E(X^k)$	$m_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k$
k-tes zentrales Moment ($k \geq 2$)	$\mu_k' = E(X - \mu_1)^k$	$m_k' = \frac{1}{n}\sum_{i=1}^{n} (X_i - \bar{X})^k$

Das erste Moment ist der Erwartungswert, das erste Stichprobenmoment der Mittelwert $\bar{X}$. Das zweite zentrale Moment ist die Varianz; ihr Stichprobengegenstück ist S^2 (Nenner n, nicht $n-1$).

```
moment <- function(x, k, zentral = FALSE) {
  if (zentral) x <- x - mean(x)
  mean(x^k)
}

x <- c(2, 4, 4, 5, 7, 8)
c(m1 = moment(x, 1), m2 = moment(x, 2), m2_zentral = moment(x, 2, zentral = TRUE))
#>         m1         m2 m2_zentral
#>          5         29          4
var(x) * (length(x) - 1) / length(x)     # m2' ist S^2, nicht var(x)
#> [1] 4
```

Die Idee

Wir wählen aus der Familie diejenige Verteilung, deren Momente mit den Momenten der Daten **übereinstimmen**. Bei k unbekannten Parametern setzt man die ersten k Momente gleich,

$$\mu_1(\theta) = m_1, \quad \mu_2(\theta) = m_2, \quad \ldots, \quad \mu_k(\theta) = m_k,$$

und löst das Gleichungssystem nach den Parametern auf. Statt der gewöhnlichen dürfen auch zentrale Momente verwendet werden, wenn das bequemer ist.

Rezept

1. Momente der Verteilungsfamilie als Funktion der Parameter aufschreiben (Formelsammlung oder Integration).
2. So viele Gleichungen aufstellen, wie es Parameter gibt.
3. Nach den Parametern auflösen.
4. Stichprobenmomente einsetzen.

Beispiel: Poisson (Baron, Bsp. 9.3)

Ein Parameter, also eine Gleichung: $\mu_1 = \lambda = m_1 = \bar{X}$, somit $\hat{\lambda} = \bar{X}$. Wir simulieren die Anzahl seltener Defekte auf 50 Chips mit $\lambda = 2{,}4$:

```
set.seed(2)
defekte <- rpois(50, lambda = 2.4)
table(defekte)
#> defekte
#>  0  1  2  3  4  5  6
#>  2 15 12  6  8  4  3

c(lambda_mom = mean(defekte),            # Momentenmethode mit dem 1. Moment
  lambda_var = var(defekte))             # Alternative über die Varianz
#> lambda_mom lambda_var
#>   2.540000   2.661633
```

Beide Werte schätzen λ — welcher ist besser? Ein Vergleich über viele Stichproben:

```
set.seed(3)
vergleich <- replicate(10000, {
  x <- rpois(50, lambda = 2.4)
  c(mittelwert = mean(x), varianz = var(x))
})
round(rbind(mittel = rowMeans(vergleich),
            se     = apply(vergleich, 1, sd)), 3)
```

```
#>        mittelwert varianz
#> mittel      2.399   2.399
#> se          0.220   0.530
```

Beide sind erwartungstreu, aber $\bar{X}$ streut deutlich weniger. Die Momentenmethode wählt das **erste** Moment, und das ist hier auch die bessere Wahl.

Beispiel: Gammaverteilte Rechenzeiten (Baron, Bsp. 9.4)

Baron verwendet die CPU-Zeiten (in Sekunden) von 30 zufällig ausgewählten Rechenaufträgen. Für $X \sim \text{Gamma}(\alpha, \lambda)$ gilt

$$E(X) = \frac{\alpha}{\lambda}, \qquad \text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

Mit dem ersten Moment und dem zweiten **zentralen** Moment entstehen zwei Gleichungen,

$$\frac{\alpha}{\lambda} = m_1, \qquad \frac{\alpha}{\lambda^2} = m_2' \qquad \Longrightarrow \qquad \hat{\alpha} = \frac{m_1^2}{m_2'}, \qquad \hat{\lambda} = \frac{m_1}{m_2'}.$$

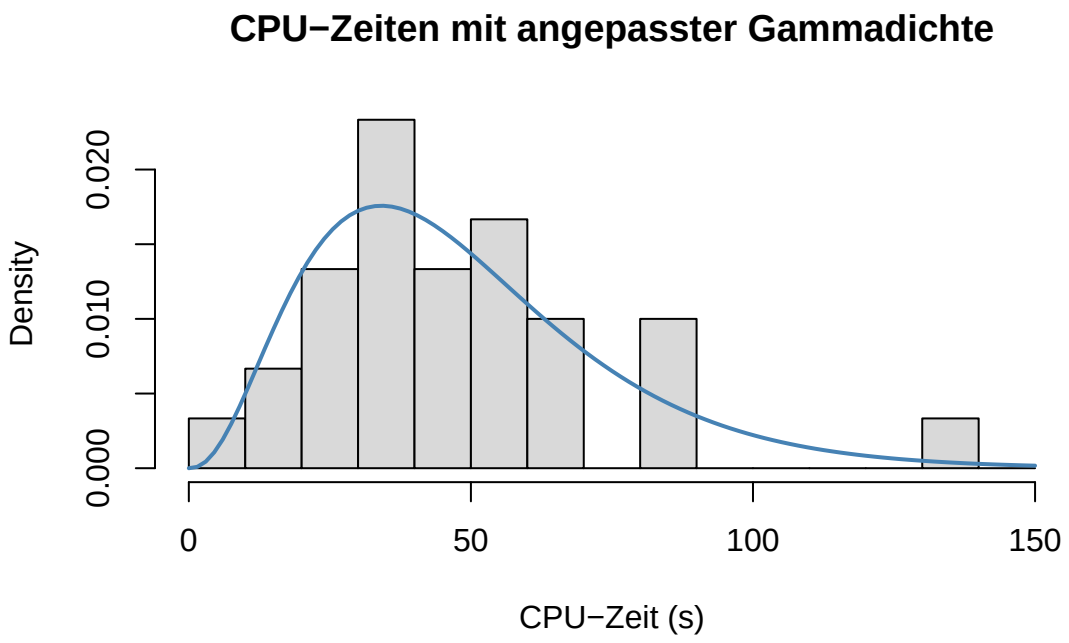
```
cpu <- c(70, 36, 43, 69, 82, 48, 34, 62, 35, 15, 59, 139, 46, 37, 42,
         30, 55, 56, 36, 82, 38, 89, 54, 25, 35, 24, 22, 9, 56, 19)

m1 <- moment(cpu, 1)
m2 <- moment(cpu, 2, zentral = TRUE)
c(m1 = m1, m2 = m2)
#>        m1        m2
#>  48.23333 679.71222

alpha_mom  <- m1^2 / m2
lambda_mom <- m1 / m2
c(alpha = alpha_mom, lambda = lambda_mom)
#>     alpha    lambda
#> 3.4227050 0.0709614
```

Das sind genau Barons Werte $\hat{\alpha} = 3{,}4227$ und $\hat{\lambda} = 0{,}0710$. Passt die geschätzte Verteilung zu den Daten?

```
hist(cpu, breaks = seq(0, 150, by = 10), freq = FALSE, col = "grey85",
     main = "CPU-Zeiten mit angepasster Gammadichte", xlab = "CPU-Zeit (s)")
curve(dgamma(x, shape = alpha_mom, rate = lambda_mom),
      add = TRUE, col = "steelblue", lwd = 2)
```



Beispiel: Pareto-Verteilung (Baron, Bsp. 9.5)

Die Pareto-Verteilung beschreibt Größen mit „schweren Rändern": wenige sehr große Werte neben vielen kleinen — Dateigrößen, Datenmengen pro Verbindung im Internet, Einkommen. Ihre Verteilungsfunktion ist

$$F(x) = 1 - \left(\frac{x}{\sigma}\right)^{-\theta}, \qquad x > \sigma.$$

Durch Integration erhält man die ersten beiden (gewöhnlichen) Momente

$$\mu_1 = \frac{\theta\sigma}{\theta - 1} \;\; (\theta > 1), \qquad \mu_2 = \frac{\theta\sigma^2}{\theta - 2} \;\; (\theta > 2).$$

Für $\theta \leq 1$ ist der Erwartungswert unendlich, für $\theta \leq 2$ die Varianz. Löst man die Momentengleichungen, ergibt sich (Baron, 9.1)

$$\hat{\theta} = 1 + \sqrt{\frac{m_2}{m_2 - m_1^2}}, \qquad \hat{\sigma} = \frac{m_1(\hat{\theta} - 1)}{\hat{\theta}}.$$

Zum Testen brauchen wir Pareto-Zufallszahlen. Mit der **Inversionsmethode** aus der letzten Vorlesung: Aus $u = 1 - (x/\sigma)^{-\theta}$ folgt $x = \sigma(1-u)^{-1/\theta}$, und weil $1 - U$ ebenfalls gleichverteilt ist, genügt $X = \sigma\, U^{-1/\theta}$.

```r
rpareto <- function(n, sigma, theta) sigma * runif(n)^(-1 / theta)

pareto_mom <- function(x) {
  m1 <- moment(x, 1)
  m2 <- moment(x, 2)                    # gewöhnliches (nicht zentrales) Moment
  theta <- 1 + sqrt(m2 / (m2 - m1^2))
  c(sigma = m1 * (theta - 1) / theta, theta = theta)
}

set.seed(4)
dateigroessen <- rpareto(200, sigma = 1, theta = 4)   # z. B. in kB
pareto_mom(dateigroessen)
#>    sigma    theta
#> 1.005965 4.291204
```

> ⚠ Wenn die Momente nicht existieren
>
> $\sqrt{m_2/(m_2 - m_1^2)}$ ist immer mindestens 1 — die Momentenmethode liefert für Pareto also **stets** $\hat{\theta} > 2$. Ist das wahre $\theta \leq 2$, existiert die Varianz nicht, und der Schätzer liegt systematisch daneben, egal wie groß die Stichprobe ist. Gerade bei Internetdaten ist $\theta < 2$ realistisch. Wir kommen bei der Maximum-Likelihood-Methode darauf zurück.

Beispiel: Normalverteilung mit bekanntem μ (Baron, Bsp. 9.6)

Ist nur σ^2 unbekannt, hilft die erste Gleichung $\mu_1 = \mu = m_1$ nicht weiter, denn sie enthält σ^2 gar nicht. Man nimmt die nächste: $\mu_2' = \sigma^2 = m_2'$, also $\hat{\sigma}^2 = S^2$. Wenn k Gleichungen nicht reichen, verwendet man **höhere** Momente.

1.3 Maximum-Likelihood-Methode

Die Idee

Die Stichprobe ist bereits beobachtet. Wir wählen den Parameter so, dass **genau diese Beobachtung möglichst wahrscheinlich** wird.

	Likelihood $L(\theta)$
diskrete Verteilung	gemeinsame Wahrscheinlichkeit $P(X_1, \dots, X_n) = \prod_{i=1}^{n} P(X_i \mid \theta)$
stetige Verteilung	gemeinsame Dichte $f(X_1, \dots, X_n) = \prod_{i=1}^{n} f(X_i \mid \theta)$

Das Produkt entsteht, weil die Beobachtungen einer einfachen Zufallsstichprobe unabhängig sind. Der **Maximum-Likelihood-Schätzer** (ML-Schätzer) $\hat{\theta}$ ist der Wert, der $L(\theta)$ maximiert.

Warum die Dichte im stetigen Fall? Die Wahrscheinlichkeit, *genau* x zu beobachten, ist 0. Die Wahrscheinlichkeit, einen Wert *nahe* x zu beobachten, ist aber proportional zur Dichte:

$$P(x-h<X<x+h)=\int_{x-h}^{x+h} f(y)\,dy \approx 2h\,f(x).$$

Log-Likelihood

Statt des Produkts maximiert man dessen Logarithmus,

$$\ell(\theta)=\ln L(\theta)=\sum_{i=1}^{n}\ln f(X_i\mid\theta).$$

Das hat zwei Gründe:

- **Mathematisch:** Eine Summe ist leichter abzuleiten als ein Produkt. Da ln streng monoton wächst, haben L und ℓ dieselbe Maximalstelle.
- **Numerisch:** Ein Produkt vieler Wahrscheinlichkeiten unterschreitet schnell die kleinste darstellbare Gleitkommazahl.

```r
set.seed(5)
x <- rexp(5000, rate = 2)
prod(dexp(x, rate = 2))                  # Unterlauf: das Produkt wird exakt 0
#> [1] 0
sum(dexp(x, rate = 2, log = TRUE))       # die Log-Likelihood ist problemlos
#> [1] -1529.231
```

Alle Dichtefunktionen in R haben deshalb das Argument `log = TRUE`.

Rezept

1. Log-Likelihood $\ell(\theta)$ aufschreiben; Terme ohne θ dürfen wegfallen.
2. Nach jedem Parameter ableiten und gleich 0 setzen.
3. Auflösen.
4. Prüfen, ob es wirklich ein Maximum ist — auch am **Rand** des Parameterbereichs.

Diskreter Fall: Poisson (Baron, Bsp. 9.7)

Mit $P(x)=e^{-\lambda}\lambda^x/x!$ ist

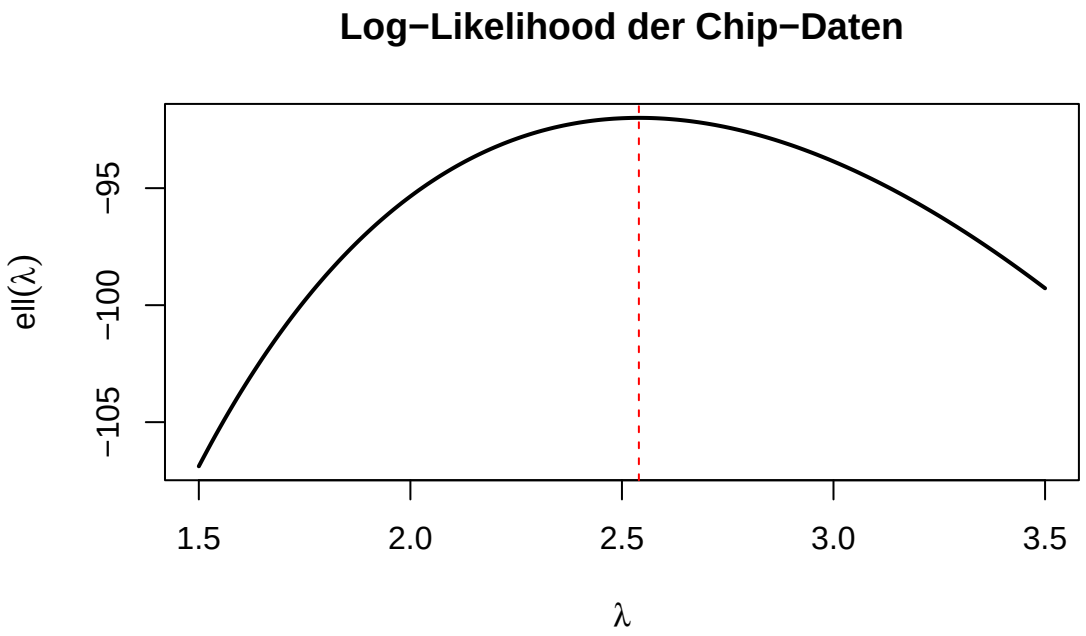
$$\ell(\lambda)=-n\lambda+\ln\lambda\sum_{i=1}^{n}X_i+C,\qquad \ell'(\lambda)=-n+\frac{1}{\lambda}\sum_{i=1}^{n}X_i=0\quad\Longrightarrow\quad\hat{\lambda}=\bar{X}.$$

Für Poisson liefern Momentenmethode und ML-Methode denselben Schätzer. Wir zeichnen die Log-Likelihood der Chip-Daten:

```
loglik_pois <- function(lambda, x) sum(dpois(x, lambda, log = TRUE))

lambda_gitter <- seq(1.5, 3.5, by = 0.01)
ll <- sapply(lambda_gitter, loglik_pois, x = defekte)

plot(lambda_gitter, ll, type = "l", lwd = 2,
     xlab = expression(lambda), ylab = expression(ell(lambda)),
     main = "Log-Likelihood der Chip-Daten")
abline(v = mean(defekte), col = "red", lty = 2)
```



Numerische Maximierung

Lässt sich $\ell'(\theta) = 0$ nicht von Hand lösen, maximiert man numerisch: `optimize()` für einen Parameter, `optim()` für mehrere.

```
optimize(loglik_pois, interval = c(0.01, 10), x = defekte, maximum = TRUE)$maximum
#> [1] 2.540014
mean(defekte)                          # analytische Lösung
#> [1] 2.54
```

Stetiger Fall: Exponentialverteilung (Baron, Bsp. 9.8)

Mit $f(x) = \lambda e^{-\lambda x}$ ist

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^{n} X_i, \qquad \ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^{n} X_i = 0 \quad \Longrightarrow \quad \hat{\lambda} = \frac{1}{\bar{X}}.$$

```
set.seed(6)
wartezeiten <- rexp(40, rate = 0.5)      # Zeit zwischen Serveranfragen

loglik_exp <- function(lambda, x) sum(dexp(x, lambda, log = TRUE))
c(analytisch = 1 / mean(wartezeiten),
  numerisch  = optimize(loglik_exp, c(0.01, 10), x = wartezeiten,
                        maximum = TRUE)$maximum)
#> analytisch  numerisch
#>  0.7141439  0.7141403
```

Maximum am Rand: Gleichverteilung (Baron, Bsp. 9.9)

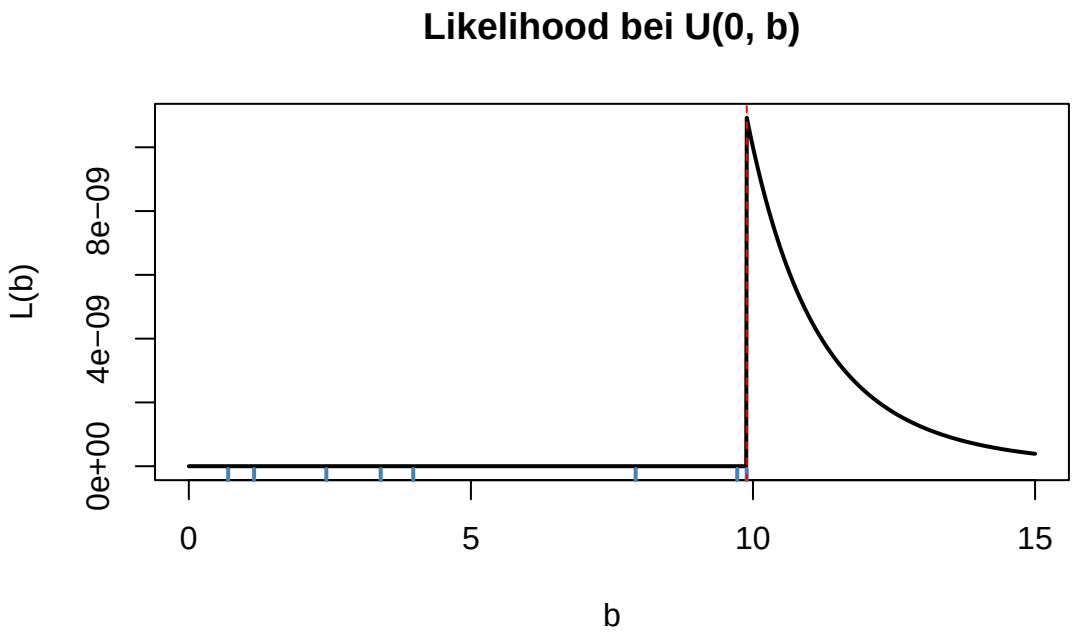
Für $X_i \sim U(0, b)$ ist

$$L(b) = \prod_{i=1}^{n} \frac{1}{b} = b^{-n} \qquad \text{für } b \geq \max_i X_i, \qquad L(b) = 0 \text{ sonst.}$$

L fällt in b, hat also **keine** Nullstelle der Ableitung. Das Maximum liegt am kleinsten zulässigen Wert: $\hat{b} = \max_i X_i$. Ein Bild macht das sofort klar:

```
set.seed(7)
y <- runif(8, 0, 10)
b_gitter <- seq(0, 15, by = 0.01)
L <- ifelse(b_gitter >= max(y), b_gitter^(-length(y)), 0)

plot(b_gitter, L, type = "l", lwd = 2, xlab = "b", ylab = "L(b)",
     main = "Likelihood bei U(0, b)")
rug(y, col = "steelblue", lwd = 2)
abline(v = max(y), col = "red", lty = 2)
```



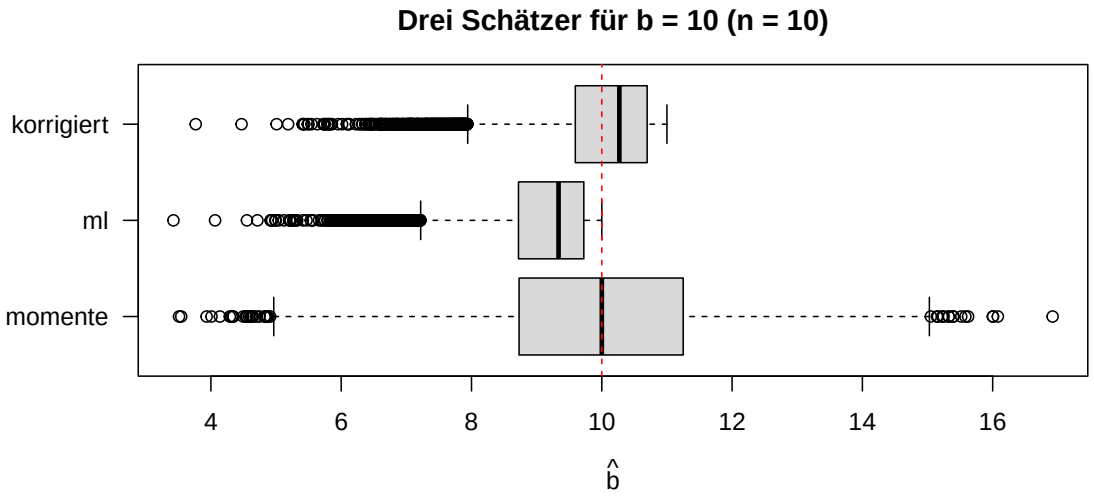
Die Momentenmethode liefert hier etwas anderes: Aus $E(X) = b/2 = \bar{X}$ folgt $\hat{b} = 2\bar{X}$. Welcher Schätzer ist besser? Wir vergleichen per Simulation mit $b = 10$ und $n = 10$ — zusätzlich mit der **korrigierten** Variante $\frac{n+1}{n} \max_i X_i$, die den systematischen Fehler des ML-Schätzers beseitigt:

```
set.seed(8)
b <- 10; n <- 10
est <- replicate(10000, {
  x <- runif(n, 0, b)
  c(momente     = 2 * mean(x),
    ml          = max(x),
    korrigiert  = (n + 1) / n * max(x))
})

round(rbind(mittel = rowMeans(est),
            bias   = rowMeans(est) - b,
            se     = apply(est, 1, sd),
            mse    = rowMeans((est - b)^2)), 3)
#>        momente     ml korrigiert
#> mittel  10.002  9.094     10.004
#> bias     0.002 -0.906      0.004
#> se       1.833  0.834      0.918
```

```
#> mse      3.359  1.516      0.842
```

```
par(mar = c(4, 7, 3, 1))                  # Platz für die Beschriftung links
boxplot(t(est), horizontal = TRUE, col = "grey85", las = 1,
        main = "Drei Schätzer für b = 10 (n = 10)", xlab = expression(hat(b)))
abline(v = b, col = "red", lty = 2)
```




```
par(mar = c(5, 4, 4, 2) + 0.1)            # Standardränder
```

Lesart:

- Der Momentenschätzer ist erwartungstreu, streut aber stark.
- Der ML-Schätzer ist **verzerrt** (er kann b nie überschätzen), hat aber trotzdem einen kleineren MSE.
- Der korrigierte Schätzer ist erwartungstreu *und* hat den kleinsten MSE.

Erwartungstreue allein macht einen Schätzer also nicht gut.

Zwei Parameter: Pareto (Baron, Bsp. 9.10)

Die Log-Likelihood

$$\ell(\sigma, \theta) = n \ln \theta + n\theta \ln \sigma - (\theta + 1) \sum_{i=1}^{n} \ln X_i, \qquad X_i \geq \sigma,$$

wächst in σ; also nimmt man den größten zulässigen Wert $\hat{\sigma} = \min_i X_i$ (wieder ein Randmaximum). Einsetzen und nach θ ableiten ergibt

$$\hat{\theta} = \frac{n}{\sum_{i=1}^{n} \ln(X_i/\hat{\sigma})}.$$

Jetzt vergleichen wir beide Methoden für verschiedene wahre Werte von θ — auch für $\theta = 1{,}5$, bei dem die Varianz nicht existiert:

```
pareto_ml <- function(x) {
  sigma <- min(x)
  c(sigma = sigma, theta = length(x) / sum(log(x / sigma)))
}

set.seed(9)
pareto_vergleich <- sapply(c(4, 2.5, 1.5), function(theta) {
  e <- replicate(2000, {
    x <- rpareto(200, sigma = 1, theta = theta)
    c(pareto_mom(x)["theta"], pareto_ml(x)["theta"])
  })
  c(wahr = theta, momente = mean(e[1, ]), ml = mean(e[2, ]),
    se_momente = sd(e[1, ]), se_ml = sd(e[2, ]))
})
round(pareto_vergleich, 3)
#>             [,1]  [,2]  [,3]
#> wahr       4.000 2.500 1.500
#> momente    4.241 2.885 2.208
#> ml         4.036 2.532 1.511
#> se_momente 0.553 0.345 0.141
#> se_ml      0.295 0.176 0.105
```

Der ML-Schätzer trifft in allen drei Fällen nahezu den wahren Wert und streut etwa halb so stark. Die Momentenmethode ist schon bei $\theta = 4$ verzerrt und versagt bei $\theta = 1{,}5$ vollständig.

Mehrere Parameter numerisch: Gamma mit `optim()`

Für die Gammaverteilung gibt es keine geschlossene Formel für den ML-Schätzer. `optim()` *minimiert* — wir übergeben also die negative Log-Likelihood. Die Momentenschätzer sind gute Startwerte:

```
neg_loglik_gamma <- function(par, x) {
  -sum(dgamma(x, shape = par[1], rate = par[2], log = TRUE))
}

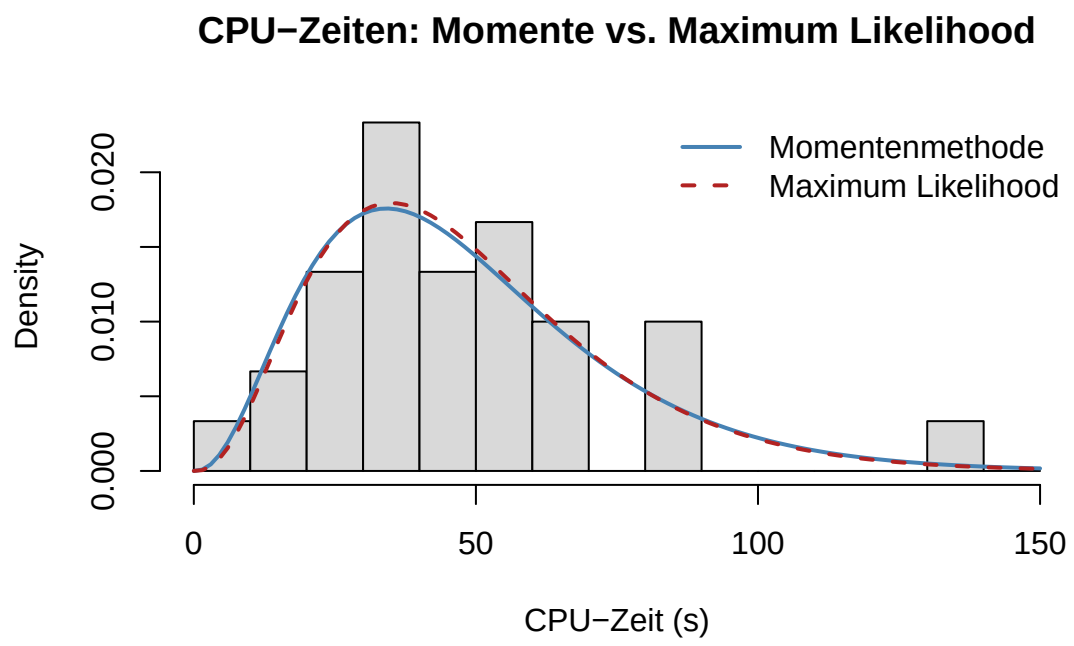
ml_gamma <- optim(par = c(alpha_mom, lambda_mom), fn = neg_loglik_gamma, x = cpu,
```

```
                    method = "L-BFGS-B", lower = c(1e-6, 1e-6), hessian = TRUE)
ml_gamma$par
#> [1] 3.63143089 0.07529265
```

Dasselbe erledigt `MASS::fitdistr()` in einer Zeile — einschließlich der Standardfehler in Klammern (Barons „Computer notes"):

```
library(MASS)
fitdistr(cpu, "gamma")
#>      shape         rate
#>   3.63007913   0.07526080
#>  (0.89719441) (0.01994748)
```

```
hist(cpu, breaks = seq(0, 150, by = 10), freq = FALSE, col = "grey85",
     main = "CPU-Zeiten: Momente vs. Maximum Likelihood", xlab = "CPU-Zeit (s)")
curve(dgamma(x, shape = alpha_mom, rate = lambda_mom),
      add = TRUE, col = "steelblue", lwd = 2)
curve(dgamma(x, shape = ml_gamma$par[1], rate = ml_gamma$par[2]),
      add = TRUE, col = "firebrick", lwd = 2, lty = 2)
legend("topright", c("Momentenmethode", "Maximum Likelihood"),
       col = c("steelblue", "firebrick"), lty = c(1, 2), lwd = 2, bty = "n")
```



`fitdistr()` kennt u. a. `"normal"`, `"exponential"`, `"poisson"`, `"geometric"`, `"gamma"`, `"weibull"`, `"lognormal"` und `"negative binomial"`.

i Momente oder Maximum Likelihood?

	Momentenmethode	Maximum Likelihood
Rechenaufwand	gering, oft geschlossene Formel	oft nur numerisch lösbar
Voraussetzung	Momente müssen existieren	Likelihood muss aufstellbar sein
Güte	manchmal schlecht (Gleichverteilung, Pareto)	für große n meist optimal: konsistent, näherungsweise normalverteilt
Typische Rolle	schnelle Schätzung, Startwert	Standardverfahren

Die Faustregel: ML ist das Standardverfahren, die Momentenmethode liefert die Startwerte.

1.4 Standardfehler von Schätzern

Warum ein Standardfehler?

Ein Schätzwert ohne Angabe seiner Genauigkeit ist wenig wert. Der **Standardfehler** $\sigma(\hat{\theta})$ misst, wie stark der Schätzer von Stichprobe zu Stichprobe schwankt. Das Vorgehen (Baron, §9.1.3):

1. Einen Ausdruck für $\sigma(\hat{\theta})$ herleiten — er hängt meist von unbekannten Parametern ab.
2. Die unbekannten Parameter durch ihre Schätzer ersetzen.

Poisson (Baron, Bsp. 9.11)

Für $\hat{\lambda} = \bar{X}$ gilt $\sigma(\hat{\lambda}) = \sigma/\sqrt{n}$, und bei Poisson ist $\sigma = \sqrt{\lambda}$. Es gibt zwei naheliegende Schätzungen:

$$s_1(\hat{\lambda}) = \sqrt{\frac{\bar{X}}{n}} \quad \text{(nutzt } \sigma^2 = \lambda\text{)}, \qquad s_2(\hat{\lambda}) = \frac{s}{\sqrt{n}} \quad \text{(nutzt nur die Stichprobe)}.$$

```
n <- length(defekte)
c(s1      = sqrt(mean(defekte) / n),
  s2      = sd(defekte) / sqrt(n),
  wahr    = sqrt(2.4 / n))              # nur bekannt, weil wir simuliert haben
```

```
#>        s1        s2      wahr
#> 0.2253886 0.2307220 0.2190890
```

Welche Schätzung ist zuverlässiger? Die Simulation zeigt: Beide treffen im Mittel, aber s_1 schwankt weniger, weil sie die Kenntnis der Verteilungsfamilie ausnutzt.

```
set.seed(10)
se_vergleich <- replicate(10000, {
  x <- rpois(50, lambda = 2.4)
  c(s1 = sqrt(mean(x) / 50), s2 = sd(x) / sqrt(50))
})
round(rbind(mittel = rowMeans(se_vergleich), sd = apply(se_vergleich, 1, sd),
            wahr = sqrt(2.4 / 50)), 4)
#>            s1     s2
#> mittel 0.2188 0.2176
#> sd     0.0100 0.0240
#> wahr   0.2191 0.2191
```

Exponentialverteilung (Baron, Bsp. 9.12)

Für $\hat{\lambda} = 1/\bar{X}$ erhält Baron über die Gammaverteilung von $\sum X_i$ (für $n \geq 3$)

$$E(\hat{\lambda}) = \frac{n\lambda}{n-1}, \qquad \sigma(\hat{\lambda}) = \frac{n\lambda}{(n-1)\sqrt{n-2}}.$$

Zwei Beobachtungen:

- Der ML-Schätzer ist **verzerrt**: Er überschätzt λ um den Faktor $n/(n-1)$. Für großes n verschwindet die Verzerrung.
- Ersetzt man λ durch $\hat{\lambda} = 1/\bar{X}$, erhält man den geschätzten Standardfehler $s(\hat{\lambda}) = \frac{n}{\bar{X}(n-1)\sqrt{n-2}}$.

Hat Baron richtig gerechnet? Wir prüfen beide Formeln mit $n = 10$ und $\lambda = 2$:

```
set.seed(11)
n <- 10; lambda <- 2
lambda_hat <- replicate(20000, 1 / mean(rexp(n, rate = lambda)))

rbind(simulation = c(erwartung = mean(lambda_hat), se = sd(lambda_hat)),
      formel     = c(n * lambda / (n - 1), n * lambda / ((n - 1) * sqrt(n - 2))))
#>            erwartung        se
#> simulation  2.226736 0.7933265
#> formel      2.222222 0.7856742
```

Für die Wartezeiten von oben ($n = 40$):

```
n <- length(wartezeiten)
c(lambda_hat = 1 / mean(wartezeiten),
  se_hat     = n / (mean(wartezeiten) * (n - 1) * sqrt(n - 2)))
#> lambda_hat     se_hat
#>  0.7141439  0.1188199
```

Standardfehler ohne Formel

Schon für etwas kompliziertere Schätzer gibt es oft keine handliche Formel für $\sigma(\hat{\theta})$. Dann gibt es zwei Auswege:

- **Bootstrap** (letzte Vorlesung, Baron §10.3): Mit Zurücklegen aus der Stichprobe ziehen, den Schätzer jedes Mal neu berechnen und die Standardabweichung der Ergebnisse nehmen.
- **Krümmung der Log-Likelihood:** Für ML-Schätzer gilt bei großem n näherungsweise $\sigma(\hat{\theta}) \approx 1/\sqrt{-\ell''(\hat{\theta})}$. Je spitzer das Maximum, desto genauer der Schätzer. Genau so berechnet `fitdistr()` seine Standardfehler; `optim(..., hessian = TRUE)` liefert die Krümmung mit:

```
sqrt(diag(solve(ml_gamma$hessian)))      # Standardfehler von alpha und lambda
#> [1] 0.89719258 0.01994618

set.seed(12)
boot_gamma <- replicate(1000, {
  xb <- sample(cpu, replace = TRUE)
  optim(c(alpha_mom, lambda_mom), neg_loglik_gamma, x = xb,
        method = "L-BFGS-B", lower = c(1e-6, 1e-6))$par
})
apply(boot_gamma, 1, sd)                 # Bootstrap-Standardfehler
#> [1] 1.2253854 0.0282639
```

Beide Wege ergeben Standardfehler in derselben Größenordnung. Bei nur 30 Beobachtungen sind Abweichungen zwischen den Methoden normal.

> **Ausblick: Konfidenzintervalle**
>
> Ein Schätzwert zusammen mit seinem Standardfehler sagt bereits, wie genau geschätzt wurde. In der nächsten Vorlesung machen wir daraus ein **Intervall**, das den wahren Parameter mit vorgegebener Wahrscheinlichkeit überdeckt: $\hat{\theta} \pm z_{\alpha/2}\,\sigma(\hat{\theta})$ (Baron, §9.2).

1.5 Übungsaufgaben

Aufgaben mit Quellenangabe stammen aus Baron, Kapitel 9. Zu jeder Aufgabe gibt es eine aufklappbare Lösung. Versuchen Sie es zuerst selbst — von Hand **und** in R. Die Reiter **Tipp**, **Lösung** und **Erklärung** können Sie einzeln öffnen.

Aufgabe 1: Zwei Werte (Baron, Übung 9.1). Aus einer diskreten Verteilung mit $P(3) = \theta$ und $P(7) = 1 - \theta$ wurde die Stichprobe $3, 3, 3, 3, 3, 7, 7, 7$ gezogen. Bestimmen Sie (a) den Momentenschätzer und (b) den ML-Schätzer von θ und (c) schätzen Sie jeweils den Standardfehler.

Lösung zu Aufgabe 1

1.5.1 Tipp

(a) $E(X) = 3\theta + 7(1-\theta)$ gleich $\bar{X}$ setzen.
(b) Die Likelihood hängt nur davon ab, wie oft die 3 und wie oft die 7 vorkommt: $L(\theta) = \theta^{\#3}(1-\theta)^{\#7}$.
(c) Schreiben Sie den Schätzer als Funktion von $\bar{X}$ und verwenden Sie $\mathrm{Var}(\bar{X}) = \mathrm{Var}(X)/n$.

1.5.2 Lösung

```
x <- c(3, 3, 3, 3, 3, 7, 7, 7)
n <- length(x)

theta_mom <- (7 - mean(x)) / 4           # aus 7 - 4 theta = Xquer
theta_ml  <- mean(x == 3)                # Anteil der Dreien
c(momente = theta_mom, ml = theta_ml)
#> momente      ml
#>   0.625   0.625

loglik <- function(theta) sum(x == 3) * log(theta) + sum(x == 7) * log(1 - theta)
optimize(loglik, c(0.001, 0.999), maximum = TRUE)$maximum   # Kontrolle
#> [1] 0.6249868

c(se_formel     = sqrt(theta_ml * (1 - theta_ml) / n),     # Var(X) = 16 theta (1 - theta)
  se_stichprobe = sd(x) / (4 * sqrt(n)))                   # Var(X) durch s^2 geschätzt
#>     se_formel se_stichprobe
#>     0.1711633     0.1829813
```

1.5.3 Erklärung

(a) $E(X) = 3\theta + 7 - 7\theta = 7 - 4\theta$. Mit $\bar{X} = 36/8 = 4{,}5$ folgt $7 - 4\theta = 4{,}5$, also $\hat{\theta} = 0{,}625$.
(b) $\ell(\theta) = 5\ln\theta + 3\ln(1-\theta)$, $\ell'(\theta) = 5/\theta - 3/(1-\theta) = 0$ ergibt $\hat{\theta} = 5/8 = 0{,}625$ — derselbe Wert. Das ist kein Zufall: Beide Schätzer sind der **Anteil der Dreien** in der Stichprobe.
(c) $\hat{\theta} = (7 - \bar{X})/4$, also $\mathrm{Var}(\hat{\theta}) = \mathrm{Var}(X)/(16n)$. Für eine Zwei-Punkt-Verteilung im Abstand 4 ist $\mathrm{Var}(X) = 16\,\theta(1-\theta)$, also $\sigma(\hat{\theta}) = \sqrt{\theta(1-\theta)/n}$ — der bekannte Standardfehler eines Anteils. Eingesetzt: $\sqrt{0{,}625 \cdot 0{,}375/8} \approx 0{,}171$. Schätzt man $\mathrm{Var}(X)$ stattdessen durch s^2, erhält man 0,183. Wie bei Baron, Bsp. 9.11, sind beide Schätzungen zulässig.

Aufgabe 2: Fehlerfreie Läufe (Baron, Übung 9.2). Die Anzahl der Läufe, bis ein Programm fehlerfrei durchläuft, sei geometrisch verteilt mit unbekanntem p. Für fünf Projekte wurden $3, 7, 5, 3, 2$ Läufe gezählt. Schätzen Sie p mit der Momenten- und der ML-Methode. Vergleichen Sie mit `MASS::fitdistr(x - 1, "geometric")` — warum `x - 1`? (Hinweis: `?dgeom`)

Lösung zu Aufgabe 2

1.5.4 Tipp

Bei Baron zählt die geometrische Verteilung die Versuche **bis einschließlich** des ersten Erfolgs: $P(x) = (1-p)^{x-1}p$ für $x = 1, 2, \ldots$, mit $E(X) = 1/p$. Für die Likelihood brauchen Sie nur $\sum X_i$ und n.

1.5.5 Lösung

```
laeufe <- c(3, 7, 5, 3, 2)
n <- length(laeufe)

c(momente = 1 / mean(laeufe),            # aus 1/p = Xquer
  ml      = n / sum(laeufe))             # aus der Log-Likelihood
#> momente      ml
#>    0.25    0.25

fitdistr(laeufe - 1, "geometric")        # R zählt die Fehlversuche
#>       prob
#>   0.25000000
#>  (0.09682458)
```

1.5.6 Erklärung

Momente: $1/p = \bar{X} = 20/5 = 4$, also $\hat{p} = 0{,}25$.

ML: $L(p) = \prod (1-p)^{X_i - 1} p = p^n (1-p)^{\sum X_i - n}$,

$$\ell'(p) = \frac{n}{p} - \frac{\sum X_i - n}{1-p} = 0 \quad \Longrightarrow \quad \hat{p} = \frac{n}{\sum X_i} = \frac{5}{20} = 0{,}25.$$

Beide Methoden stimmen überein.
Warum `x - 1`? R definiert die geometrische Verteilung über die Anzahl der **Fehlversuche vor** dem ersten Erfolg ($x = 0, 1, 2, \ldots$). Vier Läufe bei Baron sind drei Fehlversuche in R. Solche unterschiedlichen Konventionen (auch bei der Exponential- und Gammaverteilung: Rate oder Skala?) sind eine häufige Fehlerquelle — im Zweifel immer die Hilfeseite lesen. `fitdistr()` liefert zusätzlich den Standardfehler 0,097.

Aufgabe 3: Gleichverteilung (Baron, Übung 9.3a). Bestimmen Sie Momenten- und ML-Schätzer für a und b einer $U(a, b)$-Verteilung. Vergleichen Sie wie oben für $U(0, b)$ Verzerrung und MSE per Simulation für $a = 2$, $b = 5$, $n = 20$.

Lösung zu Aufgabe 3

1.5.7 Tipp

Es gibt zwei Parameter, also zwei Momentengleichungen. Bequem sind $E(X) = (a+b)/2$ und $\mathrm{Var}(X) = (b-a)^2/12$. Für die ML-Methode: Die Likelihood $(b-a)^{-n}$ wird größer, je **kürzer** das Intervall ist — wie kurz darf es höchstens werden?

1.5.8 Lösung

```
schaetze_unif <- function(x) {
  m <- mean(x)
  h <- sqrt(3 * mean((x - m)^2))          # sqrt(3 * m2')
  c(a_mom = m - h, b_mom = m + h, a_ml = min(x), b_ml = max(x))
}

set.seed(1)
wahr <- c(2, 5, 2, 5)
est <- replicate(10000, schaetze_unif(runif(20, min = 2, max = 5)))

round(rbind(bias = rowMeans(est) - wahr,
            se   = apply(est, 1, sd),
            mse  = rowMeans((est - wahr)^2)), 4)
#>       a_mom   b_mom   a_ml    b_ml
#> bias 0.0438 -0.0447 0.1407 -0.1423
#> se   0.2495  0.2445 0.1350  0.1329
#> mse  0.0642  0.0618 0.0380  0.0379
```

1.5.9 Erklärung

Momente: Aus $\frac{a+b}{2} = m_1$ und $\frac{(b-a)^2}{12} = m_2'$ folgt $b - a = \sqrt{12\, m_2'}$ und damit

$$\hat{a} = m_1 - \sqrt{3\, m_2'}, \qquad \hat{b} = m_1 + \sqrt{3\, m_2'}.$$

ML: $L(a, b) = (b - a)^{-n}$, solange $a \le \min X_i$ und $b \ge \max X_i$; sonst ist $L = 0$. Das Maximum liegt am Rand: $\hat{a} = \min X_i$, $\hat{b} = \max X_i$.
Simulation: Die ML-Schätzer sind verzerrt — $\min X_i$ liegt immer über a, $\max X_i$ immer unter b —, streuen aber nur etwa halb so stark. Ihr MSE ist deutlich kleiner (ca. 0,038 gegenüber 0,063). Der Momentenschätzer hat außerdem einen Schönheitsfehler: Er kann $\hat{a} > \min X_i$ liefern, also ein Intervall, in dem eine **beobachtete** Zahl gar nicht liegen dürfte.

Aufgabe 4: Eine Dichte auf $(0, 1)$ (Baron, Übung 9.4). Gegeben sind $X_1 = 0{,}4$, $X_2 = 0{,}7$, $X_3 = 0{,}9$ aus der Dichte $f(x) = \theta x^{\theta-1}$, $0 < x < 1$. Schätzen Sie θ mit beiden Methoden. Kontrollieren Sie den ML-Schätzer mit `optimize()`.

Lösung zu Aufgabe 4

1.5.10 Tipp

$E(X) = \int_0^1 x \cdot \theta x^{\theta-1}\, dx$ lässt sich direkt integrieren. Die Log-Likelihood ist $\ell(\theta) = n \ln \theta + (\theta - 1) \sum \ln X_i$.

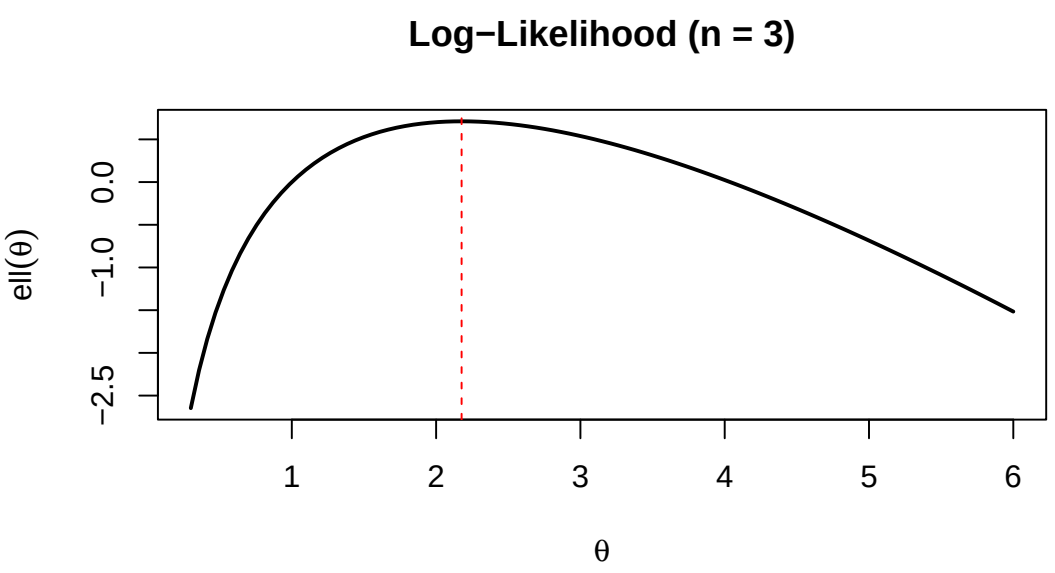
1.5.11 Lösung

```r
x <- c(0.4, 0.7, 0.9)

theta_mom <- mean(x) / (1 - mean(x))
theta_ml  <- -length(x) / sum(log(x))

loglik <- function(theta) sum(log(theta) + (theta - 1) * log(x))
c(momente   = theta_mom,
  ml        = theta_ml,
  optimize  = optimize(loglik, c(0.01, 20), maximum = TRUE)$maximum)
#>  momente       ml optimize
#> 2.000000 2.176553 2.176556
```

```r
curve(sapply(x, loglik), from = 0.3, to = 6, lwd = 2,
      xlab = expression(theta), ylab = expression(ell(theta)),
      main = "Log-Likelihood (n = 3)")
abline(v = theta_ml, col = "red", lty = 2)
```



1.5.12 Erklärung

Momente: $E(X) = \theta \int_0^1 x^\theta \, dx = \frac{\theta}{\theta+1}$. Aus $\frac{\theta}{\theta+1} = \bar{X}$ folgt $\hat{\theta} = \frac{\bar{X}}{1-\bar{X}}$. Mit $\bar{X} = 2/3$: $\hat{\theta} = 2$.
ML: $\ell'(\theta) = n/\theta + \sum \ln X_i = 0$ ergibt

$$\hat{\theta} = -\frac{n}{\sum \ln X_i} = \frac{3}{0{,}916 + 0{,}357 + 0{,}105} \approx 2{,}18.$$

Die beiden Methoden liefern hier verschiedene Werte. Bei nur drei Beobachtungen ist das nicht überraschend; die flache Log-Likelihood zeigt, wie unsicher jede Schätzung bei $n = 3$ ist.

Aufgabe 5: Mischverteilung (Baron, Übung 9.5). Zehn Beobachtungen stammen aus der Dichte $f(x) = \frac{1}{2}\left(\frac{1}{\theta}e^{-x/\theta} + \frac{1}{10}e^{-x/10}\right)$, $x > 0$; ihre Summe ist 150. (a) Schätzen Sie θ mit der Momentenmethode. (b) Schätzen Sie den Standardfehler. (c) Prüfen Sie (b) per Simulation. (Hinweis: Simulieren Sie die Mischung, indem Sie für jede Beobachtung per Münzwurf wählen, aus welcher Exponentialverteilung sie stammt.)

Lösung zu Aufgabe 5

1.5.13 Tipp

Die Dichte ist eine 50:50-Mischung aus einer Exponentialverteilung mit Mittelwert θ und einer mit Mittelwert 10. Erwartungswert und zweites Moment einer Mischung sind die

Mittelwerte der Komponenten: $E(X) = \frac{1}{2}(\theta + 10)$ und $E(X^2) = \frac{1}{2}(2\theta^2 + 2 \cdot 10^2)$.

1.5.14 Lösung

```
n <- 10; summe <- 150
theta_hat <- 2 * summe / n - 10          # aus (theta + 10)/2 = Xquer

var_x <- function(theta) theta^2 + 100 - (theta + 10)^2 / 4
se_hat <- sqrt(4 * var_x(theta_hat) / n) # Var(2 Xquer - 10) = 4 Var(X) / n
c(theta_hat = theta_hat, se_hat = se_hat)
#> theta_hat    se_hat
#>  20.00000  10.48809

r_mischung <- function(n, theta) {
  komponente <- rbinom(n, size = 1, prob = 0.5)          # Münzwurf
  ifelse(komponente == 1, rexp(n, rate = 1 / theta), rexp(n, rate = 1 / 10))
}

set.seed(2)
sim <- replicate(20000, 2 * mean(r_mischung(n, theta = theta_hat)) - 10)
c(mittel = mean(sim), se_simulation = sd(sim))
#>        mittel se_simulation
#>      20.17561      10.57115
```

1.5.15 Erklärung

(a) $E(X) = \frac{\theta+10}{2} = \bar{X} = 15$, also $\hat{\theta} = 2\bar{X} - 10 = 20$.
(b) $\hat{\theta} = 2\bar{X} - 10$ hat die Varianz $4\,\mathrm{Var}(X)/n$. Für die Mischung ist $E(X^2) = \theta^2 + 100$ und damit

$$\mathrm{Var}(X) = \theta^2 + 100 - \left(\frac{\theta + 10}{2}\right)^2.$$

Bei $\hat{\theta} = 20$: $\mathrm{Var}(X) = 500 - 225 = 275$ und $s(\hat{\theta}) = \sqrt{4 \cdot 275/10} = \sqrt{110} \approx 10{,}5$.
(c) Die Simulation (mit $\theta = 20$ als wahrem Wert) bestätigt einen Standardfehler von etwa 10,5. Ein Standardfehler von über 50 % des Schätzwerts zeigt: Mit zehn Beobachtungen aus einer so breiten Mischung ist θ kaum zu bestimmen.

Aufgabe 6: ML-Schätzer der Exponentialverteilung korrigieren. Nach Bsp. 9.12 ist $E(1/\bar{X}) = n\lambda/(n-1)$. Konstruieren Sie daraus einen erwartungstreuen Schätzer für λ und vergleichen Sie dessen MSE per Simulation mit dem des ML-Schätzers für $n = 5$ und $n = 50$.

Lösung zu Aufgabe 6

1.5.16 Tipp

Multiplizieren Sie $1/\bar{X}$ mit einem Faktor, der die Verzerrung genau aufhebt. Für die Theorie: Der korrigierte Schätzer ist ein Vielfaches $c \cdot \hat{\lambda}$, also ist seine Varianz $c^2 \operatorname{Var}(\hat{\lambda})$; $\operatorname{Var}(\hat{\lambda})$ steht in Bsp. 9.12.

1.5.17 Lösung

```
set.seed(4)
lambda <- 1
vergleich <- sapply(c(n_5 = 5, n_50 = 50), function(n) {
  est <- replicate(20000, {
    x <- rexp(n, rate = lambda)
    c(ml = 1 / mean(x), erwartungstreu = (n - 1) / sum(x))
  })
  c(mse_ml         = mean((est["ml", ] - lambda)^2),
    mse_et         = mean((est["erwartungstreu", ] - lambda)^2),
    theorie_ml     = n^2 / ((n - 1)^2 * (n - 2)) + 1 / (n - 1)^2,
    theorie_et     = 1 / (n - 2))
})
round(vergleich, 4)
#>               n_5   n_50
#> mse_ml     0.5829 0.0223
#> mse_et     0.3344 0.0209
#> theorie_ml 0.5833 0.0221
#> theorie_et 0.3333 0.0208
```

1.5.18 Erklärung

Aus $E(1/\bar{X}) = \frac{n}{n-1}\lambda$ folgt, dass

$$\tilde{\lambda} = \frac{n-1}{n} \cdot \frac{1}{\bar{X}} = \frac{n-1}{\sum X_i}$$

erwartungstreu ist. Seine Varianz ist $\left(\frac{n-1}{n}\right)^2 \operatorname{Var}(\hat{\lambda}) = \frac{\lambda^2}{n-2}$, und das ist zugleich sein MSE. Der ML-Schätzer hat $\text{MSE} = \text{Var} + \text{Bias}^2 = \frac{n^2\lambda^2}{(n-1)^2(n-2)} + \frac{\lambda^2}{(n-1)^2}$.
Bei $n = 5$ ist der korrigierte Schätzer klar besser (MSE 0,33 statt 0,58) — hier gewinnt er doppelt, weil er auch weniger streut. Bei $n = 50$ ist der Unterschied nur noch klein: Die Verzerrung von $1/\bar{X}$ verschwindet mit wachsendem n, der ML-Schätzer ist *asymptotisch* erwartungstreu.

Zum Weiterdenken: Den kleinsten MSE unter allen Schätzern der Form $c/\sum X_i$ hat $c = n - 2$ — wieder ein verzerrter Schätzer.

Aufgabe 7: Weibull mit `optim()`. Simulieren Sie 100 Werte aus `rweibull(n, shape = 1.5, scale = 2)`. Schätzen Sie beide Parameter mit `optim()` über die negative Log-Likelihood, vergleichen Sie mit `fitdistr(x, "weibull")` und zeichnen Sie die angepasste Dichte über das Histogramm.

Lösung zu Aufgabe 7

1.5.19 Tipp

Gehen Sie vor wie bei der Gammaverteilung in der Vorlesung: `dweibull(x, shape, scale, log = TRUE)` aufsummieren, das Vorzeichen umdrehen und mit `method = "L-BFGS-B"` sowie positiven unteren Grenzen minimieren. Als Startwerte genügt `c(1, 1)`.

1.5.20 Lösung

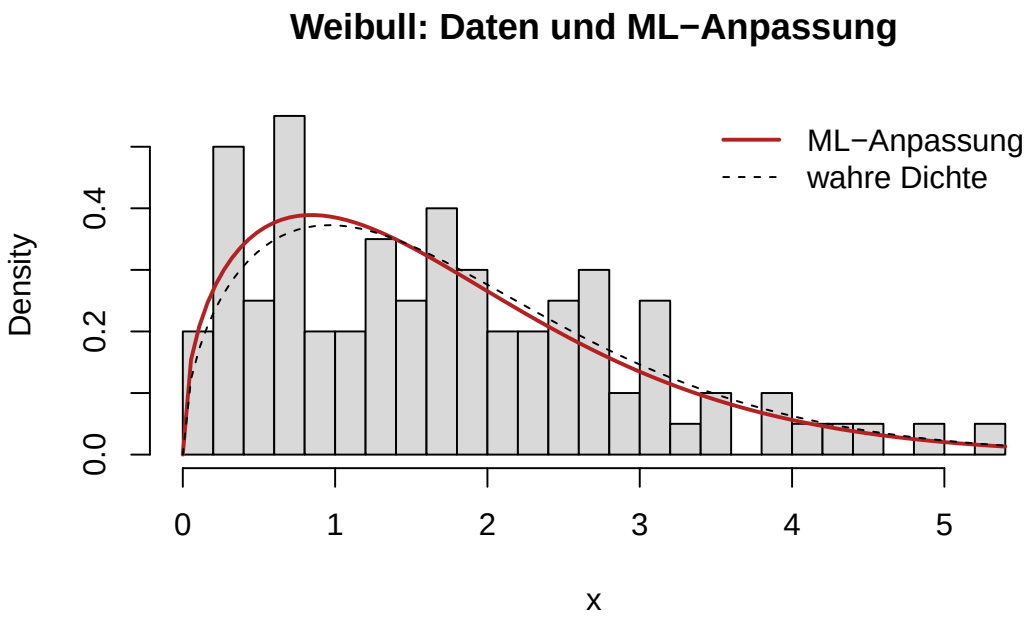
```
set.seed(5)
x <- rweibull(100, shape = 1.5, scale = 2)

neg_loglik_weibull <- function(par, x) {
  -sum(dweibull(x, shape = par[1], scale = par[2], log = TRUE))
}

fit <- optim(c(1, 1), neg_loglik_weibull, x = x, method = "L-BFGS-B",
             lower = c(1e-6, 1e-6), hessian = TRUE)
rbind(schaetzung = fit$par, se = sqrt(diag(solve(fit$hessian))))
#>                 [,1]      [,2]
#> schaetzung 1.447004 1.8995217
#> se         0.115816 0.1381495

fitdistr(x, "weibull")
#>      shape       scale
#>   1.4470053   1.8995302
#>  (0.1158160) (0.1381503)
```

```r
hist(x, breaks = 20, freq = FALSE, col = "grey85",
     main = "Weibull: Daten und ML-Anpassung", xlab = "x")
curve(dweibull(x, shape = fit$par[1], scale = fit$par[2]),
      add = TRUE, col = "firebrick", lwd = 2)
curve(dweibull(x, shape = 1.5, scale = 2), add = TRUE, lty = 2)
legend("topright", c("ML-Anpassung", "wahre Dichte"), col = c("firebrick", "black"),
       lty = c(1, 2), lwd = c(2, 1), bty = "n")
```



1.5.21 Erklärung

`optim()` und `fitdistr()` liefern dieselben Schätzwerte (Formparameter etwa 1,45, Skalenparameter etwa 1,90) und praktisch dieselben Standardfehler: `fitdistr()` macht intern genau das — es maximiert die Log-Likelihood numerisch und berechnet die Standardfehler aus der Krümmung (Hesse-Matrix).
Die wahren Werte 1,5 und 2 liegen jeweils weniger als einen Standardfehler von der Schätzung entfernt; die angepasste Dichte ist von der wahren kaum zu unterscheiden. Bei der Weibullverteilung gibt es für den Formparameter keine geschlossene ML-Formel — hier ist die numerische Optimierung der einzige Weg.

1.6 Das Minimum, das Sie ohne Hilfe beherrschen sollten

Begriffe — Parameter, Schätzer, Schätzwert, Stichprobenverteilung, Verzerrung (Bias), erwartungstreu, Standardfehler, MSE, Konsistenz, Moment, zentrales Moment, Momentenmethode, Likelihood, Log-Likelihood, ML-Schätzer, Randmaximum.

Formeln

Begriff	Formel
Mittlerer quadratischer Fehler	$\mathrm{MSE}(\hat{\theta}) = \mathrm{Bias}^2 + \mathrm{Var}(\hat{\theta})$
Momentenmethode	$\mu_k(\theta) = m_k$ für \$k = 1, ..., \$ Anzahl Parameter
Log-Likelihood	$\ell(\theta) = \sum_{i=1}^{n} \ln f(X_i \mid \theta)$
ML-Schätzer	$\ell'(\hat{\theta}) = 0$ — oder Maximum am Rand
Standardfehler des Mittelwerts	$\sigma(\bar{X}) = \sigma/\sqrt{n}$

R — `mean()`, `var()`, `sd()`, `dpois(..., log = TRUE)` und die übrigen Dichten mit `log = TRUE`, `optimize(..., maximum = TRUE)`, `optim(..., hessian = TRUE)`, `solve()`, `MASS::fitdistr()`, `replicate()`, `rowMeans()`, `apply()`.

Achtung:

1. **Parameter und Schätzwert verwechseln.** $\bar{x} = 6{,}5$ ist eine Schätzung von μ, nicht μ selbst.
2. **Momente verwechseln.** Gewöhnliches Moment $\frac{1}{n}\sum X_i^2$ und zentrales Moment $\frac{1}{n}\sum (X_i - \bar{X})^2$ sind verschieden — prüfen Sie, welches die Formel verlangt.
3. **`var()` als m_2' verwenden.** `var()` teilt durch $n-1$, das zweite zentrale Stichprobenmoment durch n.
4. **Likelihood statt Log-Likelihood berechnen.** Das Produkt unterläuft schon bei moderatem n zu 0; immer `log = TRUE` und `sum()` verwenden.
5. **`optim()` maximieren lassen.** `optim()` minimiert — übergeben Sie die **negative** Log-Likelihood.
6. **Nur nach Nullstellen der Ableitung suchen.** Das Maximum kann am Rand liegen (Gleichverteilung, Pareto).
7. **Erwartungstreue überbewerten.** Ein leicht verzerrter Schätzer mit kleinem Standardfehler kann einen kleineren MSE haben.
8. **Konventionen nicht prüfen.** `dgeom()` zählt Fehlversuche, nicht Versuche; `dexp()` und `dgamma()` verwenden die Rate, andere Programme oft die Skala. Im Zweifel die Hilfeseite lesen.