INF712 - Computerunterstützte Statistik

26-27 WS

11/10/2026

Inhaltsverzeichnis

1 Vorlesung 05: Konfidenzintervalle **2**

1.1 **Rückblick: Schätzer und Standardfehler** . . . 2
1.2 **Konfidenzintervalle: Idee und Konstruktion** . . . 3
1.3 **Konfidenzintervall für einen Mittelwert (σ bekannt)** . . . 7
1.4 **Konfidenzintervall für die Differenz zweier Mittelwerte** . . . 9
1.5 **Wahl des Stichprobenumfangs** . . . 11
1.6 **Übungsaufgaben** . . . 13
1.6.1 Tipp . . . 13
1.6.2 Lösung . . . 13
1.6.3 Erklärung . . . 13
1.6.4 Tipp . . . 14
1.6.5 Lösung . . . 14
1.6.6 Erklärung . . . 15
1.6.7 Tipp . . . 15
1.6.8 Lösung . . . 15
1.6.9 Erklärung . . . 15
1.6.10 Tipp . . . 16
1.6.11 Lösung . . . 16
1.6.12 Erklärung . . . 16
1.6.13 Tipp . . . 16
1.6.14 Lösung . . . 17
1.6.15 Erklärung . . . 17
1.7 **Das Minimum, das Sie ohne Hilfe beherrschen sollten** . . . 18

1 Vorlesung 05: Konfidenzintervalle

Definition und Interpretation, allgemeine Konstruktion, Konfidenzintervalle für einen Mittelwert und für die Differenz zweier Mittelwerte, Wahl des Stichprobenumfangs (Baron, §9.2).

Lernziele

Nach dieser Vorlesung können Sie

- erklären, was ein Konfidenzniveau aussagt — und was nicht,
- aus einem erwartungstreuen, normalverteilten Schätzer ein Konfidenzintervall konstruieren,
- Konfidenzintervalle für einen Mittelwert und für die Differenz zweier Mittelwerte berechnen,
- per Simulation prüfen, ob ein Intervallverfahren sein Konfidenzniveau tatsächlich einhält,
- den Stichprobenumfang bestimmen, der eine vorgegebene Genauigkeit garantiert.

1.1 Rückblick: Schätzer und Standardfehler

In der letzten Vorlesung haben wir Parameter **geschätzt**. Drei Punkte daraus brauchen wir heute:

- Ein Schätzer $\hat{\theta}$ ist eine **Zufallsvariable** — jede Stichprobe liefert einen anderen Wert.
- **Erwartungstreu** heißt $E(\hat{\theta}) = \theta$: Der Schätzer liegt im Mittel richtig.
- Der **Standardfehler** $\sigma(\hat{\theta})$ misst, wie stark er um θ schwankt.

Für den Stichprobenmittelwert gilt $E(\bar{X}) = \mu$ und $\sigma(\bar{X}) = \sigma/\sqrt{n}$; nach dem zentralen Grenzwertsatz ist $\bar{X}$ für großes n näherungsweise normalverteilt. Eine kurze Simulation mit $\mu = 50$, $\sigma = 8$ und $n = 25$ zeigt, was daraus folgt:

```
set.seed(1)
mu <- 50; sigma <- 8; n <- 25
xq <- replicate(10000, mean(rnorm(n, mu, sigma)))

c(mittel = mean(xq), sd = sd(xq), theorie_se = sigma / sqrt(n))
#>     mittel         sd theorie_se
#>  49.990819   1.590205   1.600000
mean(abs(xq - mu) <= 1.96 * sigma / sqrt(n))   # Anteil innerhalb von 1.96 SE
#> [1] 0.9502
```

In rund 95 % der Stichproben liegt $\bar{X}$ höchstens $1{,}96\,\sigma/\sqrt{n}$ von μ entfernt. Dann liegt umgekehrt auch μ höchstens $1{,}96\,\sigma/\sqrt{n}$ von $\bar{X}$ entfernt — und genau das ist ein Konfidenzintervall. Diese Umkehrung ist die ganze Idee der heutigen Vorlesung.

1.2 Konfidenzintervalle: Idee und Konstruktion

Von der Punktschätzung zum Intervall

Ein Schätzwert $\hat{\theta}$ ist fast sicher **nicht** gleich θ. Statt einer einzelnen Zahl geben wir deshalb ein Intervall an, das den Parameter mit hoher, bekannter Wahrscheinlichkeit enthält.

> **Definition (Baron 9.4).** Ein Intervall $[a, b]$ ist ein $(1-\alpha)100\,\%$-**Konfidenzintervall** für θ, wenn
>
> $$P(a \leq \theta \leq b) = 1 - \alpha.$$
>
> $1 - \alpha$ heißt **Konfidenzniveau** (Überdeckungswahrscheinlichkeit).

Was ist hier zufällig?

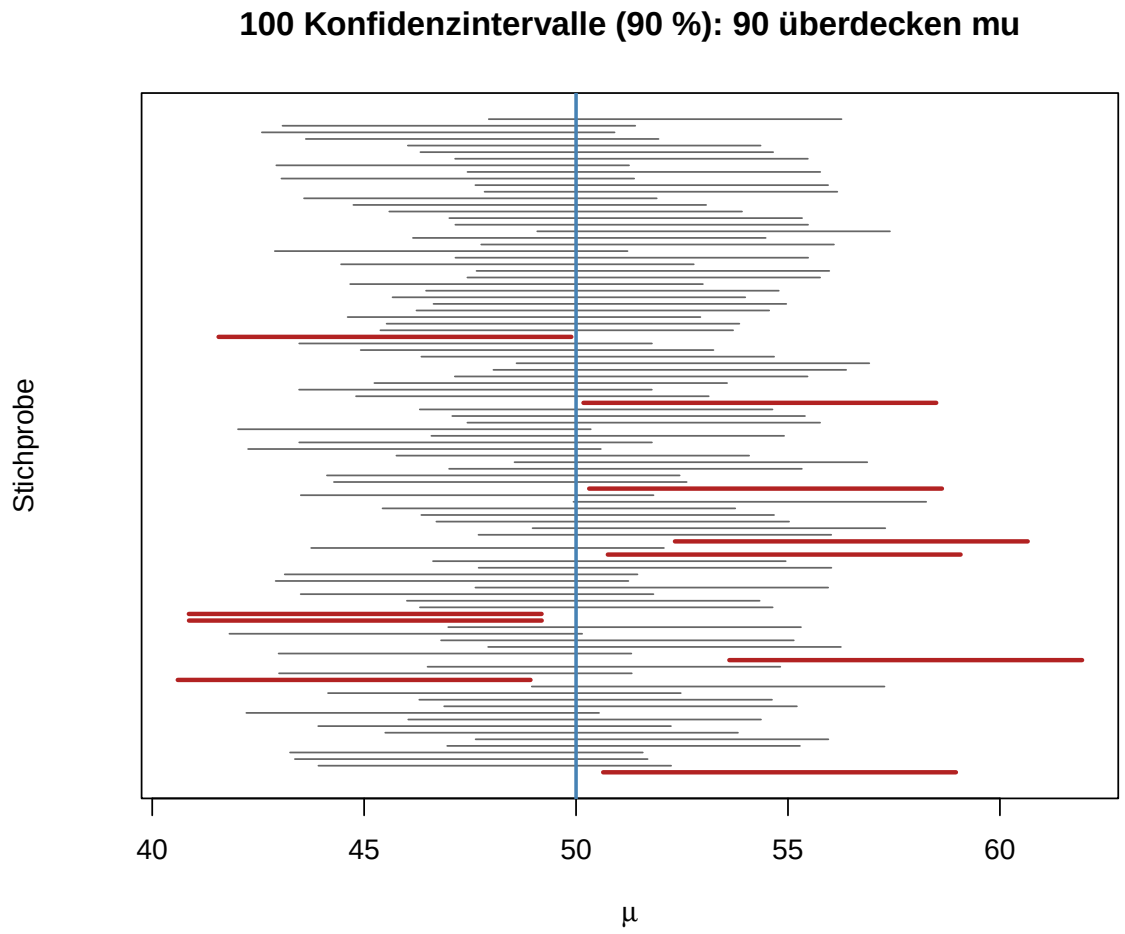
Der Parameter θ ist **fest** — eine Eigenschaft der Population. Zufällig sind die **Intervallgrenzen** a und b, denn sie werden aus der zufälligen Stichprobe berechnet. Das Konfidenzniveau ist also eine Aussage über das **Verfahren**: Wiederholt man die Datenerhebung sehr oft, überdecken $(1-\alpha)100\,\%$ der Intervalle den wahren Wert.

Das ist Barons Abbildung 9.2 — als Simulation mit 100 Stichproben ($n = 10$, $\mu = 50$, $\sigma = 8$) und 90-%-Intervallen:

```
set.seed(13)
mu <- 50; sigma <- 8; n <- 10; niveau <- 0.90
z <- qnorm(1 - (1 - niveau) / 2)

grenzen <- t(replicate(100, {
  xq <- mean(rnorm(n, mu, sigma))
  c(unten = xq - z * sigma / sqrt(n), oben = xq + z * sigma / sqrt(n))
}))
trifft <- grenzen[, "unten"] <= mu & mu <= grenzen[, "oben"]

plot(NA, xlim = range(grenzen), ylim = c(1, 100), yaxt = "n",
     xlab = expression(mu), ylab = "Stichprobe",
     main = sprintf("100 Konfidenzintervalle (90 %%): %d überdecken mu", sum(trifft)))
segments(grenzen[, "unten"], 1:100, grenzen[, "oben"], 1:100,
         col = ifelse(trifft, "grey40", "firebrick"), lwd = ifelse(trifft, 1, 2.5))
abline(v = mu, col = "steelblue", lwd = 2)
```



Die roten Intervalle verfehlen μ — nicht wegen eines Fehlers, sondern allein durch den Stichprobenzufall.

> ⚠ Die häufigste Fehlinterpretation
>
> **Falsch:** „Ich habe das 90-%-Intervall $[3, 6]$ berechnet; der Parameter liegt mit 90 % Wahrscheinlichkeit darin."
> Nach der Berechnung ist nichts mehr zufällig: θ liegt entweder in $[3, 6]$ oder nicht. **Richtig:** „Das Verfahren liefert Intervalle, die in 90 % aller Stichproben den wahren Wert enthalten."
> Die 90 % beschreiben die **Methode**, nicht dieses eine Intervall.

Die allgemeine Konstruktion (Baron, §9.2.1)

Ist $\hat{\theta}$ **erwartungstreu** und **normalverteilt**, dann ist

$$Z = \frac{\hat{\theta} - \theta}{\sigma(\hat{\theta})} \sim N(0, 1).$$

Z liegt mit Wahrscheinlichkeit $1 - \alpha$ zwischen den Quantilen $-z_{\alpha/2}$ und $z_{\alpha/2}$, wobei $z_{\alpha/2} = \Phi^{-1}(1 - \alpha/2)$ der Wert ist, der mit Wahrscheinlichkeit $\alpha/2$ überschritten wird:

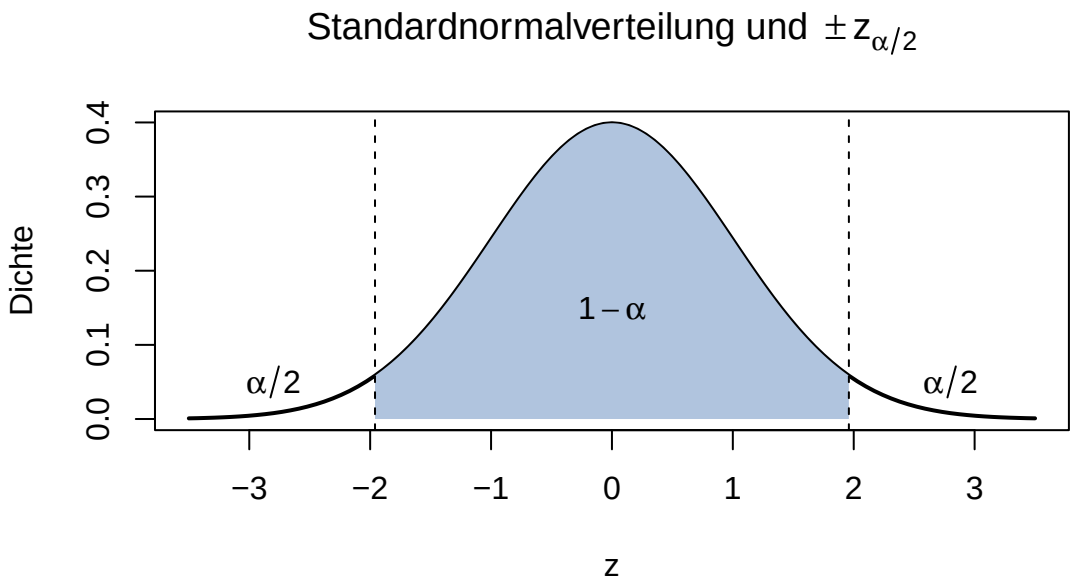
$$P\left(-z_{\alpha/2} \leq \frac{\hat{\theta} - \theta}{\sigma(\hat{\theta})} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

Auflösen der Ungleichungen nach θ ergibt die zentrale Formel

$$\boxed{\hat{\theta} \pm z_{\alpha/2} \cdot \sigma(\hat{\theta})} \qquad \text{(Baron, 9.3)}$$

Man nennt $\hat{\theta}$ den **Mittelpunkt** und $z_{\alpha/2} \cdot \sigma(\hat{\theta})$ die **Fehlermarge** (*margin of error*), wie sie bei Umfragen berichtet wird. Ist $\hat{\theta}$ nur näherungsweise normalverteilt, ist auch das Intervall nur näherungsweise ein $(1 - \alpha)100\,\%$-Intervall.

```r
alpha <- 0.05
z <- qnorm(1 - alpha / 2)
curve(dnorm(x), from = -3.5, to = 3.5, lwd = 2, xlab = "z", ylab = "Dichte",
      main = expression("Standardnormalverteilung und " %+-% z[alpha/2]))
xs <- seq(-z, z, length.out = 200)
polygon(c(-z, xs, z), c(0, dnorm(xs), 0), col = "lightsteelblue", border = NA)
abline(v = c(-z, z), lty = 2)
text(0, 0.15, expression(1 - alpha))
text(c(-2.8, 2.8), 0.05, expression(alpha / 2))
```



Quantile in R statt Tabelle

Die Quantile aus Barons Tabelle A4 liefert `qnorm()`:

```
niveaus <- c(0.80, 0.90, 0.95, 0.98, 0.99)
data.frame(niveau = niveaus, alpha = 1 - niveaus,
           z = round(qnorm(1 - (1 - niveaus) / 2), 3))
#>   niveau alpha     z
#> 1   0.80  0.20 1.282
#> 2   0.90  0.10 1.645
#> 3   0.95  0.05 1.960
#> 4   0.98  0.02 2.326
#> 5   0.99  0.01 2.576
```

Merken sollte man sich $z_{0{,}05} = 1{,}645$ (90 %), $z_{0{,}025} = 1{,}960$ (95 %) und $z_{0{,}005} = 2{,}576$ (99 %).

Rezept (Baron, §9.2.1)

(a) Einen erwartungstreuen Schätzer $\hat{\theta}$ finden.
(b) Prüfen, ob er (näherungsweise) normalverteilt ist.
(c) Seinen Standardfehler $\sigma(\hat{\theta})$ bestimmen.
(d) Das Quantil $z_{\alpha/2}$ bestimmen (`qnorm(1 - alpha/2)`).
(e) $\hat{\theta} \pm z_{\alpha/2}\,\sigma(\hat{\theta})$ berechnen.

1.3 Konfidenzintervall für einen Mittelwert (σ bekannt)

Für $\theta = \mu$ ist $\hat{\theta} = \bar{X}$ erwartungstreu mit $\sigma(\bar{X}) = \sigma/\sqrt{n}$. Normalverteilt ist $\bar{X}$ in zwei Fällen:

1. Die Daten sind normalverteilt — dann ist $\bar{X}$ exakt normal.
2. Der Stichprobenumfang n ist groß — dann ist $\bar{X}$ nach dem zentralen Grenzwertsatz näherungsweise normal.

$$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \qquad \text{(Baron, 9.5)}$$

```
ki_mittelwert <- function(x, sigma, niveau = 0.95) {
  z <- qnorm(1 - (1 - niveau) / 2)
  marge <- z * sigma / sqrt(length(x))
  c(mittelwert = mean(x), marge = marge,
    unten = mean(x) - marge, oben = mean(x) + marge)
}
```

Beispiel (Baron, Bsp. 9.13). Messungen 2,5; 7,4; 8,0; 4,5; 7,4; 9,2 mit normalverteilten Messfehlern; das Messgerät garantiert $\sigma = 2{,}2$. Gesucht ist ein 95-%-Konfidenzintervall für μ.

```
messung <- c(2.5, 7.4, 8.0, 4.5, 7.4, 9.2)
round(ki_mittelwert(messung, sigma = 2.2, niveau = 0.95), 2)
#> mittelwert      marge      unten       oben
#>       6.50       1.76       4.74       8.26
```

Ergebnis: $6{,}50 \pm 1{,}76$, also $[4{,}74;\ 8{,}26]$ — wie bei Baron.

Hält das Verfahren sein Versprechen?

Wir prüfen die Überdeckung per Simulation. Bei normalverteilten Daten sollte sie für **jedes** n bei 95 % liegen:

```
ueberdeckung <- function(zufall, mu, sigma, n, R = 10000, niveau = 0.95) {
  z <- qnorm(1 - (1 - niveau) / 2)
  treffer <- replicate(R, {
    xq <- mean(zufall(n))
    abs(xq - mu) <= z * sigma / sqrt(n)
  })
  mean(treffer)
}

set.seed(14)
```

```
sapply(c(n_3 = 3, n_10 = 10, n_50 = 50),
       function(n) ueberdeckung(function(k) rnorm(k, 6.5, 2.2), 6.5, 2.2, n))
#>    n_3   n_10   n_50
#> 0.9532 0.9521 0.9504
```

Und bei nicht normalverteilten Daten?

Baron warnt: Für kleine Stichproben aus nicht normalverteilten Populationen gilt die Formel nicht. Wie äußert sich das? Wir verwenden stark schiefe exponentialverteilte Daten ($\mu = \sigma = 1$) und zählen getrennt, wie oft das Intervall **zu hoch** bzw. **zu tief** liegt:

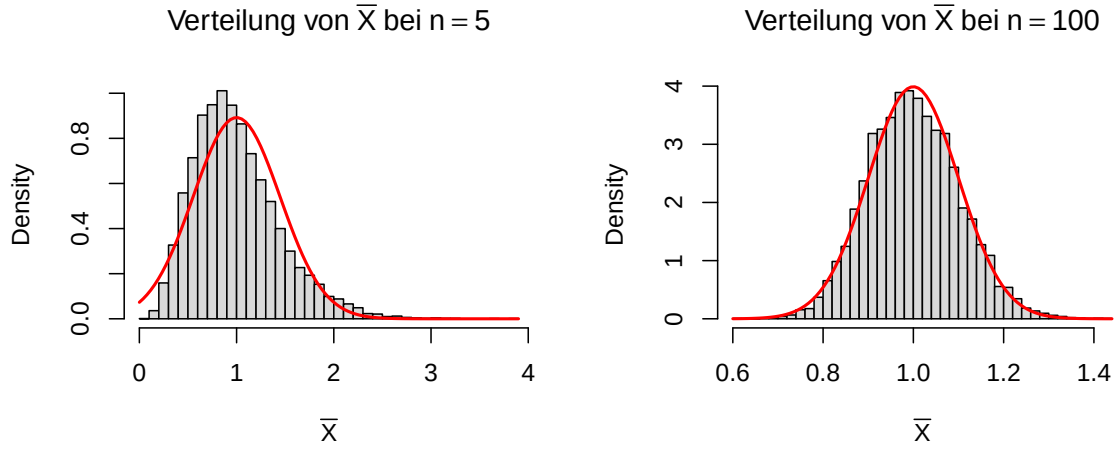
```
fehlerseiten <- function(n, R = 20000, niveau = 0.95) {
  z <- qnorm(1 - (1 - niveau) / 2)
  r <- replicate(R, {
    xq <- mean(rexp(n, rate = 1))
    marge <- z * 1 / sqrt(n)
    c(zu_hoch = xq - marge > 1, zu_tief = xq + marge < 1)
  })
  c(ueberdeckung = 1 - mean(colSums(r) > 0),
    zu_hoch = mean(r["zu_hoch", ]), zu_tief = mean(r["zu_tief", ]))
}

set.seed(15)
round(t(sapply(c(n_5 = 5, n_10 = 10, n_30 = 30, n_100 = 100, n_1000 = 1000),
               fehlerseiten)), 4)
#>        ueberdeckung zu_hoch zu_tief
#> n_5          0.9580  0.0412  0.0008
#> n_10         0.9550  0.0398  0.0052
#> n_30         0.9504  0.0346  0.0150
#> n_100        0.9530  0.0287  0.0184
#> n_1000       0.9514  0.0261  0.0226
```

Die **Gesamtüberdeckung** liegt erstaunlich nah bei 95 % — aber die Fehler sind **einseitig**: Bei $n = 5$ liegt das Intervall in rund 4 % der Fälle zu hoch und fast nie zu tief. Erst bei großem n verteilen sich die Fehler gleichmäßig auf beide Seiten, so wie es bei einem symmetrischen Intervall sein soll. Wer aus einem solchen Intervall einseitige Schlüsse zieht (z. B. „μ ist höchstens …“), irrt sich viel häufiger als in 2,5 % der Fälle.

```
set.seed(16)
par(mfrow = c(1, 2))
for (n in c(5, 100)) {
  xq <- replicate(10000, mean(rexp(n)))
```

```r
  hist(xq, breaks = 50, freq = FALSE, col = "grey85",
       main = bquote("Verteilung von" ~ bar(X) ~ "bei" ~ n == .(n)),
       xlab = expression(bar(X)))
  curve(dnorm(x, 1, 1 / sqrt(n)), add = TRUE, col = "red", lwd = 2)
}
```




```r
par(mfrow = c(1, 1))
```

1.4 Konfidenzintervall für die Differenz zweier Mittelwerte

Oft vergleicht man zwei Populationen: zwei Server, zwei Algorithmen, zwei Konfigurationen, vor und nach einem Update. Aus jeder Population wird **unabhängig** eine Stichprobe gezogen, $X_1, \ldots, X_n$ und $Y_1, \ldots, Y_m$. Gesucht ist ein Konfidenzintervall für $\theta = \mu_X - \mu_Y$. Wir folgen dem Rezept:

(a) Schätzer: $\hat{\theta} = \bar{X} - \bar{Y}$.
(b) Erwartungstreu: $E(\bar{X} - \bar{Y}) = \mu_X - \mu_Y$.
(c) Normalverteilt, wenn beide Populationen normal sind oder beide Stichproben groß sind.
(d) Wegen der Unabhängigkeit addieren sich die Varianzen: $\sigma(\hat{\theta}) = \sqrt{\sigma_X^2/n + \sigma_Y^2/m}$.
(e) Damit:

$$\bar{X} - \bar{Y} \pm z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \qquad \text{(Baron, 9.6)}$$

> **!** Varianzen addieren sich — auch bei einer Differenz
>
> $\mathrm{Var}(\bar{X} - \bar{Y}) = \mathrm{Var}(\bar{X}) + \mathrm{Var}(\bar{Y})$, nicht die Differenz der Varianzen. Die Unsicherheit beider Stichproben kommt zusammen.

```r
ki_differenz <- function(xq, yq, sigma_x, sigma_y, n, m, niveau = 0.95) {
  z <- qnorm(1 - (1 - niveau) / 2)
  marge <- z * sqrt(sigma_x^2 / n + sigma_y^2 / m)
  c(differenz = xq - yq, marge = marge,
    unten = xq - yq - marge, oben = xq - yq + marge)
}
```

Beispiel (Baron, Bsp. 9.14): Wirkung eines Hardware-Upgrades. Ein Prozess läuft 50-mal vor und 50-mal nach einem Upgrade. Die mittlere Laufzeit beträgt 8,5 Minuten vorher und 7,2 Minuten nachher; die Standardabweichung ist aus Erfahrung $\sigma = 1{,}8$ Minuten (in beiden Fällen). Gesucht ist ein 90-%-Konfidenzintervall für die Verkürzung der mittleren Laufzeit.

```r
round(ki_differenz(xq = 8.5, yq = 7.2, sigma_x = 1.8, sigma_y = 1.8,
                   n = 50, m = 50, niveau = 0.90), 2)
#> differenz     marge     unten      oben
#>      1.30      0.59      0.71      1.89
```

Das Upgrade verkürzt die mittlere Laufzeit um 1,3 Minuten, mit einer 90-%-Fehlermarge von 0,6 Minuten: [0,7; 1,9]. Da das Intervall die 0 nicht enthält, ist eine echte Verbesserung plausibel.

Die Laufzeiten müssen dafür nicht normalverteilt sein — bei $n = m = 50$ sorgt der zentrale Grenzwertsatz für die Normalität von $\bar{X} - \bar{Y}$. Eine Simulation mit schiefen (gammaverteilten) Laufzeiten bestätigt das:

```r
set.seed(17)
# Gammaverteilte Laufzeiten mit Mittelwert 8.5 bzw. 7.2 und sd 1.8
r_lauf <- function(n, mu, sd) rgamma(n, shape = (mu / sd)^2, rate = mu / sd^2)

treffer <- replicate(10000, {
  vorher  <- r_lauf(50, 8.5, 1.8)
  nachher <- r_lauf(50, 7.2, 1.8)
  ki <- ki_differenz(mean(vorher), mean(nachher), 1.8, 1.8, 50, 50, niveau = 0.90)
  ki["unten"] <= 1.3 & 1.3 <= ki["oben"]
})
mean(treffer)                              # Ziel: 0.90
#> [1] 0.9016
```

1.5 Wahl des Stichprobenumfangs

Jedes Konfidenzintervall dieser Vorlesung hat die Form **Mittelpunkt ± Marge**. Damit lässt sich die Frage umdrehen: *Wie groß muss die Stichprobe sein, damit die Marge höchstens* Δ *beträgt?* Für den Mittelwert ist

$$z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le \Delta \quad \Longleftrightarrow \quad n \ge \left(\frac{z_{\alpha/2}\,\sigma}{\Delta}\right)^2 \qquad \text{(Baron, 9.8)}$$

Das Ergebnis wird **immer aufgerundet** — beim Abrunden wäre die Marge größer als Δ.

```
n_benoetigt <- function(sigma, delta, niveau = 0.95) {
  z <- qnorm(1 - (1 - niveau) / 2)
  ceiling((z * sigma / delta)^2)
}
```

Beispiel (Baron, Bsp. 9.15). Das Intervall aus Bsp. 9.13 hatte die Marge 1,76 — zu breit. Wie groß muss die Stichprobe sein, damit die 95-%-Marge höchstens 0,4 beträgt?

```
(qnorm(0.975) * 2.2 / 0.4)^2             # exakter Wert
#> [1] 116.2041
n_benoetigt(sigma = 2.2, delta = 0.4)    # aufgerundet
#> [1] 117
```

Man braucht mindestens 117 Messungen.

Was treibt den Stichprobenumfang?

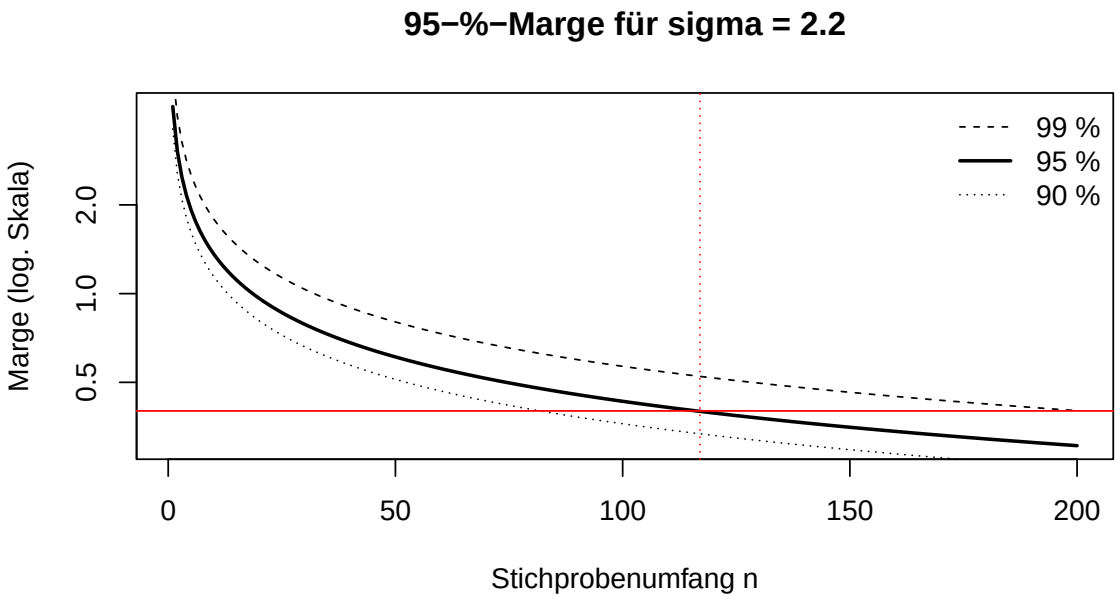
Ein großes n ist nötig für

- eine **kleine Marge** Δ,
- ein **hohes Konfidenzniveau** (kleines α),
- **stark streuende Daten** (großes σ).

Weil Δ nur mit $1/\sqrt{n}$ fällt, muss man den Stichprobenumfang **vervierfachen**, um die Marge zu **halbieren** — dieselbe $1/\sqrt{n}$-Regel wie beim Monte-Carlo-Fehler.

```
n_seq <- 1:200
plot(n_seq, qnorm(0.975) * 2.2 / sqrt(n_seq), type = "l", lwd = 2, log = "y",
     xlab = "Stichprobenumfang n", ylab = "Marge (log. Skala)",
     main = "95-%-Marge für sigma = 2.2")
lines(n_seq, qnorm(0.995) * 2.2 / sqrt(n_seq), lty = 2)
lines(n_seq, qnorm(0.95)  * 2.2 / sqrt(n_seq), lty = 3)
```

```r
abline(h = 0.4, col = "red"); abline(v = 117, col = "red", lty = 3)
legend("topright", c("99 %", "95 %", "90 %"), lty = c(2, 1, 3), lwd = c(1, 2, 1),
       bty = "n")
```




```r
outer(c(sigma_1 = 1, sigma_2 = 2, sigma_5 = 5),
      c(delta_1 = 1, delta_0.5 = 0.5, delta_0.1 = 0.1),
      Vectorize(function(s, d) n_benoetigt(s, d)))
#>         delta_1 delta_0.5 delta_0.1
#> sigma_1       4        16       385
#> sigma_2      16        62      1537
#> sigma_5      97       385      9604
```

i Ausblick: unbekanntes σ

Alle Intervalle dieser Vorlesung setzen ein **bekanntes** σ voraus — etwa aus der Genauigkeit eines Messgeräts oder aus vielen historischen Daten. Meist ist σ aber unbekannt und muss durch s geschätzt werden. Für große Stichproben ändert sich fast nichts; für kleine normalverteilte Stichproben ersetzt man $z_{\alpha/2}$ durch das Quantil der t**-Verteilung** (Baron, §9.3; `t.test()`). Das ist Thema der nächsten Vorlesung.

1.6 Übungsaufgaben

Aufgaben mit Quellenangabe stammen aus Baron, Kapitel 9. Zu jeder Aufgabe gibt es eine aufklappbare Lösung. Versuchen Sie es zuerst selbst — von Hand **und** in R. Die Reiter **Tipp**, **Lösung** und **Erklärung** können Sie einzeln öffnen.

Aufgabe 1: Gleichzeitige Nutzer (Baron, Übung 9.7a). Zu 100 zufälligen Zeitpunkten waren im Mittel 37,7 Nutzer gleichzeitig auf einem Server; $\sigma = 9{,}2$. Berechnen Sie ein 90-%-Konfidenzintervall für die erwartete Nutzerzahl.

Lösung zu Aufgabe 1

1.6.1 Tipp

Formel (9.5) mit $z_{0{,}05} = 1{,}645$. Die Rohdaten brauchen Sie nicht — nur $\bar{x}$, σ und n.

1.6.2 Lösung

```
z <- qnorm(0.95)                          # 90 %: alpha/2 = 0.05
marge <- z * 9.2 / sqrt(100)
c(z = z, marge = marge, unten = 37.7 - marge, oben = 37.7 + marge)
#>         z     marge     unten      oben
#>  1.644854  1.513265 36.186735 39.213265
```

1.6.3 Erklärung

$37{,}7 \pm 1{,}645 \cdot 9{,}2/\sqrt{100} = 37{,}7 \pm 1{,}51$, also $[36{,}19;\ 39{,}21]$.
Ob die Anzahl gleichzeitiger Nutzer normalverteilt ist, spielt keine Rolle: Bei $n = 100$ ist $\bar{X}$ nach dem zentralen Grenzwertsatz näherungsweise normalverteilt. Das Intervall sagt etwas über den **Erwartungswert** — einzelne Zeitpunkte mit 50 oder 20 Nutzern sind damit vereinbar (vgl. Aufgabe 2).

Aufgabe 2: Installationszeit (Baron, Übung 9.8). Die Installation einer Hardware dauert zufällig lang mit $\sigma = 5$ Minuten. (a) Bei 64 Installationen betrug die mittlere Dauer 42 Minuten. Berechnen Sie ein 95-%-Konfidenzintervall für die mittlere Installationszeit. (b) Angenommen, der wahre Mittelwert ist 40 Minuten und die Dauer ist normalverteilt. Mit welcher Wahrscheinlichkeit liegt **eine einzelne** Installation in dem Intervall aus (a)? Warum ist das nicht 95 %?

Lösung zu Aufgabe 2

1.6.4 Tipp

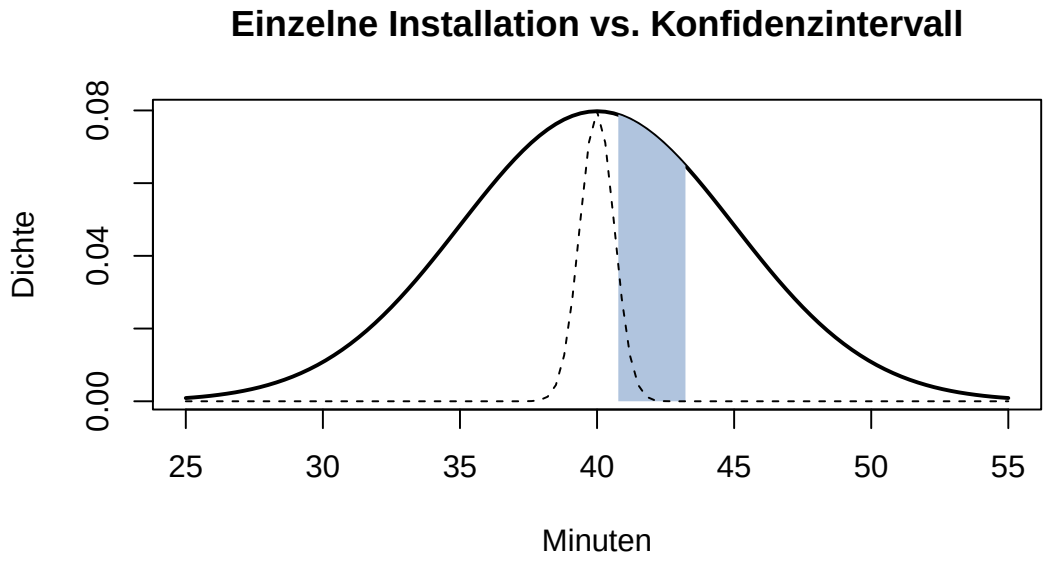
(a) wie Aufgabe 1. (b) Eine einzelne Installation ist $N(40, 5^2)$- verteilt — nicht $N(40, 5^2/64)$. Gesucht ist $P(a \leq X \leq b)$ mit `pnorm()`.

1.6.5 Lösung

```
ki <- 42 + c(-1, 1) * qnorm(0.975) * 5 / sqrt(64)
ki
#> [1] 40.77502 43.22498

diff(pnorm(ki, mean = 40, sd = 5))       # (b): P(a <= X <= b) für eine Installation
#> [1] 0.1789438
```

```
curve(dnorm(x, 40, 5), from = 25, to = 55, lwd = 2, xlab = "Minuten",
      ylab = "Dichte", main = "Einzelne Installation vs. Konfidenzintervall")
xs <- seq(ki[1], ki[2], length.out = 100)
polygon(c(ki[1], xs, ki[2]), c(0, dnorm(xs, 40, 5), 0),
        col = "lightsteelblue", border = NA)
curve(dnorm(x, 40, 5 / 8) / 8, add = TRUE, lty = 2)   # Verteilung von Xquer (skaliert)
```



1.6.6 Erklärung

(a) $42 \pm 1{,}96 \cdot 5/8 = 42 \pm 1{,}23$, also $[40{,}78;\ 43{,}22]$.
(b) $P(40{,}78 \le X \le 43{,}22) \approx 0{,}18$ — weit weg von 95 %. Das Konfidenzintervall ist für den **Mittelwert** gebaut, dessen Standardfehler $\sigma/\sqrt{64} = 0{,}625$ beträgt. Eine einzelne Installation streut mit $\sigma = 5$, also achtmal so stark. Konfidenzintervalle sind keine Vorhersageintervalle für einzelne Beobachtungen. Hinzu kommt, dass das Intervall aus (a) den wahren Mittelwert 40 gar nicht enthält — es ist eines der 5 % „Fehlschläge".

Aufgabe 3: Widerstände (Baron, Übung 9.12). Widerstände sind näherungsweise normalverteilt mit $\sigma = 0{,}2\ \Omega$. 52 Widerstände haben den Mittelwert 0,62 Ω. (a) Berechnen Sie ein 95-%-Konfidenzintervall für den mittleren Widerstand. (b) Wie wahrscheinlich ist ein Mittelwert von 0,62 oder mehr, wenn der wahre Mittelwert genau 0,6 Ω beträgt? (c) Wie viele Widerstände müsste man messen, damit die 99-%-Marge höchstens 0,02 Ω beträgt?

Lösung zu Aufgabe 3

1.6.7 Tipp

(b) Unter $\mu = 0{,}6$ ist $\bar{X} \sim N(0{,}6;\ 0{,}2^2/52)$.
(c) Formel (9.8) mit $z_{0{,}005}$ — und aufrunden.

1.6.8 Lösung

```
se <- 0.2 / sqrt(52)
0.62 + c(-1, 1) * qnorm(0.975) * se                  # (a)
#> [1] 0.5656404 0.6743596

pnorm(0.62, mean = 0.6, sd = se, lower.tail = FALSE) # (b)
#> [1] 0.2354208

(qnorm(0.995) * 0.2 / 0.02)^2                        # (c) exakter Wert
#> [1] 663.4897
n_benoetigt(sigma = 0.2, delta = 0.02, niveau = 0.99)
#> [1] 664
```

1.6.9 Erklärung

(a) $0{,}62 \pm 1{,}96 \cdot 0{,}0277 = 0{,}62 \pm 0{,}054$, also $[0{,}566;\ 0{,}674]$.
(b) $P(\bar{X} \ge 0{,}62) = P\left(Z \ge \frac{0{,}02}{0{,}0277}\right) = P(Z \ge 0{,}72) \approx 0{,}24$. Ein Mittelwert von 0,62 ist bei $\mu = 0{,}6$ also nicht ungewöhnlich — passend dazu enthält das Intervall aus (a) den Wert 0,6.

(c) $n \geq (2{,}576 \cdot 0{,}2/0{,}02)^2 = 663{,}5$, also **664** Widerstände. Gegenüber $n = 52$ entspricht das einer Verkleinerung der Marge von etwa 0,071 (99 %) auf 0,02.

Aufgabe 4: Antwortzeiten zweier Server. Server A beantwortet 80 Anfragen in im Mittel 212 ms, Server B 120 Anfragen in im Mittel 198 ms. Aus Lasttests ist $\sigma_A = 35$ ms und $\sigma_B = 40$ ms bekannt. Berechnen Sie ein 95-%-Konfidenzintervall für $\mu_A - \mu_B$. Ist Server B plausibel schneller?

Lösung zu Aufgabe 4

1.6.10 Tipp

Formel (9.6) bzw. die Funktion `ki_differenz()` aus der Vorlesung. „Plausibel schneller" heißt: Liegt das ganze Intervall für $\mu_A - \mu_B$ oberhalb von 0?

1.6.11 Lösung

```
round(ki_differenz(xq = 212, yq = 198, sigma_x = 35, sigma_y = 40,
                   n = 80, m = 120, niveau = 0.95), 2)
#> differenz     marge     unten      oben
#>     14.00     10.49      3.51     24.49
```

1.6.12 Erklärung

$\sigma(\bar{X} - \bar{Y}) = \sqrt{35^2/80 + 40^2/120} = \sqrt{15{,}31 + 13{,}33} \approx 5{,}35$ und damit $14 \pm 1{,}96 \cdot 5{,}35 = 14 \pm 10{,}5$, also $[3{,}5;\ 24{,}5]$ ms.
Das Intervall liegt vollständig oberhalb von 0: Server A ist plausibel langsamer, Server B also schneller — um geschätzt 14 ms, aber mit großer Unsicherheit (zwischen etwa 3,5 und 24,5 ms). Ob dieser Unterschied praktisch relevant ist, ist eine andere Frage als die statistische. Einen formalen Test dafür lernen wir in Baron §9.4.

Aufgabe 5: Überdeckung selbst messen. Schreiben Sie eine Funktion, die die Überdeckung des Intervalls $\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$ (95 %) für Pareto-Daten mit $\sigma = 1$ schätzt und — wie in der Vorlesung — getrennt zählt, wie oft das Intervall zu hoch bzw. zu tief liegt. Erwartungswert und Varianz sind bekannt: $\mu = \frac{\theta}{\theta-1}$, $\mathrm{Var}(X) = \frac{\theta}{(\theta-1)^2(\theta-2)}$. Untersuchen Sie $\theta = 3$ und $\theta = 2{,}2$ für $n = 10, 100, 1000$. Was fällt auf?

Lösung zu Aufgabe 5

1.6.13 Tipp

Pareto-Zufallszahlen erzeugen Sie wie in Vorlesung 04 per Inversion: $X = \sigma\, U^{-1/\theta}$. Orientieren Sie sich an `fehlerseiten()`. Achten Sie nicht nur auf die Gesamtüberdeckung,

sondern auch auf die Aufteilung der Fehler auf beide Seiten.

1.6.14 Lösung

```r
rpareto <- function(n, sigma, theta) sigma * runif(n)^(-1 / theta)   # Inversion

pareto_seiten <- function(n, theta, R = 10000) {
  mu <- theta / (theta - 1)
  s  <- sqrt(theta / ((theta - 1)^2 * (theta - 2)))
  marge <- qnorm(0.975) * s / sqrt(n)
  r <- replicate(R, {
    xq <- mean(rpareto(n, sigma = 1, theta = theta))
    c(zu_hoch = xq - marge > mu, zu_tief = xq + marge < mu)
  })
  c(ueberdeckung = 1 - mean(colSums(r) > 0),
    zu_hoch = mean(r["zu_hoch", ]), zu_tief = mean(r["zu_tief", ]))
}

set.seed(3)
gitter <- expand.grid(n = c(10, 100, 1000), theta = c(3, 2.2))
cbind(gitter, round(t(mapply(pareto_seiten, gitter$n, gitter$theta)), 4))
#>      n theta ueberdeckung zu_hoch zu_tief
#> 1   10   3.0       0.9636  0.0364  0.0000
#> 2  100   3.0       0.9614  0.0349  0.0037
#> 3 1000   3.0       0.9586  0.0287  0.0127
#> 4   10   2.2       0.9830  0.0170  0.0000
#> 5  100   2.2       0.9820  0.0180  0.0000
#> 6 1000   2.2       0.9839  0.0159  0.0002
```

1.6.15 Erklärung

Überraschend: Die Gesamtüberdeckung liegt **über** 95 % (rund 96 % bei $\theta = 3$, rund 98 % bei $\theta = 2{,}2$). Das Verfahren wirkt also „zu vorsichtig" — tatsächlich ist es aber auf **beiden** Seiten falsch:

- **Zu tief** liegt das Intervall fast nie. Der Mittelwert kann nicht weit unter μ fallen, denn alle Werte sind mindestens $\sigma = 1$.
- **Zu hoch** liegt es dagegen in rund 1,5–3,7 % der Fälle — immer dann, wenn ein seltener, extrem großer Wert den Mittelwert nach oben zieht.

Die Varianz wird von diesen seltenen Extremen dominiert. In einer typischen Stichprobe kommen sie nicht vor; dort ist $\bar{X}$ viel weniger variabel, als $\sigma/\sqrt{n}$ unterstellt, und das Intervall ist unnötig breit.

Bei $\theta = 3$ nähert sich die Aufteilung mit wachsendem n langsam dem symmetrischen Ideal (2,5 % / 2,5 %). Bei $\theta = 2{,}2$ ist davon selbst bei $n = 1000$ nichts zu sehen: Je näher θ an 2 liegt (wo die Varianz unendlich wird), desto langsamer wirkt der zentrale Grenzwertsatz. „n groß genug" hängt also stark von der Verteilung ab — für Daten mit schweren Rändern wie Dateigrößen oder Antwortzeiten kann es sehr groß sein.

1.7 Das Minimum, das Sie ohne Hilfe beherrschen sollten

Begriffe — Konfidenzintervall, Konfidenzniveau, Überdeckungswahrscheinlichkeit, Fehlermarge, Quantil $z_{\alpha/2}$, zentraler Grenzwertsatz, Stichprobenumfangsplanung.

Formeln

Situation	Formel
Allgemeines Konfidenzintervall	$\hat{\theta} \pm z_{\alpha/2}\,\sigma(\hat{\theta})$
Mittelwert, σ bekannt	$\bar{X} \pm z_{\alpha/2}\,\sigma/\sqrt{n}$
Differenz zweier Mittelwerte	$\bar{X} - \bar{Y} \pm z_{\alpha/2}\sqrt{\sigma_X^2/n + \sigma_Y^2/m}$
Stichprobenumfang	$n \geq (z_{\alpha/2}\,\sigma/\Delta)^2$, aufrunden

R — `qnorm()`, `pnorm()`, `mean()`, `replicate()`, `ceiling()`, `segments()`, `curve()`, `polygon()`, `mapply()`, `expand.grid()`.

Achtung:

1. **Konfidenzintervall falsch deuten.** Die 95 % beziehen sich auf das Verfahren, nicht auf das eine berechnete Intervall.
2. **Konfidenz- mit Vorhersageintervall verwechseln.** Das Intervall gilt für den Mittelwert μ, nicht für einzelne Beobachtungen.
3. z_α **statt** $z_{\alpha/2}$**.** Für ein zweiseitiges 95-%-Intervall braucht man `qnorm(0.975)` = 1,96, nicht `qnorm(0.95)` = 1,645.
4. **Varianzen subtrahieren.** Bei $\bar{X} - \bar{Y}$ werden die Varianzen **addiert**.
5. **Stichprobenumfang abrunden.** Immer `ceiling()`.
6. **Formel ohne Voraussetzung anwenden.** $\bar{X} \pm z\,\sigma/\sqrt{n}$ braucht normalverteilte Daten oder ein großes n — bei kleinen, schiefen Stichproben sind die Fehler einseitig.
7. **Nur die Gesamtüberdeckung prüfen.** Ein Verfahren mit 96 % Überdeckung kann trotzdem schlecht sein, wenn alle Fehler auf einer Seite liegen.